ĐẠI HỌC KINH TẾ QUỐC DÂN
VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO VÀ POHE

BÀI TẬP NHÓM

ĐỀ TÀI 9: ADULT CENSUS INCOME
PHÂN TÍCH CÁC YẾU TỐ LIÊN HỆ VỚI MỨC THU NHẬP CÁ NHÂN

Giảng viên:	**Trần Đức Minh**
Môn học:	**Khoa học dữ liệu trong kinh tế và kinh doanh**
Lớp học phần:	**AEP.TOKT1138.LS(126)_01**
Nhóm:	**Nhóm 19**
Thành viên:	**Đan Lê Anh Đạt** **Nguyễn Đại Lợi** **Nguyễn Bảo Thanh** **Nguyễn Đức Việt** **Nguyễn Tuấn Minh**

Hà Nội, 2026

MỤC LỤC

TÓM TẮT iii
ABSTRACT iv
DANH MỤC TỪ VIẾT TẮT viii
CHƯƠNG 1. THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU 1
1.1. Giới thiệu bài toán và mục tiêu 1
1.1.1. Bối cảnh và câu hỏi nghiên cứu 1
1.1.2. Các giả thuyết 1
1.1.3. Phạm vi 2
1.2. Nguồn dữ liệu 2
1.3. Kiểm tra hiện trạng dữ liệu 4
1.3.1. Cấu trúc và kiểu dữ liệu 4
1.3.2. Giá trị thiếu 4
1.3.3. Phân phối của biến mục tiêu 5
1.3.4. Tính nhất quán giữa *education* và *education_num* 5
1.4. Tổng hợp vấn đề phát hiện 5
CHƯƠNG 2. TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU 7
2.1. Giá trị thiếu 7
2.1.1. Mức độ và cơ chế thiếu 7
2.1.2. Giải trình cách xử lý 8
2.1.3. Dùng median hay mean để điền giá trị thiếu 9
2.2. Dòng trùng lặp 9
2.3. Ngoại lệ 10
2.3.1. Phát hiện bằng IQR 10
2.3.2. *capital_gain* và *capital_loss* 11
2.3.3. *hours_per_week* và *age* 11
2.3.4. *fnlwgt* và *education_num* 12
2.4. Biến đổi và mã hóa 12
2.4.1. Vì sao chọn *log1p* thay vì chuẩn hóa thang đo 13
2.5. Tổng kết sau làm sạch 14
CHƯƠNG 3. PHÂN TÍCH VÀ TRỰC QUAN HÓA 16
3.1. Tổng quan 16
3.1.1. Phương pháp luận và quy ước báo cáo thống kê 16

3.2. Kiểm định năm giả thuyết 19
3.2.1. H1: học vấn và thu nhập 19
3.2.2. H2: tuổi và thu nhập 20
3.2.3. H3: số giờ làm và thu nhập 21
3.2.4. H4: chênh lệch giữa nam và nữ 23
3.2.5. H5: tình trạng hôn nhân và thu nhập 25
3.3. So sánh độ mạnh liên hệ giữa các biến 28
3.4. Bảng tổng hợp kết quả kiểm định 30
CHƯƠNG 4. ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ 33
4.1. Các phát hiện nổi bật 33
4.2. Đề xuất giải pháp ứng dụng 34
4.3. Giới hạn của dữ liệu và phân tích 35
4.4. Hướng mở rộng trong tương lai 36
KẾT LUẬN 37
TÀI LIỆU THAM KHẢO 38
PHỤ LỤC 40
Phụ lục A. Mã nguồn 40
Phụ lục B. Mô tả đầy đủ các thuộc tính 40
Phụ lục C. Danh sách hình và tên tệp ảnh 41

TÓM TẮT

Báo cáo phân tích bộ dữ liệu Adult Census Income, trích từ điều tra dân số Mỹ năm 1994 [1], [2], gồm 32,561 quan sát và 15 thuộc tính. Câu hỏi chính là những yếu tố nào liên hệ với việc có thu nhập trên 50K và độ mạnh của các mối liên hệ đó thay đổi ra sao sau khi điều chỉnh đa biến.

Ở giai đoạn làm sạch, giá trị thiếu mã hóa bằng "?" ở ba cột workclass, occupation, native_country được kiểm định cơ chế thiếu (bác bỏ giả định thiếu hoàn toàn ngẫu nhiên MCAR với $p < 0.001$) và gán nhãn Unknown. Sau khi loại 24 dòng trùng lặp, dữ liệu còn 32,537 dòng. Hai cột capital_gain và capital_loss lệch mạnh được biến đổi bằng log1p khi mô tả phân phối, tạo thêm cờ nhị phân (has_cap_gain, has_cap_loss) cho mô hình đa biến và kiểm tra độ nhạy với giá trị chặn trên 99,999. Năm giả thuyết (H1 đến H3 là giả thuyết xác nhận, H4 và H5 là giả thuyết khám phá) được kiểm định bằng tương quan hạng Spearman, Chi-square, Cramér's V hiệu chỉnh sai lệch theo Bergsma, Mann-Whitney U kèm kích thước hiệu ứng CLES, hồi quy logistic bậc hai và đa biến lồng nhau kèm hiệu ứng biên trung bình (AME), khoảng tin cậy Wilson và bootstrap 95%, hiệu chỉnh đa kiểm định Holm ở mức $\alpha = 0.05$ và phân tích độ nhạy theo trọng số lấy mẫu fnlwgt.

Báo cáo ghi nhận ba phát hiện nổi bật nhất. Thứ nhất, tỷ lệ thu nhập trên 50K tăng từ 16.0% (CI 95% [15.3%, 16.7%]) ở nhóm 9 năm học lên 74.1% ([69.7%, 78.1%]) ở nhóm 16 năm học (Spearman $\rho = 0.330$, CI 95% [0.320, 0.340]); tuổi có quan hệ hình chuông đạt cực đại tại 50.4 tuổi trong hồi quy logistic bậc hai (LR $\chi^2 = 2{,}277.0$, $p < 0.001$, đỉnh mô tả 40.1% ở nhóm 45-54 tuổi); số giờ làm tăng tỷ lệ >50K đến nhóm 41-50 giờ (39.6%) rồi chững lại ở nhóm trên 50 giờ (41.3%, CLES = 0.672, Spearman $\rho = 0.269$). Thứ hai, marital_status có Cramér's V hiệu chỉnh là 0.447 ([0.439, 0.456]), ngang ngửa relationship (0.453, [0.445, 0.461]); nhóm Married-civ-spouse đạt 44.7% so với 4.6% ở Never-married, và sau khi điều chỉnh đồng thời tuổi, giới tính, học vấn, giờ làm cùng lãi/lỗ vốn vẫn duy trì tỷ số chênh OR = 9.755 ([8.692, 10.948], LR $\chi^2 = 3{,}050.9$, $p < 0.001$). Thứ ba, khoảng cách thô giữa nữ (11.0%) và nam (30.6%, chênh 19.6 điểm phần trăm, Cohen's h = 0.496) gần như biến mất trong nhóm đã kết hôn (45.5% và 44.6%) nhưng không giảm khi chỉ tách theo giờ làm; trong chuỗi mô hình logistic đa biến lồng nhau (M0 đến M3), chênh lệch xác suất dự đoán trung bình (AME, nữ trừ nam) thu hẹp khoảng 90%, từ -19.63 điểm phần trăm ([-20.57, -18.71]) ở mô hình thô xuống -1.92 điểm phần trăm ([-2.97, -0.84]) ở M2 và -2.03 điểm phần trăm ([-3.20, -0.98], OR = 0.823) ở M3.

Phân tích độ nhạy theo trọng số fnlwgt cho thấy tỷ lệ >50K toàn mẫu có gia quyền (23.87%) rất sát mức chưa gia quyền (24.09%) và độ lệch ở mọi nhóm con không vượt quá 1.3 điểm phần trăm. Giới hạn quan trọng nhất là dữ liệu cắt ngang chỉ phản ánh nước Mỹ năm 1994, ngưỡng 50K nhị phân hóa làm mất thông tin thu nhập chi tiết, và mô hình không loại trừ được các biến gây nhiễu chưa quan sát. Kết quả chỉ mô tả mối liên hệ thống kê, không cho phép kết luận nhân quả.

Từ khóa: Adult Census Income, phân phối thu nhập, phân tích dữ liệu khám phá, hồi quy logistic đa biến, kích thước hiệu ứng, phân tích độ nhạy.

ABSTRACT

This report analyzes the Adult Census Income dataset extracted from the 1994 U.S. Current Population Survey (n = 32,561 observations, 15 attributes) [1], [2] to investigate demographic and employment factors associated with earning over 50,000 USD per year. In the data cleaning stage, missing values encoded as "?" in workclass, occupation, and native_country were formally tested against missing completely at random (MCAR rejected at $p < 0.001$) and assigned an explicit Unknown category; removing 24 exact duplicate records yielded 32,537 clean observations. Log1p transformations and binary indicators (has_cap_gain, has_cap_loss) were constructed for skewed capital columns alongside a sensitivity check excluding the top-coded value 99,999. Five hypotheses (H1–H3 confirmatory, H4–H5 exploratory) were evaluated using Spearman rank correlation, Pearson Chi-square, Bergsma bias-corrected Cramér's V, Mann-Whitney U with Common Language Effect Size (CLES), quadratic and nested multivariable logistic regression with Average Marginal Effects (AME), 95% Wilson and bootstrap confidence intervals, Holm multiple-testing correction, and fnlwgt sampling-weight sensitivity analysis. High-income probability increases with schooling ($\rho = 0.330$, 95% CI [0.320, 0.340]), follows an inverted-U trajectory across age peaking at 50.4 years in quadratic logistic regression (LR $\chi^2 = 2{,}277.0$, $p < 0.001$), and rises with weekly hours up to 41–50 hours (39.6%) before plateauing above 50 hours (41.3%, CLES = 0.672). Marital status exhibits a strong independent association after multivariable adjustment (Married-civ-spouse vs. Never-married OR = 9.755, 95% CI [8.692, 10.948]). Meanwhile, the unadjusted female-minus-male probability gap (-19.63 percentage points, Cohen's h = 0.496) narrows by roughly 90% in nested logistic models to -1.92 percentage points ([-2.97, -0.84]) in M2 and -2.03 percentage points ([-3.20, -0.98], OR = 0.823) in M3. Because the data are cross-sectional from 1994 and dichotomized at 50K, all findings represent statistical associations rather than causal effects.

Keywords: Adult Census Income, income distribution, exploratory data analysis, multivariable logistic regression, effect size, sensitivity analysis.

DANH MỤC HÌNH

Hình 2.1. Tỷ lệ giá trị thiếu sau khi đổi "?" thành NaN 7
Hình 2.2. Boxplot của sáu cột số 10
Hình 2.3. Phân phối capital_gain > 0 trước và sau log1p 14
Hình 3.1. Tỷ lệ >50K theo số năm học (education_num) kèm CI Wilson 95% 19
Hình 3.2. Tỷ lệ >50K theo nhóm tuổi kèm CI Wilson 95% 20
Hình 3.3. Tỷ lệ >50K theo số giờ làm mỗi tuần kèm CI Wilson 95% 21
Hình 3.4. Tỷ lệ >50K theo giới tính, tách theo hôn nhân (trái) và giờ làm (phải) kèm CI Wilson 95% 23
Hình 3.5. Tỷ lệ >50K theo tình trạng hôn nhân kèm CI Wilson 95% 25
Hình 3.6. Cramér's V hiệu chỉnh giữa các biến phân loại và income kèm CI bootstrap 95% 28
Hình 3.7. Ma trận tương quan Spearman của các biến số 29

DANH MỤC BẢNG

Bảng 1.1. Năm giả thuyết và phương pháp kiểm định dự kiến 1
Bảng 1.2. Mô tả 15 thuộc tính của bộ dữ liệu 3
Bảng 1.3. Thống kê mô tả sáu cột số (dữ liệu gốc, n = 32,561) 4
Bảng 1.4. Giá trị thiếu mã hóa bằng "?" (n = 32,561) 4
Bảng 1.5. Phân phối của income (n = 32,561) 5
Bảng 1.6. Các vấn đề dữ liệu, mức độ và nơi xử lý 6
Bảng 2.1. Đối chiếu dòng thiếu của workclass và occupation (n = 32,561) 7
Bảng 2.2. Tỷ lệ >50K khi thiếu và khi đủ kèm kiểm định cơ chế thiếu (n = 32,561) 8
Bảng 2.3. Ảnh hưởng của việc loại dòng trùng 9
Bảng 2.4. Ngoại lệ theo phương pháp IQR (n = 32,537) 10
Bảng 2.5. Quyết định xử lý ngoại lệ theo từng cột 12
Bảng 2.6. Các biến đổi và mã hóa 12
Bảng 2.7. Độ lệch trước và sau log1p 13
Bảng 2.8. Dữ liệu trước và sau làm sạch 14
Bảng 3.1. Mục tiêu và loại biểu đồ của từng hình 16
Bảng 3.1A. Quy ước báo cáo thống kê 18
Bảng 3.2. Tỷ lệ >50K, khoảng tin cậy Wilson 95% và số dòng theo số năm học 19
Bảng 3.3. Tỷ lệ >50K, khoảng tin cậy Wilson 95% và số dòng theo nhóm tuổi 20
Bảng 3.4. Tỷ lệ >50K, khoảng tin cậy Wilson 95% và số dòng theo nhóm giờ làm 22
Bảng 3.5. Tỷ lệ >50K theo hôn nhân và giới tính 23
Bảng 3.6. Tỷ lệ >50K theo giờ làm và giới tính 23
Bảng 3.6A. Hồi quy logistic đa biến lồng nhau và hiệu ứng biên trung bình (AME) của giới tính (Nữ so với Nam, n = 32,537) 24
Bảng 3.7. Tỷ lệ >50K, khoảng tin cậy Wilson 95%, số dòng và tuổi trung vị theo tình trạng hôn nhân 25
Bảng 3.8. Tỷ lệ >50K theo nhóm tuổi và cờ is_married 26
Bảng 3.8A. Hồi quy logistic đa biến cho tình trạng hôn nhân (Married-civ-spouse so với Never-married, n = 32,537) 26
Bảng 3.9. Cramér's V chưa hiệu chỉnh, hiệu chỉnh Bergsma và CI bootstrap 95% giữa biến phân loại và income 28

Bảng 3.10. Cramér's V giữa ba biến có thể chồng lấn 29
Bảng 3.10A. Đối chiếu tỷ lệ >50K chưa gia quyền và có gia quyền theo trọng số fnlwgt (n = 32,537) 30
Bảng 3.11. Tổng hợp kết quả kiểm định năm giả thuyết 30
Bảng 4.1. Đề xuất và phát hiện làm căn cứ 34
Bảng B.1. Kiểu và các giá trị của 15 thuộc tính 40
Bảng C.1. Hình trong báo cáo và tệp ảnh tương ứng 41

DANH MỤC TỪ VIẾT TẮT

AGI: Adjusted Gross Income, thu nhập gộp điều chỉnh

AME: Average Marginal Effects, hiệu ứng biên trung bình

BLS: Bureau of Labor Statistics, Cục Thống kê Lao động Mỹ

CI: Confidence Interval, khoảng tin cậy

CLES: Common Language Effect Size

CPI-U: Consumer Price Index for All Urban Consumers

IQR: Interquartile Range, khoảng tứ phân vị

MAR: Missing At Random

MCAR: Missing Completely At Random

MNAR: Missing Not At Random

OR: Odds Ratio, tỷ số chênh

PSU: Primary Sampling Unit, đơn vị lấy mẫu sơ cấp

UCI: University of California, Irvine

CHƯƠNG 1. THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU

1.1. Giới thiệu bài toán và mục tiêu

1.1.1. Bối cảnh và câu hỏi nghiên cứu

Thu nhập của một người thường đi cùng nhiều đặc điểm nhân khẩu và việc làm như học vấn, độ tuổi, số giờ làm hay tình trạng hôn nhân. Bộ dữ liệu Adult Census Income ghi lại các đặc điểm này cho hơn 32 nghìn người trưởng thành ở Mỹ, kèm một nhãn cho biết thu nhập của họ có vượt 50K hay không [1]. Theo mô tả của bộ dữ liệu, ngưỡng 50K tính bằng đô la Mỹ mỗi năm. Lý thuyết vốn nhân lực cho rằng học vấn và kinh nghiệm đi cùng thu nhập [9], [10]. Bài dùng lý thuyết này để định hướng các giả thuyết, không nhằm kiểm định chính lý thuyết.

Câu hỏi nghiên cứu của bài là: **những yếu tố nào liên hệ với việc có thu nhập trên 50K, và mối liên hệ đó mạnh đến đâu?** Bài có bốn mục tiêu cụ thể:

- Đánh giá chất lượng dữ liệu và ghi lại các vấn đề phát hiện được.
- Làm sạch dữ liệu, mỗi quyết định đều có bằng chứng và lý do.
- Kiểm định năm giả thuyết và so sánh độ mạnh liên hệ của các biến với thu nhập.
- Rút ra phát hiện chính, đề xuất ứng dụng và chỉ rõ giới hạn của kết quả.

1.1.2. Các giả thuyết

Năm giả thuyết dưới đây chia làm hai loại. H1, H2 và H3 là giả thuyết xác nhận, được xác định trước khi thực hiện các kiểm định tương ứng, xuất phát từ những đặc điểm có thể liên hệ với thu nhập. H4 và H5 mang tính khám phá, được phát triển từ những dấu hiệu quan sát được trong dữ liệu, chủ yếu là chênh lệch thô giữa nam và nữ và sự chồng lấn giữa giới tính, hôn nhân và tuổi. Chênh lệch thu nhập theo giới là chủ đề được nghiên cứu rộng rãi trong kinh tế lao động [11]. Hai giả thuyết này được thiết kế để kiểm tra xem một mối liên hệ thô có còn nguyên vẹn sau khi tách hoặc điều chỉnh theo biến thứ ba hay không, nên kết quả của chúng được diễn giải là bằng chứng khám phá chứ không phải xác nhận.

Bảng 1.1. Năm giả thuyết và phương pháp kiểm định dự kiến

Mã	Phát biểu	Biến chính	Phương pháp
H1 (xác nhận)	Học vấn càng cao thì tỷ lệ thu nhập trên 50K càng cao.	education_num, income_bin	Spearman (CI bootstrap 95%), tỷ lệ theo số năm học (CI Wilson 95%)
H2 (xác nhận)	Tỷ lệ thu nhập cao tăng theo tuổi rồi giảm ở nhóm lớn tuổi.	age_group, age_c, age_c2	Chi-square, Cramér's V, hồi quy logistic bậc hai, kiểm định tỷ số hợp lý (LR test)
H3 (xác nhận)	Người làm nhiều giờ hơn có tỷ lệ thu nhập cao hơn.	hours_per_week, hours_group	Mann-Whitney U (kèm CLES, rank-biserial), Spearman, tỷ lệ theo nhóm giờ làm (CI Wilson 95%)

Mã	Phát biểu	Biến chính	Phương pháp
H4 (khám phá)	Chênh lệch tỷ lệ thu nhập cao giữa nam và nữ giảm đáng kể khi kiểm soát theo tình trạng hôn nhân hoặc số giờ làm việc.	sex, marital_status, hours_group và biến kiểm soát	Chi-square, Cramér's V, Cohen's h, tách theo biến thứ ba, hồi quy logistic đa biến lồng nhau (M0–M3) và hiệu ứng biên trung bình (AME)
H5 (khám phá)	Tình trạng hôn nhân liên hệ mạnh với thu nhập, và tuổi không giải thích hết mối liên hệ đó.	marital_status, age_group và biến kiểm soát	Tỷ lệ theo nhóm (CI Wilson 95%), tách theo nhóm tuổi, hồi quy logistic đa biến (M1–M3) và kiểm định LR

1.1.3. Phạm vi

Bài làm trọn trong bốn giai đoạn mà đề yêu cầu: đánh giá dữ liệu, làm sạch, phân tích và trực quan hóa, đánh giá tác động và khuyến nghị. Phân tích dừng ở mô tả và kiểm định mối liên hệ thống kê. Các cụm như "đi cùng" hay "liên hệ với" được dùng xuyên suốt vì dữ liệu quan sát không cho phép kết luận nhân quả. Mọi số liệu lấy từ notebook đi kèm, và các hình được lưu trong thư mục figures.

1.2. Nguồn dữ liệu

Dữ liệu được lấy từ trang Kaggle của UCI tại địa chỉ https://www.kaggle.com/datasets/uciml/adult-census-income [1]. Nguồn gốc là kho UCI Machine Learning Repository, trích từ cơ sở dữ liệu điều tra dân số Mỹ năm 1994 [2]. Notebook tải dữ liệu bằng kagglehub và đọc file adult.csv có sẵn trong máy nếu việc tải bị lỗi.

Bộ dữ liệu chỉ có một file là adult.csv, gồm 32,561 dòng và 15 cột, trong đó 6 cột là số nguyên và 9 cột là chữ (Bảng 1.2). Notebook dùng assert để chặn lại ngay nếu nạp nhầm file có kích thước khác. Mỗi dòng mô tả một người theo tài liệu của dataset, và file không có cột định danh. Tên cột gốc có dấu chấm, chẳng hạn education.num, nên được đổi thành dấu gạch dưới để truy cập thuộc tính bằng mã thuận tiện hơn.

Dữ liệu không phải toàn bộ dân số Mỹ. Theo tài liệu của UCI, bộ Adult được trích từ cơ sở dữ liệu điều tra dân số năm 1994 với bốn điều kiện: tuổi lớn hơn 16 (AAGE > 16), thu nhập gộp điều chỉnh AGI lớn hơn 100, trọng số lấy mẫu fnlwgt lớn hơn 1 và số giờ làm mỗi tuần lớn hơn 0 [2]. Bộ dữ liệu này đã được dùng trong nghiên cứu phân lớp của Kohavi [12]. Các điều kiện trên loại sẵn một phần dân số trước khi dữ liệu được công bố, nên các quan sát không nên được hiểu là một mẫu ngẫu nhiên đại diện đầy đủ cho người trưởng thành ở Mỹ.

Về nguồn gốc của file trên Kaggle, tài liệu UCI nêu bộ Adult có 48,842 quan sát, chia thành phần huấn luyện và phần kiểm tra. File adult.csv dùng ở đây có 32,561 dòng, khớp với số dòng của phần huấn luyện (adult.data) theo mô tả đó, nên nhiều khả năng đây chỉ là phần huấn luyện

chứ không phải toàn bộ 48,842 quan sát. Nhóm chưa đối chiếu từng dòng giữa hai nguồn, nên nhận định này suy ra từ số dòng.

Điều kiện số giờ làm lớn hơn 0 loại những người không làm việc trong tuần điều tra, và có thể ảnh hưởng đến thành phần của nhóm được đưa vào phân tích. Trong dữ liệu, nhóm Married-civ-spouse có 1,657 nữ so với 13,313 nam (Bảng 3.5), một chênh lệch rất lớn về quy mô. Đây có thể liên quan đến sai lệch chọn mẫu và cấu trúc lực lượng lao động. Tuy nhiên, số lượng quan sát một mình không chứng minh được điều kiện giờ làm lớn hơn 0 là nguyên nhân duy nhất, nên bài coi đây là một giả thuyết về sai lệch chọn mẫu cần kiểm chứng, không phải một kết luận đã được chứng minh.

Vì chỉ có một file, không tồn tại khóa chính hay khóa ngoại để gộp bảng. Bước kiểm tra nhất quán giữa các file mà đề nêu vì vậy không áp dụng, và được thay bằng kiểm tra nhất quán nội tại giữa education và education_num ở mục 1.3.4.

Bảng 1.2. Mô tả 15 thuộc tính của bộ dữ liệu

Thuộc tính	Kiểu	Ý nghĩa theo tài liệu UCI	Số giá trị khác nhau
age	Số	Tuổi của người được điều tra	73
workclass	Chữ	Loại hình người sử dụng lao động, ví dụ Private, Self-emp-not-inc, Never-worked	9
fnlwgt	Số	Trọng số lấy mẫu của điều tra (final weight)	21,648
education	Chữ	Trình độ học vấn cao nhất	16
education_num	Số	Trình độ học vấn dưới dạng số	16
marital_status	Chữ	Tình trạng hôn nhân	7
occupation	Chữ	Nhóm nghề nghiệp	15
relationship	Chữ	Vai trò trong hộ gia đình, ví dụ Husband, Wife, Own-child	6
race	Chữ	Chủng tộc	5
sex	Chữ	Giới tính	2
capital_gain	Số	Lãi từ vốn	119
capital_loss	Số	Lỗ từ vốn	92
hours_per_week	Số	Số giờ làm việc mỗi tuần	94
native_country	Chữ	Quốc gia xuất thân	42
income	Chữ	Nhãn thu nhập: <=50K hoặc >50K	2

Số giá trị khác nhau lấy từ output của df_raw.nunique(). *Ba cột* workclass, occupation, native_country *đã tính "?" là một giá trị.*

1.3. Kiểm tra hiện trạng dữ liệu

1.3.1. Cấu trúc và kiểu dữ liệu

Lệnh df.info() cho thấy 32,561 dòng, 15 cột, không ô nào trống theo cách đếm mặc định của pandas. Sáu cột số là age, fnlwgt, education_num, capital_gain, capital_loss, hours_per_week. Chín cột còn lại là chữ. Bảng 1.3 cho thống kê mô tả của sáu cột số trên dữ liệu gốc.

Bảng 1.3. Thống kê mô tả sáu cột số (dữ liệu gốc, n = 32,561)

Cột	Mean	Std	Min	25%	50%	75%	Max
age	38.58	13.64	17	28	37	48	90
fnlwgt	189,778.37	105,549.98	12,285	117,827	178,356	237,051	1,484,705
education_num	10.08	2.57	1	9	10	12	16
capital_gain	1,077.65	7,385.29	0	0	0	0	99,999
capital_loss	87.30	402.96	0	0	0	0	4,356
hours_per_week	40.44	12.35	1	40	40	45	99

Bảng thống kê trả lời câu hỏi: cột số nào có hình dạng bất thường cần xem kỹ hơn. Ba cột nổi lên. capital_gain có trung bình 1,077.65 trong khi trung vị bằng 0 và giá trị lớn nhất là 99,999. capital_loss có tứ phân vị thứ ba vẫn bằng 0 nhưng giá trị lớn nhất là 4,356. hours_per_week có tứ phân vị thứ nhất và trung vị cùng bằng 40, tứ phân vị thứ ba là 45, nên khoảng giữa rất hẹp so với khoảng từ 1 đến 99 giờ. Cả ba dấu hiệu này báo trước các vấn đề về ngoại lệ và độ lệch sẽ được xử lý ở mục 2.3 và 2.4. Bảng này chỉ gợi ý, chưa đủ để kết luận, và nó được tính trước khi loại dòng trùng.

1.3.2. Giá trị thiếu

Notebook đếm số ô NaN thật và nhận được 0. Con số này dễ khiến người đọc nghĩ dữ liệu đầy đủ, nhưng bộ dữ liệu mã hóa giá trị thiếu bằng chuỗi "?" nên isna() mặc định không nhận ra. Khi đếm riêng chuỗi này trên chín cột chữ, ba cột xuất hiện giá trị thiếu (Bảng 1.4). Sáu cột số có kiểu int64 và không chứa chuỗi nên không thể có "?".

Bảng 1.4. Giá trị thiếu mã hóa bằng "?" (n = 32,561)

Cột	Số dòng thiếu	Tỷ lệ (%)
workclass	1,836	5.64
occupation	1,843	5.66
native_country	583	1.79

workclass và occupation thiếu gần bằng nhau, 5.64% và 5.66%, trong khi native_country thấp hơn nhiều với 1.79%. Điều đáng chú ý là hai cột đầu chênh nhau đúng 7 dòng, gợi ý hai cột thiếu ở cùng các dòng, trừ một số rất ít. Điều này được kiểm chứng ở mục 2.1. Ý nghĩa thực tế là nếu bỏ qua bước đếm "?" thì cả ba cột sẽ bị coi là sạch và các nhóm thiếu sẽ bị gộp ngầm vào phân tích. Tính chung, 4,262 ô thiếu nằm trên 2,399 dòng (Bảng 2.8). Bảng này chỉ cho biết có bao nhiêu dòng thiếu, chưa nói được vì sao thiếu.

1.3.3. Phân phối của biến mục tiêu

Bảng 1.5. Phân phối của income (n = 32,561)

Nhãn	Số dòng	Tỷ lệ (%)
<=50K	24,720	75.92
>50K	7,841	24.08

Câu hỏi ở đây là hai nhãn có cân bằng hay không. Nhãn <=50K chiếm 24,720 dòng, tức 75.92%, còn >50K chỉ có 7,841 dòng, tức 24.08% (Bảng 1.5). Nói cách khác, khoảng ba trên bốn người trong mẫu nằm ở mức thu nhập thấp hơn ngưỡng. Hệ quả cho các chương sau là mọi tỷ lệ theo nhóm chỉ có ý nghĩa khi đặt cạnh mức nền chung. Vì vậy, Chương 3 luôn báo cáo tỷ lệ kèm số dòng của nhóm, và lấy mức nền 24.09% của mẫu sau làm sạch làm mốc tham chiếu.

1.3.4. Tính nhất quán giữa *education* và *education_num*

Do không có nhiều file để đối chiếu khóa, bài kiểm tra tính nhất quán nội tại giữa hai cột cùng mô tả học vấn. Notebook nhóm theo education rồi đếm số mã education_num khác nhau, sau đó làm ngược lại. Cả hai chiều đều cho kết quả tối đa là 1, trên toàn bộ 32,561 dòng. Hai cột vì vậy ánh xạ một một với nhau: mỗi trình độ chữ ứng với đúng một mã số và mỗi mã số ứng với đúng một trình độ chữ. Phát hiện này có nghĩa là hai cột mang cùng một thông tin, và việc giữ cả hai trong một phép phân tích sẽ lặp lại thông tin đó. Quyết định dùng education_num được giải trình ở mục 2.4. Giới hạn của phép kiểm tra là nó chỉ chứng minh hai cột khớp nhau, chứ không chứng minh giá trị ghi nhận đúng với trình độ thực tế của từng người.

1.4. Tổng hợp vấn đề phát hiện

Bảng 1.6 gom các vấn đề đã nhận diện và chỉ ra chương xử lý. Hai vấn đề về dòng trùng và ngoại lệ chỉ được xác nhận bằng phép tính ở Chương 2, còn ở giai đoạn này chúng mới được gợi ý qua Bảng 1.3. Mức độ được đánh giá theo ảnh hưởng của vấn đề lên phân tích phía sau.

Bảng 1.6. Các vấn đề dữ liệu, mức độ và nơi xử lý

Vấn đề	Bằng chứng	Mức độ	Xử lý tại
Giá trị thiếu mã hóa bằng “?”	Ba cột thiếu 5.64%, 5.66%, 1.79%, trong khi isna() báo 0 (Bảng 1.4)	Cao	Mục 2.1
Hai cột workclass và occupation thiếu cùng dòng	Chênh nhau chỉ 7 dòng (Bảng 1.4)	Trung bình	Mục 2.1
Biến mục tiêu mất cân bằng	>50K chiếm 24.08% (Bảng 1.5)	Trung bình	Chương 3, báo cáo tỷ lệ kèm n
Dòng trùng lặp	Chưa kiểm tra ở giai đoạn này	Thấp	Mục 2.2
Ngoại lệ và lệch của capital_gain, capital_loss, hours_per_week	Mean khác xa median, Q1 = Q3 = 0 (Bảng 1.3)	Cao	Mục 2.3 và 2.4

Vấn đề	Bằng chứng	Mức độ	Xử lý tại
education và education_num trùng thông tin	Ánh xạ một một hai chiều (mục 1.3.4)	Thấp	Mục 2.4
native_country có nhiều nhóm rất nhỏ	Mỹ chiếm khoảng 90% mẫu, các nước còn lại mỗi nước rất ít dòng	Thấp	Mục 2.4
fnlwgt là trọng số lấy mẫu, không phải đặc điểm của người	Mô tả của UCI (Bảng 1.2)	Thấp	Mục 2.3.4 và 3.3, không dùng trong kiểm định chính, dùng kiểm tra độ nhạy gia quyền
Tên cột chứa dấu chấm	Ví dụ education.num	Thấp	Đổi tên ngay khi nạp dữ liệu

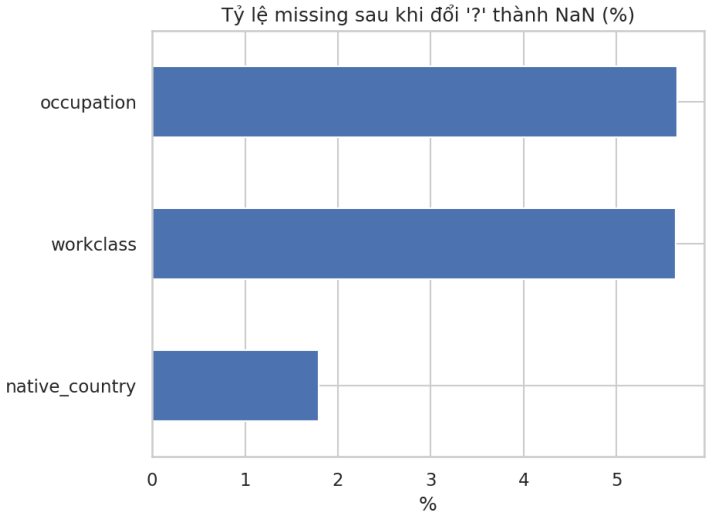
CHƯƠNG 2. TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU

Chương này xử lý lần lượt bốn việc: giá trị thiếu, dòng trùng, ngoại lệ, rồi biến đổi và mã hóa. Thứ tự này trùng với thứ tự trong notebook. Vì dòng trùng chỉ bị loại ở bước thứ hai, các bảng về giá trị thiếu tính trên 32,561 dòng, còn bảng IQR, độ lệch và toàn bộ Chương 3 tính trên 32,537 dòng. Mỗi quyết định được trình bày theo trình tự vấn đề, bằng chứng, giải pháp, lý do và phương án đã loại.

2.1. Giá trị thiếu

2.1.1. Mức độ và cơ chế thiếu

Câu hỏi cần trả lời là giá trị thiếu rải ngẫu nhiên hay đi theo một quy luật nào đó, vì câu trả lời quyết định cách điền. Sau khi đổi chuỗi "?" thành NaN bằng pandas [3], Hình 2.1 cho thấy ba cột bị ảnh hưởng.



Hình 2.1. Tỷ lệ giá trị thiếu sau khi đổi "?" thành NaN

occupation thiếu 5.66%, workclass thiếu 5.64% và native_country thiếu 1.79%. Hai thanh đầu dài gần bằng nhau, còn thanh thứ ba chỉ bằng khoảng một phần ba. Bảng 2.1 kiểm tra xem hai cột đầu có thiếu cùng các dòng hay không.

Bảng 2.1. Đối chiếu dòng thiếu của workclass và occupation (n = 32,561)

	occupation đủ	occupation thiếu
workclass đủ	30,718	7
workclass thiếu	0	1,836

Có 1,836 dòng thiếu đồng thời cả hai cột và không có dòng nào thiếu workclass mà đủ occupation. Bảy dòng còn lại chỉ thiếu occupation và cả bảy đều có workclass là Never-worked. Kết quả này phù hợp với việc một người chưa từng đi làm không có nghề để khai báo, nên bảy dòng này có vẻ là thiếu có lý do chứ không phải sót ghi.

Bảng 2.2. Tỷ lệ >50K khi thiếu và khi đủ kèm kiểm định cơ chế thiếu (n = 32,561)

Cột	Số dòng thiếu	>50K khi thiếu (%)	>50K khi đủ (%)	p-income (χ^2)	p-sex (χ^2)	p-age (MWU)	p-edu (MWU)
workclass	1,836	10.4	24.9	< 0.001	< 0.001	0.722	< 0.001
occupation	1,843	10.4	24.9	< 0.001	< 0.001	0.550	< 0.001
native_country	583	25.0	24.1	0.618	0.009	0.457	< 0.001

Bảng 2.2 cho thấy hai cột đầu hành xử khác native_country. Khi workclass hoặc occupation thiếu, tỷ lệ >50K chỉ là 10.4%, thấp rõ rệt so với 24.9% ở nhóm khai đủ. Với native_country, hai con số gần như trùng nhau, 25.0% và 24.1%. Nếu gộp ba cột thành một cờ "có thiếu" thì sự khác biệt này bị che mất, vì vậy notebook xét từng cột riêng. Bằng chứng này chỉ là gián tiếp. Việc tỷ lệ thu nhập khác nhau cho biết thiếu dữ liệu đi cùng thu nhập thấp hơn, nhưng không nói được lý do người ta bỏ trống.

Về bản chất cơ chế thiếu, 7 dòng Never-worked thiếu occupation thuộc dạng thiếu có cấu trúc (structural missingness), vì người chưa từng đi làm thì không có nghề để ghi. Để kiểm tra xem trạng thái thiếu có hoàn toàn ngẫu nhiên (MCAR) hay không, notebook thực hiện kiểm định Chi-square giữa cờ báo thiếu của từng cột với income_bin và sex, đồng thời kiểm định Mann-Whitney U đối với age và education_num (Bảng 2.2). Ở cả workclass và occupation, trạng thái thiếu liên hệ có ý nghĩa thống kê rất cao với thu nhập ($p < 0.001$), giới tính ($p < 0.001$) và số năm học ($p < 0.001$), trong khi không khác biệt có ý nghĩa theo tuổi ($p = 0.722$ và $p = 0.550$). Ở native_country, trạng thái thiếu không liên hệ với thu nhập ($p = 0.618$) hay tuổi ($p = 0.457$), nhưng có liên hệ với giới tính ($p = 0.009$) và số năm học ($p < 0.001$). Các bằng chứng định lượng này bác bỏ giả định thiếu hoàn toàn ngẫu nhiên (không phải MCAR), cho thấy xác suất thiếu dữ liệu phụ thuộc vào các đặc điểm quan sát được (MAR); tuy nhiên, các phép kiểm định trên dữ liệu quan sát không thể loại trừ khả năng việc không khai báo còn phụ thuộc vào chính nhóm nghề hoặc thu nhập thực tế chưa quan sát được (MNAR).

2.1.2. Giải trình cách xử lý

Vấn đề. Ba cột chứa giá trị thiếu mã hóa bằng "?" cần được xử lý trước khi phân tích.

Bằng chứng. Bảng 2.1 và Bảng 2.2: thiếu ở workclass và occupation trùng gần như hoàn toàn, đi cùng tỷ lệ >50K thấp hơn hẳn (10.4% so với 24.9%, $p < 0.001$) và phụ thuộc vào cả giới tính lẫn học vấn ($p < 0.001$), bác bỏ giả định MCAR.

Giải pháp. Đổi "?" thành NaN, rồi điền nhãn Unknown cho cả ba cột. Sau bước này notebook xác nhận còn 0 giá trị thiếu.

Lý do. Cả ba cột đều là biến phân loại nên một nhãn riêng là cách điền tự nhiên. Với workclass và occupation, nhãn Unknown giữ lại thông tin "không khai báo", vốn đi cùng một tỷ lệ thu nhập khác hẳn. Cách này cũng giữ nguyên số dòng. native_country được làm cùng cách cho nhất quán dù mức khác biệt nhỏ.

Phương án đã loại. Điền giá trị phổ biến nhất (mode) sẽ gán một nghề phổ biến cho những người không khai báo, và xóa mất tín hiệu 10.4% ở trên. Xóa các dòng thiếu sẽ bỏ đi 2,399 dòng có ít nhất một ô thiếu (Bảng 2.8), trong đó nhóm thiếu workclass và occupation có tỷ lệ >50K thấp hơn phần còn lại, nên mẫu giữ lại sẽ lệch về phía thu nhập cao.

2.1.3. Dùng median hay mean để điền giá trị thiếu

Sáu cột số đều có đủ 32,561 giá trị (Bảng 1.3) nên không cần điền. Nếu buộc phải chọn, median phù hợp hơn mean với các cột lệch, và capital_gain là ví dụ rõ nhất. Trên dữ liệu gốc, trung bình của cột này là 1,077.65 trong khi trung vị bằng 0. Trung bình bị kéo lên bởi một nhóm nhỏ có lãi vốn lớn, trong đó có giá trị 99,999. Điền bằng mean sẽ gán cho người thiếu một khoản lãi vốn mà phần lớn mẫu không có, còn median là 0 mô tả đúng người điển hình. Với các cột chữ, bài dùng nhãn Unknown như đã nêu ở mục 2.1.2.

2.2. Dòng trùng lặp

Vấn đề. Một số dòng có thể bị lặp và làm đếm hai lần cùng một người.

Bằng chứng. Notebook đánh dấu 24 dòng trùng khi giữ bản đầu, và 47 dòng thuộc các nhóm trùng. Các ví dụ đầu tiên là những cặp dòng giống hệt nhau ở tất cả các cột, chẳng hạn hai người 19 tuổi cùng fnlwgt 97,261, cùng HS-grad, Never-married, Farming-fishing. Không nhóm trùng nào có nhãn income mâu thuẫn nhau (0 nhóm).

Giải pháp. Loại 24 dòng trùng, giữ bản đầu tiên, đưa dữ liệu từ 32,561 xuống 32,537 dòng.

Lý do. Số dòng bị loại rất ít và nhãn nhất quán, nên việc loại không tạo mâu thuẫn. Bảng 2.3 cho thấy tỷ lệ >50K chỉ đổi từ 24.081% sang 24.093%, tức ảnh hưởng không đáng kể.

Bảng 2.3. Ảnh hưởng của việc loại dòng trùng

Chỉ tiêu	Trước	Sau
Số dòng	32,561	32,537
Tỷ lệ >50K (%)	24.081	24.093

Cần nói thẳng một hạn chế: dữ liệu không có cột định danh, nên bài không chứng minh được chắc chắn rằng 24 dòng này là bản ghi lặp. Hai người khác nhau vẫn có thể trùng toàn bộ các thuộc tính. Cột fnlwgt có tới 21,648 giá trị khác nhau (Bảng 1.2) nên trùng khớp cả cột này cùng các cột còn lại ít có khả năng chỉ do ngẫu nhiên, nhưng đó là suy luận chứ không phải bằng chứng. Quyết định loại vì vậy là một lựa chọn có chủ ý, được cân nhắc dựa trên quy mô nhỏ và tác động không đáng kể.

Phương án đã loại. Giữ nguyên các dòng trùng cũng cho kết quả gần như không đổi, nhưng sẽ đếm lặp nếu chúng thật sự là một bản ghi. Loại cả 47 dòng thuộc nhóm trùng thì mất luôn các bản gốc, và cũng không có lý do để làm vậy.

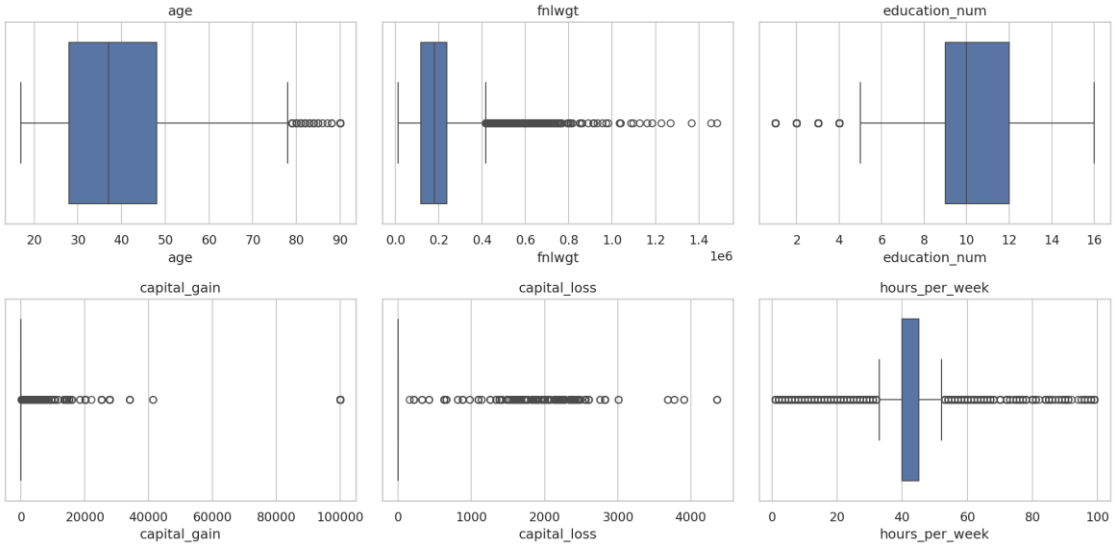
2.3. Ngoại lệ

2.3.1. Phát hiện bằng IQR

Câu hỏi là cột số nào có nhiều giá trị ngoài khoảng thông thường, và phương pháp IQR có đáng tin ở từng cột hay không. IQR (khoảng tứ phân vị) là hiệu giữa tứ phân vị thứ ba và thứ nhất. Một giá trị bị gắn là ngoại lệ nếu nằm dưới Q1 trừ 1.5 lần IQR hoặc trên Q3 cộng 1.5 lần IQR. Bảng 2.4 là kết quả trên 32,537 dòng, và Hình 2.2 là boxplot vẽ bằng seaborn [4].

Bảng 2.4. Ngoại lệ theo phương pháp IQR (n = 32,537)

Cột	Q1	Q3	Cận dưới	Cận trên	Số ngoại lệ	Tỷ lệ (%)
age	28	48	-2	78	142	0.44
fnlwgt	117,827	236,993	-60,922	415,742	993	3.05
education_num	9	12	4.5	16.5	1,193	3.67
capital_gain	0	0	0	0	2,712	8.34
capital_loss	0	0	0	0	1,519	4.67
hours_per_week	40	45	32.5	52.5	9,002	27.67



Hình 2.2. Boxplot của sáu cột số

Theo tỷ lệ, hours_per_week dẫn đầu với 9,002 ngoại lệ (27.67%), tiếp theo là capital_gain (8.34%), capital_loss (4.67%), education_num (3.67%), fnlwgt (3.05%) và age (0.44%). Hình 2.2 cho thấy hình dạng của từng cột. Hai cột capital_gain và capital_loss có hộp dẹt tại 0 và một dải chấm kéo dài sang phải, với điểm xa nhất ở 99,999 và 4,356. hours_per_week có hộp hẹp từ 40 đến 45 giờ, râu từ khoảng 33 đến 52 và chấm ở cả hai phía. age có chấm ở phía trên 78 tuổi, còn education_num có chấm ở các mức 1 đến 4. Điểm đáng chú ý là tỷ lệ ngoại lệ cao không đồng nghĩa với dữ liệu lỗi. Con số 27.67% của hours_per_week và các con số của hai cột capital_* đến từ hình dạng phân phối chứ không phải từ sai sót nhập liệu. Vì vậy mỗi cột cần được xem riêng trước khi quyết định, và các mục dưới đây làm việc đó.

2.3.2. *capital_gain* và *capital_loss*

Hơn 90% giá trị của cả hai cột là 0, nên Q1 và Q3 đều bằng 0, IQR bằng 0 và mọi giá trị khác 0 tự động bị gắn là ngoại lệ. Con số 2,712 và 1,519 ở Bảng 2.4 vì thế chỉ bằng số dòng khác 0 và không cho thêm thông tin nào. Notebook mô tả hai cột bằng tỷ lệ khác 0 và đuôi phân phối. capital_gain khác 0 ở 8.34% số dòng (n = 2,712), trung vị của nhóm khác 0 là 7,298 và giá trị lớn nhất là 99,999. capital_loss khác 0 ở 4.67% số dòng (n = 1,519), trung vị của nhóm khác 0 là 1,887 và giá trị lớn nhất là 4,356. Không dòng nào có đồng thời gain và loss lớn hơn 0.

Giá trị 99,999 đáng chú ý nhất. Nó xuất hiện 159 lần và cả 159 dòng đều có nhãn >50K. Dù là giá trị lớn nhất của cột, nó đứng thứ năm về tần suất, sau 0, 15,024 (347 lần), 7,688 (284 lần) và 7,298 (246 lần). Một mức cao nhất mà lặp lại nhiều như vậy giống một giá trị bị chặn trên hơn là một số đo thật, nghĩa là các khoản lãi vốn lớn hơn có thể đã bị gộp vào cùng một con số.

Quyết định. Giữ nguyên các dòng, không xóa và không cắt đuôi, biến đổi bằng log1p để mô tả phân phối và tạo thêm cờ nhị phân (has_cap_gain, has_cap_loss) ở mục 2.4 cho các mô hình hồi quy. **Lý do.** Nhóm 99,999 đồng nhất với nhãn >50K, nên xóa đi là mất đúng tín hiệu mạnh nhất của cột. Để kiểm tra độ vững (sensitivity) đối với giá trị chặn trên này, notebook đối chiếu kết quả trên toàn bộ dữ liệu sau làm sạch (n = 32,537; hệ số Spearman giữa capital_gain và income_bin đạt $\rho = 0.278$, $p < 0.001$; tỷ lệ >50K toàn mẫu là 24.09%) với trường hợp loại tạm 159 dòng có capital_gain = 99,999 (còn n = 32,378; hệ số Spearman đạt $\rho = 0.257$, $p < 0.001$; tỷ lệ >50K là 23.72%). Việc hệ số tương quan hạng chỉ giảm nhẹ 0.021 và tỷ lệ >50K chỉ chênh 0.37 điểm phần trăm chứng tỏ mối liên hệ thuận chiều giữa lãi vốn và thu nhập vẫn vững chứ không bị chi phối hoàn toàn bởi điểm chặn trên 99,999. **Phương án đã loại.** Xóa theo IQR sẽ loại toàn bộ người có lãi vốn, và cắt đuôi (winsorize) vô nghĩa vì phần đuôi chính là phần có thông tin. Giới hạn của lựa chọn này là phân tích không thể phân biệt các mức lãi vốn thật nằm bên trong nhóm 99,999.

2.3.3. *hours_per_week* và *age*

Gần một nửa số dòng, chính xác là 46.7%, làm đúng 40 giờ mỗi tuần. Khoảng từ Q1 đến Q3 vì vậy chỉ rộng 5 giờ, cận trên 52.5 và cận dưới 32.5, và IQR gắn ngoại lệ cho 9,002 dòng dù phần lớn không phải lỗi. Ở đầu cực trị, có 341 dòng làm từ 80 giờ trở lên, trong đó 85 dòng đúng 99 giờ. Tỷ lệ >50K của nhóm từ 80 giờ trở lên là 35.2%, cao hơn mức nền 24.1%. **Quyết định.** Giữ nguyên và gộp thành nhóm giờ làm ở mục 2.4. **Lý do.** Các giá trị này khả dĩ về mặt thực tế và nhóm cực trị mang thông tin, vì nó có tỷ lệ thu nhập cao khác với phần còn lại.

Với age, tuổi nhỏ nhất là 17 và lớn nhất là 90. Có 142 ngoại lệ phía trên 78 tuổi, gồm 120 dòng từ 80 tuổi trở lên và 42 dòng đúng 90 tuổi. Tỷ lệ >50K của nhóm từ 80 tuổi trở lên là 13.3%, thấp hơn mức nền 24.1%. **Quyết định.** Giữ nguyên và đưa vào nhóm 65+ của age_group. **Lý do.** Đây là các độ tuổi hợp lệ của người trưởng thành, và nhóm này không hành xử như lỗi mà đơn giản là có thu nhập thấp hơn.

2.3.4. *fnlwgt* và *education_num*

fnlwgt là trọng số lấy mẫu của điều tra chứ không phải đặc điểm cá nhân của người được hỏi. Cột này có 993 ngoại lệ theo IQR (3.05%), giá trị lớn nhất là 1,484,705. Các kiểm định và mô hình chính ở Chương 3 tính trên mẫu chưa gia quyền, đồng thời báo cáo bổ sung phân tích độ nhạy so sánh tỷ lệ >50K chưa gia quyền và có gia quyền theo fnlwgt ở mục 3.3 (và thảo luận giới hạn thiết kế mẫu ở mục 4.3). Với education_num, 1,193 ngoại lệ chính là bốn mức 1 đến 4 nằm dưới cận 4.5. Bốn mức này có 50, 166, 332 và 645 dòng (Bảng 3.2), cộng lại đúng 1,193, và đều là trình độ hợp lệ nên được giữ nguyên.

Bảng 2.5. Quyết định xử lý ngoại lệ theo từng cột

Cột	Quyết định	Lý do
age	Giữ, chia nhóm	Độ tuổi hợp lệ, nhóm từ 80 tuổi có tỷ lệ >50K 13.3%
fnlwgt	Giữ, dùng cho kiểm tra độ nhạy	Là trọng số lấy mẫu CPS; dùng để đối chiếu tỷ lệ có gia quyền ở mục 3.3
education_num	Giữ	Các mức 1 đến 4 là trình độ hợp lệ
capital_gain	Giữ, log1p và tạo cờ nhị phân	Q1 = Q3 = 0 nên IQR vô nghĩa; 159 dòng 99,999 đều >50K (loại tạm vẫn cho ρ = 0.257)
capital_loss	Giữ, log1p và tạo cờ nhị phân	Q1 = Q3 = 0 nên IQR vô nghĩa, chỉ 4.67% khác 0
hours_per_week	Giữ, chia nhóm	46.7% dồn ở 40 giờ nên IQR gắn ngoại lệ quá nhiều, nhóm từ 80 giờ có tỷ lệ >50K 35.2%

2.4. Biến đổi và mã hóa

Bảng 2.6 liệt kê các biến đổi và mã hóa được thực hiện kèm lý do chọn. Các cột mới được thêm vào chứ không thay thế cột gốc, nên bộ dữ liệu có 26 cột ở cuối Giai đoạn 2 (và 28 cột khi xuất tệp adult_clean.csv ở cuối Giai đoạn 3 sau khi thêm hai cột gộp nhóm nghề thưa cho mô hình M3).

Bảng 2.6. Các biến đổi và mã hóa

Cột gốc	Kỹ thuật biến đổi / mã hóa	Lý do thực hiện
income	Mã hóa nhị phân thành income_bin (1 nếu >50K, 0 nếu <=50K)	Tính tỷ lệ >50K bằng trung bình, dùng cho tương quan Spearman và hồi quy logistic
education, education_num	Dùng education_num cho H1, Spearman và hồi quy; giữ education cho Cramér's V	Ánh xạ một-một hai chiều (mục 1.3.4), có thứ tự tự nhiên 16 mức
age	Chia 6 nhóm age_group (17-24, 25-34, 35-44, 45-54, 55-64, 65+); tâm hóa age_c = age −	Đặt cận dưới (16, 24] để bao gồm trọn từ 17 tuổi; age_c và age_c2 giúp kiểm định đường cong bậc hai ở H2 và

Cột gốc	Kỹ thuật biến đổi / mã hóa	Lý do thực hiện
	mean(age) và bình phương age_c2 = age_c²	giảm đa cộng tuyến giữa bậc một với bậc hai
hours_per_week	Chia 4 nhóm hours_group: <=34, 35-40, 41-50, >50	Mốc 40 giờ được tách riêng vì tập trung tới 46.7% quan sát
native_country	Gộp 3 nhóm native_group: US, Non-US, Unknown	Mỹ chiếm khoảng 90% mẫu, các quốc gia còn lại mỗi nước rất ít dòng
marital_status	Tạo cờ is_married: Married-civ-spouse là "Đã kết hôn", còn lại là "Khác"	Phục vụ phân tích tách nhóm ở H4, H5 và kiểm định tương tác với giới tính
capital_gain, capital_loss	Biến đổi log1p thành log_cap_gain, log_cap_loss; tạo cờ nhị phân has_cap_gain, has_cap_loss (1 nếu > 0)	log1p giảm độ lệch khi mô tả phân phối; cờ nhị phân phù hợp hơn trong hồi quy logistic vì hơn 90% giá trị bằng 0
workclass, occupation	Tạo workclass_m3, occupation_m3 (gộp nhóm có n < 50 vào Unknown)	Tránh hiện tượng phân tách hoàn toàn hoặc gần hoàn toàn (quasi-separation) khi khớp mô hình logistic đầy đủ M3 ở H4

Sau khi gộp, native_group có 29,153 dòng US, 2,802 dòng Non-US và 582 dòng Unknown. Cần nhớ rằng nhóm "Khác" của is_married còn chứa cả Married-spouse-absent và Married-AF-spouse, vì cờ này chỉ lấy riêng Married-civ-spouse.

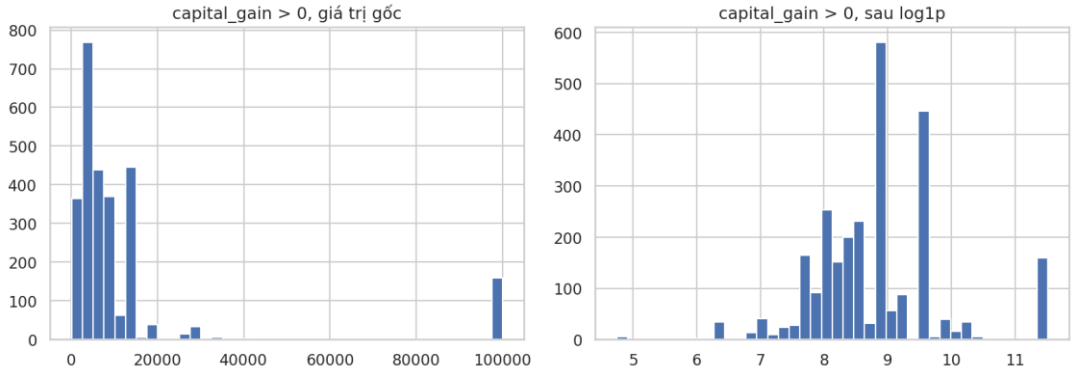
2.4.1. Vì sao chọn *log1p* thay vì chuẩn hóa thang đo

Vấn đề. capital_gain và capital_loss lệch rất mạnh. **Bằng chứng.** Độ lệch (skewness) của capital_gain là 11.95 và của capital_loss là 4.59 (Bảng 2.7). **Giải pháp.** Áp dụng log1p (logarit tự nhiên của 1 cộng giá trị) để quan sát phân phối phần dương, đồng thời tạo hai biến cờ nhị phân has_cap_gain và has_cap_loss (nhận giá trị 1 nếu lớn hơn 0, 0 nếu bằng 0) để đưa vào các mô hình hồi quy logistic ở Chương 3. **Lý do.** Phải dùng log1p thay vì log thường vì cả hai cột có hơn 90% giá trị bằng 0. Trong hồi quy logistic đa biến, việc dùng biến cờ nhị phân hợp lý hơn biến liên tục hay log1p vì đại đa số quan sát nằm tại điểm 0 và log1p không cải thiện được độ lệch của capital_loss. **Phương án đã loại.** StandardScaler và MinMaxScaler chỉ thay đổi thang đo mà giữ nguyên hình dạng phân phối, trong khi MinMaxScaler còn bị giá trị chặn trên 99,999 chi phối toàn bộ khoảng chia. Với Spearman, phép tính dựa trên thứ hạng nên dùng cột gốc hay cột log1p đều cho cùng kết quả.

Bảng 2.7. Độ lệch trước và sau log1p

Phạm vi	Trước	Sau log1p
capital_gain (toàn cột)	11.95	3.09
capital_loss (toàn cột)	4.59	4.31
capital_gain > 0	3.41	0.56

Hình 2.3 trả lời câu hỏi log1p có làm gọn phân phối của capital_gain hay không, và vẽ riêng nhóm lãi vốn dương vì 29,825 dòng bằng 0 sẽ che hết phần còn lại.



Hình 2.3. Phân phối capital_gain > 0 trước và sau log1p

Ở nhóm lãi vốn dương, độ lệch giảm từ 3.41 xuống 0.56, và hình bên phải trải đều hơn hẳn so với hình bên trái, vốn dồn vào vùng dưới 20,000 với một cột lẻ loi ở 99,999. Cột lẻ loi đó là 159 dòng và vẫn hiện ở khoảng 11.5 sau biến đổi. Với toàn cột, độ lệch giảm từ 11.95 xuống 3.09 nhưng vẫn còn cao, vì khối 29,825 giá trị 0 vẫn tồn tại. Điểm bất ngờ nằm ở capital_loss: độ lệch gần như không đổi, 4.59 xuống 4.31. Lý do là cột này chỉ có 4.67% giá trị khác 0, nên độ lệch chủ yếu đến từ khối số 0 chứ không từ phần đuôi, và log1p không xử lý được khối số 0. Bài học là log1p có hiệu quả với capital_gain và gần như vô tác dụng với capital_loss. Cột log_cap_loss vẫn được giữ vì Spearman không phụ thuộc vào phép biến đổi, nhưng không nên coi nó là đã được chuẩn hóa. Hình bên phải cũng còn nhiều cột nhọn, vì lãi vốn lặp lại ở một số mức cố định.

2.5. Tổng kết sau làm sạch

Bảng 2.8 so sánh dữ liệu trước và sau làm sạch, lấy từ output của notebook.

Bảng 2.8. Dữ liệu trước và sau làm sạch

Chỉ tiêu	Trước làm sạch	Sau làm sạch
Số dòng	32,561	32,537
Số cột	15	26 (28 trong adult_clean.csv)
Số ô thiếu (mã hóa bằng "?")	4,262	0
Số dòng có ít nhất một ô thiếu	2,399	0
Số dòng bị đánh dấu trùng	24	0
Tỷ lệ >50K (%)	24.081	24.093

Chỉ 24 dòng bị loại, toàn bộ vì trùng lặp. Không dòng nào bị xóa vì thiếu dữ liệu, mà 4,262 ô thiếu rải trên 2,399 dòng được giữ lại bằng nhãn Unknown. Mười một cột mới được tạo trong Giai đoạn 2 gồm income_bin, age_group, hours_group, log_cap_gain, log_cap_loss, native_group, is_married, has_cap_gain, has_cap_loss, age_c và age_c2 (cùng hai cột phụ trợ

workclass_m3, occupation_m3 tạo trong Giai đoạn 3 cho mô hình M3, đưa tệp xuất adult_clean.csv lên 28 cột). Tỷ lệ >50K gần như không đổi (24.081% sang 24.093%) nên các bước làm sạch không làm lệch biến mục tiêu.

CHƯƠNG 3. PHÂN TÍCH VÀ TRỰC QUAN HÓA

3.1. Tổng quan

Mọi phân tích trong chương này tính trên 32,537 dòng sau làm sạch, và tỷ lệ thu nhập trên 50K của toàn mẫu là 24.09%. Con số này là mức nền để so sánh với tỷ lệ của từng nhóm. Các phép kiểm định dùng thư viện SciPy [5]. Vì mẫu lớn nên mọi giá trị p đều rất nhỏ, được báo cáo là < 0.001, và vì vậy kết luận dựa chủ yếu vào độ lớn của hiệu ứng (hệ số Spearman, Cramér's V) và vào tỷ lệ theo nhóm kèm số dòng, không dựa vào giá trị p.

Bảng 3.1. Mục tiêu và loại biểu đồ của từng hình

Hình	Loại biểu đồ	Câu hỏi phân tích
3.1	Cột, tỷ lệ theo số năm học	H1: tỷ lệ >50K có tăng theo học vấn không
3.2	Đường, tỷ lệ theo nhóm tuổi	H2: tỷ lệ có tăng rồi giảm theo tuổi không
3.3	Cột, tỷ lệ theo nhóm giờ làm	H3: làm nhiều giờ hơn có tỷ lệ cao hơn không
3.4	Cột nhóm, giới tính theo hôn nhân và giờ làm	H4: chênh lệch nam nữ còn lại gì sau khi tách
3.5	Cột ngang, tỷ lệ theo tình trạng hôn nhân	H5: hôn nhân liên hệ với thu nhập mạnh đến đâu
3.6	Cột ngang, Cramér's V	Biến phân loại nào liên hệ mạnh nhất với thu nhập
3.7	Heatmap Spearman	Các biến số liên hệ với nhau và với thu nhập ra sao

3.1.1. Phương pháp luận và quy ước báo cáo thống kê

Giả thuyết không và giả thuyết đối. Mỗi kiểm định dưới đây được phát biểu theo cặp H0 và H1, hai phía.

- **H1.** H0: không có tương quan hạng giữa education_num và income_bin ($\rho = 0$). H1: $\rho \neq 0$. Kiểm định bằng Spearman.
- **H2.** H0: hệ số bậc hai của tuổi trong hồi quy logistic bằng 0, tức quan hệ giữa tuổi và log-odds thu nhập cao là tuyến tính. H1: hệ số này khác 0, và dấu âm cho thấy đường cong có đỉnh. Kiểm định bằng likelihood-ratio test giữa mô hình bậc hai và mô hình tuyến tính.
- **H3.** H0: phân phối giờ làm của hai nhóm thu nhập như nhau. H1: hai phân phối khác nhau. Kiểm định bằng Mann-Whitney U.
- **H4.** H0: sau khi điều chỉnh các biến trong mô hình, hệ số giới tính (nữ so với nam) bằng 0. H1: hệ số này khác 0. Mức thu hẹp chênh lệch được đánh giá riêng bằng chênh lệch xác suất dự đoán đã điều chỉnh và CI bootstrap của nó. Đây là giả thuyết khám phá.

- **H5.** H0: toàn bộ hệ số của marital_status bằng 0 trong mô hình đã điều chỉnh tuổi và các biến khác. H1: có ít nhất một hệ số khác 0. Kiểm định bằng likelihood-ratio test. Đây là giả thuyết khám phá.

Bác bỏ H0 cho biết dữ liệu không phù hợp với H0 ở mức ý nghĩa đã chọn. Không bác bỏ H0 không có nghĩa H0 đúng, mà chỉ là dữ liệu chưa đủ bằng chứng để bác bỏ. Vì vậy báo cáo dùng các cụm "ủng hộ giả thuyết", "ủng hộ một phần" và "chưa đủ bằng chứng" thay cho "chấp nhận giả thuyết".

Mức ý nghĩa và đa kiểm định. Mức ý nghĩa là $\alpha = 0.05$. Năm p-value của H1 đến H5 được coi là một họ kiểm định và được hiệu chỉnh bằng phương pháp Holm [13], công thức (6). H1 đến H3 là giả thuyết xác nhận, H4 và H5 mang tính khám phá, và việc hiệu chỉnh Holm không biến hai giả thuyết khám phá thành xác nhận. Với mẫu hơn 32 nghìn dòng, p-value rất nhỏ ngay cả khi hiệu ứng nhỏ, nên p-value không phản ánh độ lớn hay tầm quan trọng thực tiễn của một mối liên hệ. Báo cáo dùng $p < 0.001$ thay vì số mũ, và dựa chủ yếu vào kích thước hiệu ứng và khoảng tin cậy (CI).

Các phương pháp thống kê. Spearman được dùng cho cặp biến thứ bậc và nhị phân vì dựa trên thứ hạng, không đòi hỏi phân phối chuẩn [6]. Kiểm định chi-square về tính độc lập dùng cho hai biến phân loại, và Cramér's V hiệu chỉnh sai lệch theo Bergsma đo độ mạnh liên hệ, công thức (3) [7], [15]. Mann-Whitney U so sánh hai nhóm khi giờ làm không có phân phối chuẩn [8], kèm CLES = $U/(n_1 n_2)$, là xác suất một người ở nhóm thứ nhất có giá trị lớn hơn một người ở nhóm thứ hai cộng nửa xác suất bằng nhau, và hệ số rank-biserial = $2 \cdot \text{CLES} - 1$. CLES ở đây không phải ROC-AUC của một mô hình dự báo. CI Wilson cho tỷ lệ theo nhóm, công thức (2) [14], ổn định hơn CI chuẩn khi tỷ lệ gần 0 hoặc 1 và khi nhóm nhỏ. CI bootstrap theo cặp quan sát được dùng cho hệ số Spearman và Cramér's V vì không có công thức tham số được xác minh cho hai thống kê này trong bài. Hồi quy logistic cho phép điều chỉnh đồng thời nhiều biến và báo cáo odds ratio (OR) theo công thức (4) [16]. Likelihood-ratio test so hai mô hình lồng nhau. Average Marginal Effects (AME) trong H4 là hiệu của xác suất dự đoán trung bình khi mọi người là nữ và khi mọi người là nam, giữ nguyên các biến khác, vì OR không thu

gọn được nên sự thay đổi OR giữa các mô hình không bằng mức thay đổi chênh lệch xác suất. Cohen's h so hai tỷ lệ, công thức (5).

Công thức. Ký hiệu: k là số người có thu nhập trên 50K trong nhóm, n là cỡ nhóm, z = 1.96.

$$\hat{p} = k / n \qquad (1)$$

$$\tilde{p} = [\, \hat{p} + z^2/(2n) \,] / [\, 1 + z^2/n \,], \;\; CI = \tilde{p} \pm \{\, z / [\, 1 + z^2/n \,] \} \cdot \sqrt{(\, \hat{p}(1 - \hat{p})/n + z^2/(4n^2) \,)} \qquad (2)$$

$$\hat{V} = \sqrt{(\, \tilde{\varphi}^2 / \min(\tilde{k} - 1, \tilde{r} - 1) \,)}, \;\; \tilde{\varphi}^2 = \max\{\, 0, \chi^2/N - (k-1)(r-1)/(N-1) \,\}, \;\; \tilde{k} = k - (k-1)^2/(N-1), \;\; \tilde{r} = r - (r-1)^2/(N-1) \qquad (3)$$

$$\log[\, p / (1 - p) \,] = \beta_0 + \beta_1 x_1 + \ldots + \beta_m x_m, \;\; OR = \exp(\hat{\beta}) \qquad (4)$$

$$h = 2 \cdot \arcsin(\sqrt{p_1}) - 2 \cdot \arcsin(\sqrt{p_2}) \qquad (5)$$

$$p_{Holm}(i) = \max_{j \le i} \min\{\, 1, (m - j + 1) \cdot p(j) \,\}, \;\; p(1) \le \ldots \le p(m), \; m = 5 \qquad (6)$$

Phần mềm và khả năng tái lập. Phân tích được thực hiện trên Python 3.13.18 với các thư viện NumPy 2.4.6, Pandas 2.2.3 [3], SciPy 1.16.3 [5], Statsmodels 0.15.0 [16], Matplotlib 3.10.0 và Seaborn 0.13.2 [4]. Notebook in phiên bản của từng thư viện ngay ở ô đầu tiên khi chạy và xuất dữ liệu sạch ra tệp adult_clean.csv (32,537 dòng, 28 cột) ở ô cuối cùng. Random seed được cố định là 42 cho mọi phép lấy mẫu lại (bootstrap). Số lần bootstrap là 1,000 cho khoảng tin cậy 95% của hệ số Spearman và Cramér's V hiệu chỉnh, và 200 cho khoảng tin cậy 95% của hiệu ứng biên trung bình (AME) trong các mô hình hồi quy logistic ở H4.

Quy ước báo cáo. Bảng 3.1A tóm tắt thông tin được báo cáo cho từng loại thống kê và ngưỡng diễn giải áp dụng thống nhất cho toàn bộ báo cáo.

Bảng 3.1A. Quy ước báo cáo thống kê

Thống kê	Thông tin cần báo cáo	Ngưỡng diễn giải
Tỷ lệ theo nhóm	n, tỷ lệ, Wilson CI 95%	n < 30: nhóm nhỏ, kết quả kém ổn định
Cramér's V	V hiệu chỉnh, bootstrap CI 95%	0.10 nhỏ; 0.30 vừa; 0.50 lớn
Spearman ρ	ρ, bootstrap CI 95%	0.10 nhỏ; 0.30 vừa; 0.50 lớn
Mann-Whitney	U, p, CLES, rank-biserial	CLES 0.56 / 0.64 / 0.71: mốc tham khảo nhỏ / vừa / lớn
Chênh lệch hai tỷ lệ	Cohen's h	0.20 / 0.50 / 0.80
Hồi quy logistic	OR, CI 95%, p-value	Diễn giải theo ngữ cảnh, không áp ngưỡng OR cứng
Mọi kiểm định	p-value gốc và p-Holm	α = 0.05

Các ngưỡng về kích thước hiệu ứng là quy ước tham khảo [17], không phải quy luật phổ quát. Không dùng một thang cố định cho OR, vì cách chuyển OR thành mức hiệu ứng phụ thuộc vào tỷ lệ nền của nhóm tham chiếu [18]. Vì income là biến nhị phân, mọi Cramér's V trong báo cáo

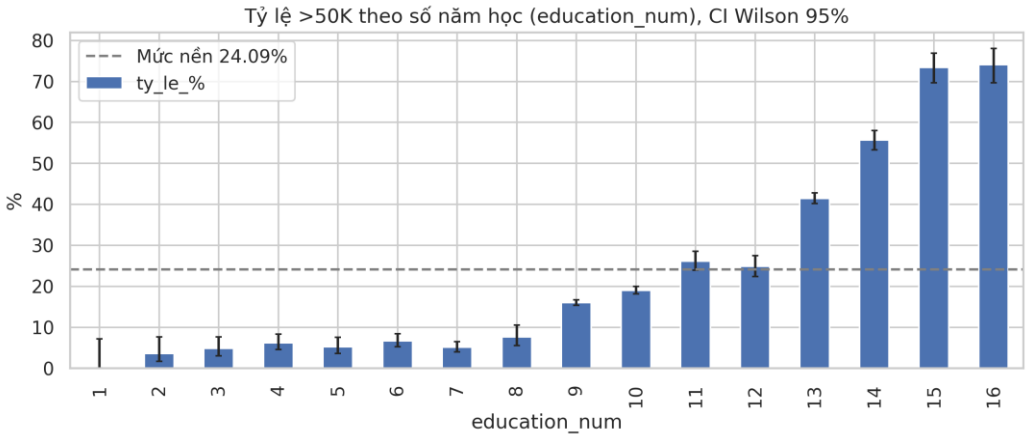
đều dùng cùng một quy ước. Theo quy ước này, V = 0.447 thuộc mức vừa, ở phía cao của khoảng, ρ = 0.27 thuộc mức nhỏ và ρ = 0.33 thuộc mức vừa.

3.2. Kiểm định năm giả thuyết

3.2.1. H1: học vấn và thu nhập

Giả thuyết: học vấn càng cao thì tỷ lệ thu nhập trên 50K càng cao. **Phương pháp:** education_num là biến thứ bậc còn income_bin là biến nhị phân, nên bài dùng hệ số tương quan hạng Spearman [6] kèm khoảng tin cậy bootstrap 95% (B = 1,000), không đòi hỏi phân phối chuẩn. Bài đồng thời tính tỷ lệ >50K kèm khoảng tin cậy Wilson 95% ở từng mức năm học để kiểm tra hình dạng đơn điệu của mối liên hệ.

Câu hỏi của Hình 3.1 là tỷ lệ >50K thay đổi thế nào khi số năm học tăng.



Hình 3.1. Tỷ lệ >50K theo số năm học (education_num) kèm CI Wilson 95%

Bảng 3.2. Tỷ lệ >50K, khoảng tin cậy Wilson 95% và số dòng theo số năm học

Năm học	Tỷ lệ (%)	CI Wilson 95% (%)	n	Năm học	Tỷ lệ (%)	CI Wilson 95% (%)	n
1	0.0	[0.0, 7.1]	50	9	16.0	[15.3, 16.7]	10,494
2	3.6	[1.7, 7.7]	166	10	19.0	[18.1, 20.0]	7,282
3	4.8	[3.0, 7.7]	332	11	26.1	[23.9, 28.5]	1,382
4	6.2	[4.6, 8.3]	645	12	24.8	[22.3, 27.5]	1,067
5	5.3	[3.6, 7.5]	514	13	41.5	[40.2, 42.8]	5,353
6	6.6	[5.2, 8.4]	933	14	55.7	[53.3, 58.0]	1,722
7	5.1	[4.0, 6.5]	1,175	15	73.4	[69.7, 76.9]	576
8	7.6	[5.5, 10.5]	433	16	74.1	[69.7, 78.1]	413

Hệ số tương quan hạng Spearman giữa education_num và income_bin là ρ = 0.330, CI bootstrap 95% [0.320, 0.340], p < 0.001 (p-Holm < 0.001). Tỷ lệ >50K ở các mức từ 1 đến 8 năm học dao động thấp dưới mức nền 24.09%, từ 0.0% (CI Wilson 95% [0.0%, 7.1%]) đến

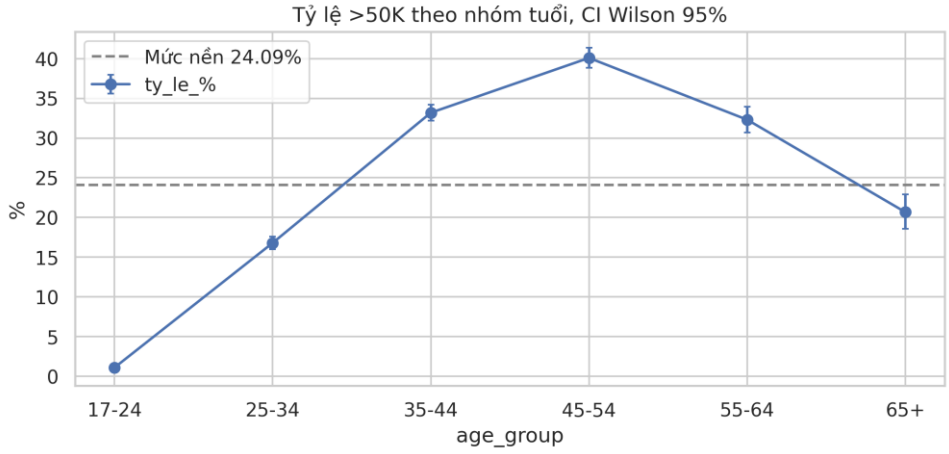
7.6% ([5.5%, 10.5%]). Từ mức 9 năm học trở đi tỷ lệ tăng mạnh: 16.0% ([15.3%, 16.7%]) ở mức 9, 19.0% ([18.1%, 20.0%]) ở mức 10, vượt mức nền ở mức 11 với 26.1% ([23.9%, 28.5%]), đạt 41.5% ([40.2%, 42.8%]) ở mức 13 (cử nhân), 55.7% ([53.3%, 58.0%]) ở mức 14 (thạc sĩ), rồi 73.4% ([69.7%, 76.9%]) ở mức 15 và 74.1% ([69.7%, 78.1%]) ở mức 16 (tiến sĩ). Bước nhảy lớn nhất nằm giữa mức 12 (24.8%) và mức 13 (41.5%) với hai khoảng tin cậy tách biệt hoàn toàn. Có hai đoạn chững lại: mức 11 (26.1%) và mức 12 (24.8%) có khoảng tin cậy Wilson 95% chồng lấn mạnh ([23.9%, 28.5%] so với [22.3%, 27.5%]), và hai mức cao nhất 15 và 16 cũng có khoảng tin cậy gần như trùng nhau ([69.7%, 76.9%] và [69.7%, 78.1%]), cho thấy dấu hiệu bão hòa ở bậc sau đại học. Không có mức học vấn nào có cỡ mẫu n < 30 (n_nho = False ở cả 16 mức), dù mức 1 (n = 50) và mức 2 (n = 166) có khoảng tin cậy rộng hơn các nhóm đông quan sát.

Kết luận: bác bỏ H0, kết quả ủng hộ giả thuyết (kèm điều kiện). Học vấn cao hơn đi cùng tỷ lệ thu nhập >50K cao hơn rõ rệt với kích thước hiệu ứng ở mức vừa (ρ = 0.330, CI 95% [0.320, 0.340]) theo quy ước ở mục 3.1.1, nhưng xu hướng không tăng đơn điệu nghiêm ngặt tại mức 11–12 và bão hòa ở mức 15–16 năm học. Đây là mối liên hệ thống kê trên dữ liệu quan sát, không khẳng định tác động nhân quả trực tiếp của số năm đi học.

3.2.2. H2: tuổi và thu nhập

Giả thuyết: tỷ lệ thu nhập cao tăng theo tuổi rồi giảm ở nhóm lớn tuổi. **Phương pháp:** giả thuyết phát biểu về đường cong có đỉnh (hình chuông), nên bên cạnh việc tính tỷ lệ >50K kèm CI Wilson 95% theo 6 nhóm tuổi và kiểm định Chi-square kèm Cramér's V [7], báo cáo khớp mô hình hồi quy logistic bậc hai theo tuổi đã tâm hóa (income_bin ~ age_c + age_c2) và so sánh với mô hình tuyến tính (income_bin ~ age_c) bằng kiểm định tỷ số hợp lý (likelihood-ratio test) để kiểm định trực tiếp tính chất tăng rồi giảm.

Hình 3.2 hỏi tỷ lệ >50K đạt đỉnh ở nhóm tuổi nào và giảm bao nhiêu sau đỉnh.



Hình 3.2. Tỷ lệ >50K theo nhóm tuổi kèm CI Wilson 95%

Bảng 3.3. Tỷ lệ >50K, khoảng tin cậy Wilson 95% và số dòng theo nhóm tuổi

Nhóm tuổi	Tỷ lệ (%)	CI Wilson 95% (%)	n
17-24	1.1	[0.9, 1.4]	5,562
25-34	16.8	[16.1, 17.7]	8,473
35-44	33.2	[32.1, 34.2]	8,146
45-54	40.1	[38.9, 41.4]	5,849
55-64	32.3	[30.7, 34.0]	3,172
65+	20.7	[18.6, 22.9]	1,335

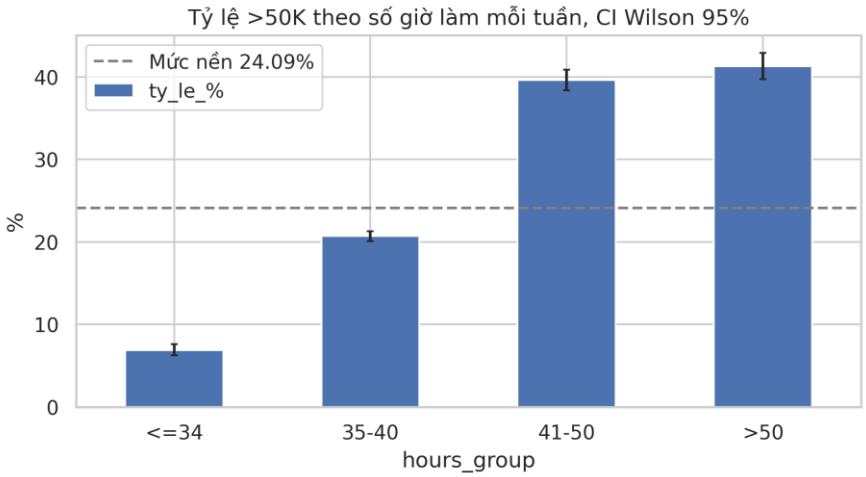
Trên bảng phân tổ theo nhóm tuổi, kiểm định Chi-square cho $\chi^2 = 3{,}168.5$, $p < 0.001$ và Cramér's V = 0.312 (mức liên hệ vừa). Tỷ lệ >50K tăng từ 1.1% (CI Wilson 95% [0.9%, 1.4%]) ở nhóm 17-24, qua 16.8% ([16.1%, 17.7%]) ở 25-34 và 33.2% ([32.1%, 34.2%]) ở 35-44, đạt đỉnh 40.1% ([38.9%, 41.4%]) ở nhóm 45-54, rồi giảm xuống 32.3% ([30.7%, 34.0%]) ở 55-64 và 20.7% ([18.6%, 22.9%]) ở nhóm 65+ (tất cả các nhóm đều có $n \geq 1{,}335$, n_nho = False). Trong hồi quy logistic bậc hai (income_bin ~ age_c + age_c2, thuật toán hội tụ hoàn toàn), hệ số bậc hai của tuổi là $\beta(\text{age_c2}) = -0.00346$ với CI 95% [-0.00363, -0.00329], $p < 0.001$; kiểm định tỷ số hợp lý (LR test) so sánh mô hình bậc hai với mô hình tuyến tính cho $\chi^2 = 2{,}277.0$ (df = 1, $p < 0.001$, p-Holm < 0.001). Hệ số bậc hai mang dấu âm và khác 0 có ý nghĩa thống kê rất cao xác nhận đường cong log-odds thu nhập cao theo tuổi là hàm lõm có điểm cực đại tại 50.4 tuổi (nằm trong khoảng tuổi quan sát [17, 90] và khớp chặt chẽ với nhóm đỉnh 45-54 tuổi trên biểu đồ).

Kết luận: bác bỏ H0, kết quả ủng hộ giả thuyết. Cả thống kê mô tả theo nhóm tuổi (đạt đỉnh 40.1% ở nhóm 45-54 tuổi, Cramér's V = 0.312 ở mức vừa) lẫn kiểm định hồi quy logistic bậc hai ($\beta(\text{age_c2}) = -0.00346 < 0$, LR $\chi^2 = 2{,}277.0$, $p < 0.001$, tuổi cực đại tại 50.4 tuổi) đều xác nhận mối quan hệ tăng theo tuổi rồi giảm ở nhóm lớn tuổi. Cần lưu ý đây là dữ liệu cắt ngang năm 1994, nên sự sụt giảm sau tuổi 50 phản ánh sự khác biệt giữa các nhóm tuổi tại cùng một thời điểm (bao gồm hiệu ứng thế hệ và cấu trúc người còn tham gia lao động sau tuổi nghỉ hưu) chứ không theo dõi quỹ đạo thu nhập của cùng một cá nhân theo thời gian.

3.2.3. H3: số giờ làm và thu nhập

Giả thuyết: người làm nhiều giờ hơn có tỷ lệ thu nhập cao hơn. **Phương pháp:** hours_per_week tập trung mạnh tại mốc 40 giờ (46.7%) nên không thỏa phân phối chuẩn; do đó bài dùng kiểm định phi tham số Mann-Whitney U [8] kèm kích thước hiệu ứng CLES (Common Language Effect Size) và tương quan hạng nhị phân (rank-biserial), kết hợp hệ số tương quan hạng Spearman (kèm CI bootstrap 95%) và tỷ lệ >50K theo bốn nhóm giờ làm (kèm CI Wilson 95%).

Câu hỏi của Hình 3.3 là tỷ lệ >50K có tăng đều theo số giờ làm hay chỉ tăng đến một mốc nào đó.



Hình 3.3. Tỷ lệ >50K theo số giờ làm mỗi tuần kèm CI Wilson 95%

Bảng 3.4. Tỷ lệ >50K, khoảng tin cậy Wilson 95% và số dòng theo nhóm giờ làm

Nhóm giờ làm	Tỷ lệ (%)	CI Wilson 95% (%)	n
<=34	6.9	[6.3, 7.6]	5,578
35-40	20.7	[20.1, 21.3]	17,383
41-50	39.6	[38.4, 40.9]	5,934
>50	41.3	[39.7, 42.9]	3,642

Tỷ lệ >50K tăng mạnh từ 6.9% (CI Wilson 95% [6.3%, 7.6%]) ở nhóm làm từ 34 giờ trở xuống, lên 20.7% ([20.1%, 21.3%]) ở nhóm 35-40 giờ, rồi vọt lên 39.6% ([38.4%, 40.9%]) ở nhóm 41-50 giờ, nhưng chỉ nhích nhẹ lên 41.3% ([39.7%, 42.9%]) ở nhóm làm trên 50 giờ (hai khoảng tin cậy của nhóm 41-50 giờ và >50 giờ chồng lấn nhau). Kiểm định Mann-Whitney U cho U = 130,106,292, $p < 0.001$ (p-Holm < 0.001), với kích thước hiệu ứng CLES = 0.672 (xác suất một người thuộc nhóm >50K làm nhiều giờ hơn một người thuộc nhóm <=50K cộng nửa xác suất bằng nhau đạt 67.2%, thuộc mức vừa đến lớn theo các mốc tham khảo 0.56 / 0.64 / 0.71 ở Bảng 3.1A) và hệ số rank-biserial đạt 0.344. Hệ số tương quan hạng Spearman giữa hours_per_week và income_bin là $\rho = 0.269$, CI bootstrap 95% [0.259, 0.279], $p < 0.001$, thuộc mức liên hệ thuận chiều nhỏ (gần ngưỡng vừa 0.30). Trung vị giờ làm của cả hai nhóm thu nhập đều bằng 40.0 giờ, trong khi trung bình đạt 45.47 giờ ở nhóm >50K so với 38.84 giờ ở nhóm <=50K, cho thấy sự khác biệt nằm chủ yếu ở phần đuôi làm thêm trên 40 giờ.

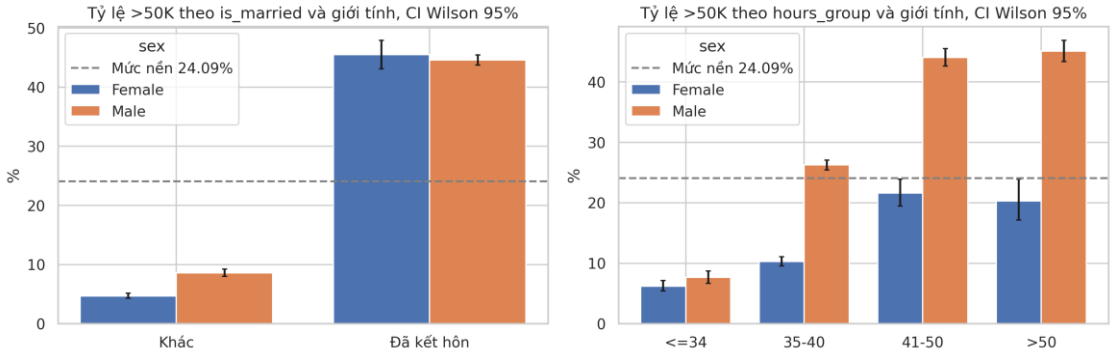
Kết luận: bác bỏ H0, kết quả ủng hộ giả thuyết (kèm điều kiện). Nhóm thu nhập >50K có số giờ làm cao hơn có ý nghĩa thống kê và thực tiễn (CLES = 0.672, rank-biserial = 0.344, Spearman $\rho = 0.269$ [0.259, 0.279]), song tỷ lệ thu nhập cao chỉ tăng rõ đến ngưỡng 41-50 giờ (39.6%) rồi gần như đi ngang ở nhóm trên 50 giờ (41.3%). Do đó không thể khái quát hóa tuyến tính rằng làm càng nhiều giờ ngoài mốc 50 giờ thì xác suất thu nhập cao càng tăng tương ứng.

3.2.4. H4: chênh lệch giữa nam và nữ

Giả thuyết: Chênh lệch tỷ lệ thu nhập cao giữa nam và nữ giảm đáng kể khi kiểm soát theo tình trạng hôn nhân hoặc số giờ làm việc.

Phương pháp: bài đo chênh lệch thô giữa hai giới bằng Chi-square, Cramér's V và kích thước hiệu ứng Cohen's h, sau đó tách mẫu theo từng biến thứ ba (is_married và hours_group) kèm khoảng tin cậy Wilson 95%. Để khắc phục hạn chế của việc chỉ tách từng biến rời rạc, báo cáo khớp bốn mô hình hồi quy logistic đa biến lồng nhau (M0 đến M3, lấy Male làm nhóm tham chiếu) và ước lượng hiệu ứng biên trung bình (Average Marginal Effects - AME, đo mức chênh lệch xác suất dự đoán >50K tính bằng điểm phần trăm giữa nữ và nam khi giữ nguyên các đặc điểm khác) kèm khoảng tin cậy bootstrap 95% (B = 200).

Số liệu thô. Tỷ lệ >50K của nữ là 11.0% (n = 10,762) và của nam là 30.6% (n = 21,775), với Cramér's V = 0.216 (p < 0.001). Chênh lệch thô nam trừ nữ là 19.6 điểm phần trăm (hay nữ trừ nam là -19.63 điểm phần trăm), tương ứng Cohen's h = 0.496 (xấp xỉ ngưỡng hiệu ứng trung bình 0.50). Câu hỏi của Hình 3.4 và chuỗi mô hình M0–M3 là khoảng cách này còn lại bao nhiêu khi tách nhóm và khi điều chỉnh đồng thời các biến nhân khẩu – việc làm.



Hình 3.4. Tỷ lệ >50K theo giới tính, tách theo hôn nhân (trái) và giờ làm (phải) kèm CI Wilson 95%

Bảng 3.5. Tỷ lệ >50K theo hôn nhân và giới tính

Nhóm hôn nhân	Giới tính	Tỷ lệ (%)	n
Đã kết hôn	Nữ	45.5	1,657
Đã kết hôn	Nam	44.6	13,313
Khác	Nữ	4.7	9,105
Khác	Nam	8.6	8,462

Trong mẫu khảo sát, có tới 61.1% nam giới (13,313 trên tổng số 21,775) nằm ở nhóm Đã kết hôn (nhóm có tỷ lệ thu nhập cao xấp xỉ 45%), trong khi chỉ có 15.4% nữ giới (1,657 trên tổng số 10,762) thuộc nhóm này (84.6% nữ nằm ở nhóm Khác vốn có tỷ lệ rất thấp). Chính sự chênh lệch cấu trúc mẫu này (biến nhiễu tình trạng hôn nhân) đã kéo tỷ lệ trung bình thô của toàn bộ nam giới lên cao.

Bảng 3.6. Tỷ lệ >50K theo giờ làm và giới tính

Nhóm giờ làm	Nữ (%)	Nam (%)
<=34	6.2	7.7
35-40	10.3	26.3
41-50	21.6	44.1
>50	20.4	45.1

Hai cách tách đơn biến cho hai bức tranh trái ngược nhau. Trong nhóm Đã kết hôn (Married-civ-spouse), chênh lệch thô gần như biến mất: nữ đạt 45.5% và nam đạt 44.6% (khoảng tin cậy Wilson 95% trên Hình 3.4 chồng lấn hoàn toàn). Trong nhóm Khác, nam vẫn cao hơn nữ (8.6% so với 4.7%), nhưng cả hai đều ở mức thấp. Ngược lại, khi chỉ tách theo giờ làm việc (Bảng 3.6), chênh lệch nam – nữ không thu hẹp mà còn mở rộng ở các nhóm làm nhiều giờ: từ 1.5 điểm phần trăm ở nhóm <=34 giờ (6.2% so với 7.7%) lên 16.0 điểm phần trăm ở nhóm 35-40 giờ (10.3% so với 26.3%), 22.5 điểm phần trăm ở nhóm 41-50 giờ (21.6% so với 44.1%) và 24.7 điểm phần trăm ở nhóm trên 50 giờ (20.4% so với 45.1%).

Bảng 3.6A. Hồi quy logistic đa biến lồng nhau và hiệu ứng biên trung bình (AME) của giới tính (Nữ so với Nam, n = 32,537)

Mô hình	Biến điều chỉnh trong mô hình	OR (Nữ / Nam)	CI 95% (OR)	p-value	Pseudo-R^2	AME (điểm %)	CI 95% (AME)
M0	Chỉ có sex (mô hình thô)	0.279	[0.261, 0.299]	< 0.001	0.047	-19.63	[-20.57, -18.71]
M1	M0 + marital_status	0.728	[0.672, 0.789]	< 0.001	0.198	-4.58	[-5.92, -3.44]
M2	M1 + age_c + age_c2 + education_num + hours_per_week + has_cap_gain + has_cap_loss	0.838	[0.764, 0.919]	< 0.001	0.378	-1.92	[-2.97, -0.84]
M3	M2 + occupation_m3 + workclass_m3	0.823	[0.746, 0.909]	< 0.001	0.401	-2.03	[-3.20, -0.98]

Bảng 3.6A trình bày kết quả kiểm soát đồng thời nhiều biến qua bốn mô hình logistic lồng nhau (cả bốn mô hình đều hội tụ hoàn toàn, không có hiện tượng phân tách với $|\beta|_{max} < 10$ và 0 lần lỗi trong 200 lần bootstrap). Ở mô hình thô M0, tỷ số chênh của nữ so với nam là OR = 0.279 (CI 95% [0.261, 0.299]) và chênh lệch xác suất dự đoán trung bình là AME = -19.63 điểm phần trăm (CI bootstrap 95% [-20.57, -18.71]). Khi đưa thêm tình trạng hôn nhân vào M1, Pseudo-R^2 tăng vọt từ 0.047 lên 0.198, OR tiến về gần 1 hơn (0.728, [0.672, 0.789]) và chênh lệch xác suất dự đoán thu hẹp hơn 3/4, chỉ còn AME = -4.58 điểm phần trăm ([-5.92, -3.44]). Khi điều chỉnh tiếp tuổi (bậc một và bậc hai), học vấn, số giờ làm và lãi/lỗ vốn ở M2

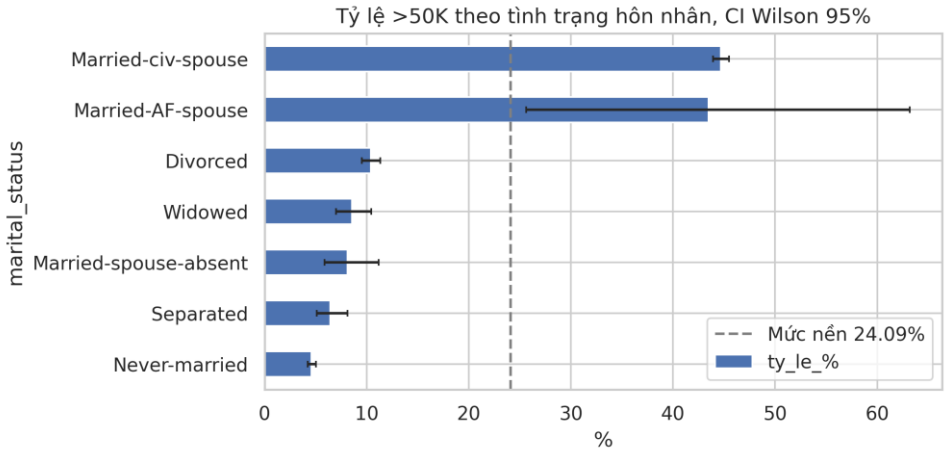
(Pseudo-R^2 = 0.378), OR của nữ so với nam tăng lên 0.838 ([0.764, 0.919], p < 0.001, p-Holm < 0.001) và AME thu hẹp còn -1.92 điểm phần trăm ([-2.97, -0.84]). Ở mô hình đầy đủ M3 có thêm nhóm nghề nghiệp và loại hình lao động (Pseudo-R^2 = 0.401), kết quả giữ ổn định với OR = 0.823 ([0.746, 0.909]) và AME = -2.03 điểm phần trăm ([-3.20, -0.98]). Như vậy, việc điều chỉnh đa biến giúp giải thích khoảng 90% mức chênh lệch xác suất thô ban đầu (-19.63 xuống -1.92 và -2.03 điểm phần trăm).

Kết luận: bác bỏ H0 ở M2 (p < 0.001, p-Holm < 0.001); kết quả ủng hộ một phần giả thuyết khám phá H4. Giả thuyết được ủng hộ ở vế hôn nhân và trong mô hình đa biến khi chênh lệch xác suất dự đoán giữa nữ và nam giảm khoảng 90% (AME từ -19.63 xuống -1.92 điểm phần trăm ở M2 và -2.03 điểm phần trăm ở M3), trong đó cấu trúc tình trạng hôn nhân đóng góp phần thu hẹp lớn nhất. Tuy nhiên, giả thuyết chỉ được ủng hộ một phần vì hai lý do: thứ nhất, khi chỉ tách đơn biến theo số giờ làm việc thì chênh lệch không giảm mà còn lớn hơn mức thô ở các nhóm làm trên 40 giờ (22.5 và 24.7 điểm phần trăm so với 19.6); thứ hai, ngay cả sau khi đã điều chỉnh đồng thời hôn nhân, tuổi, học vấn, giờ làm, lãi/lỗ vốn và nghề nghiệp ở M2–M3, nữ giới vẫn có xác suất dự đoán >50K thấp hơn nam giới khoảng 1.9 đến 2.0 điểm phần trăm (OR = 0.838 và 0.823, khoảng tin cậy 95% không chứa 1). Đây là phần chênh lệch thống kê còn lại trên dữ liệu quan sát năm 1994, không đủ cơ sở để kết luận trực tiếp về phân biệt đối xử vì chưa có thông tin thâm niên thực tế hay vị trí công việc chi tiết.

3.2.5. H5: tình trạng hôn nhân và thu nhập

Giả thuyết: tình trạng hôn nhân liên hệ mạnh với thu nhập, và tuổi không giải thích hết mối liên hệ đó. **Phương pháp:** bài so sánh tỷ lệ >50K kèm khoảng tin cậy Wilson 95% giữa bảy nhóm hôn nhân, đối chiếu tuổi trung vị và tách theo nhóm tuổi, sau đó khớp ba mô hình hồi quy logistic đa biến lồng nhau (M1 đến M3, lấy Never-married làm nhóm tham chiếu) kèm kiểm định tỷ số hợp lý (LR test, df = 6) để đánh giá xem mối liên hệ của hôn nhân còn mạnh đến đâu sau khi điều chỉnh đồng thời tuổi, giới tính, học vấn, giờ làm và lãi/lỗ vốn.

Câu hỏi của Hình 3.5 là nhóm hôn nhân nào có tỷ lệ cao và khoảng cách giữa các nhóm lớn đến mức nào.



Hình 3.5. Tỷ lệ >50K theo tình trạng hôn nhân kèm CI Wilson 95%

Bảng 3.7. Tỷ lệ >50K, khoảng tin cậy Wilson 95%, số dòng và tuổi trung vị theo tình trạng hôn nhân

Tình trạng hôn nhân	Tỷ lệ (%)	CI Wilson 95% (%)	n	Tuổi trung vị
Never-married	4.6	[4.2, 5.0]	10,667	25
Separated	6.4	[5.1, 8.1]	1,025	38
Married-spouse-absent	8.1	[5.9, 11.2]	418	40
Widowed	8.6	[7.0, 10.5]	993	60
Divorced	10.4	[9.6, 11.4]	4,441	42
Married-AF-spouse (*)	43.5	[25.6, 63.2]	23	30
Married-civ-spouse	44.7	[43.9, 45.5]	14,970	42

Bảy nhóm hôn nhân tách thành hai cụm rõ rệt (Bảng 3.7). Hai nhóm đang chung sống với vợ/chồng là Married-civ-spouse (44.7%, CI Wilson 95% [43.9%, 45.5%], n = 14,970) và Married-AF-spouse (43.5%, CI 95% [25.6%, 63.2%], n = 23 - nhóm duy nhất bị đánh dấu n_nho = True do n < 30 nên khoảng tin cậy rất rộng) vượt trội hoàn toàn so với năm nhóm còn lại, vốn chỉ nằm trong khoảng từ 4.6% ([4.2%, 5.0%] ở Never-married) đến 10.4% ([9.6%, 11.4%] ở Divorced). Về độ tuổi, Never-married có tuổi trung vị thấp nhất là 25 tuổi nên yếu tố tuổi trẻ giải thích một phần tỷ lệ 4.6%; tuy nhiên, Divorced và Married-civ-spouse có cùng tuổi trung vị là 42 tuổi mà tỷ lệ >50K chênh nhau hơn 4 lần (10.4% so với 44.7%), còn Widowed có tuổi trung vị cao nhất (60 tuổi) nhưng chỉ đạt 8.6%.

Bảng 3.8. Tỷ lệ >50K theo nhóm tuổi và cờ is_married

Nhóm tuổi	Khác (%)	Đã kết hôn (%)
17-24	0.5	7.0
25-34	5.0	33.6
35-44	10.7	50.3
45-54	14.4	56.0
55-64	11.3	44.5
65+	7.2	31.3

Bảng 3.8 kiểm tra vai trò của tuổi bằng cách phân tầng. Trong mọi nhóm tuổi, người thuộc nhóm Đã kết hôn (Married-civ-spouse) đều có tỷ lệ >50K cao hơn hẳn nhóm Khác, chẳng hạn 33.6% so với 5.0% ở nhóm 25-34 tuổi, 50.3% so với 10.7% ở nhóm 35-44 tuổi và 56.0% so với 14.4% ở nhóm 45-54 tuổi.

Bảng 3.8A. Hồi quy logistic đa biến cho tình trạng hôn nhân (Married-civ-spouse so với Never-married, n = 32,537)

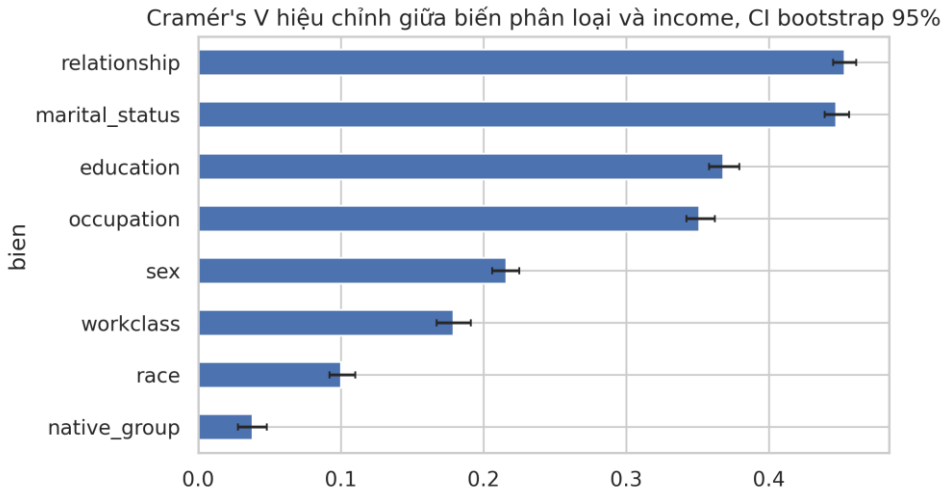
Mô hình	Biến đưa vào mô hình	OR (Married-civ / Never-married)	CI 95% (OR)	p-Wald	LR χ^2 (df = 6)	p-LR	Pseudo-R^2
M1	Chỉ có marital_status	16.745	[15.211, 18.435]	< 0.001	7,057.6	< 0.001	0.196
M2	M1 + age_c + age_c2	7.848	[7.085, 8.693]	< 0.001	4,491.2	< 0.001	0.237
M3	M2 + sex + education_num + hours_per_week + has_cap_gain + has_cap_loss	9.755	[8.692, 10.948]	< 0.001	3,050.9	< 0.001	0.378

Bảng 3.8A định lượng mức độ giải thích của tuổi và các biến đồng hành bằng hồi quy logistic (cả ba mô hình đều hội tụ hoàn toàn). Ở mô hình chưa điều chỉnh M1, tỷ số chênh của Married-civ-spouse so với Never-married là OR = 16.745 (CI 95% [15.211, 18.435], LR χ^2 = 7,057.6, df = 6, $p < 0.001$). Khi điều chỉnh thêm tuổi bậc một và bậc hai ở M2, OR giảm hơn một nửa xuống còn 7.848 ([7.085, 8.693]) và thống kê LR χ^2 của marital_status giảm xuống 4,491.2 ($p < 0.001$), xác nhận rằng cấu trúc tuổi giải thích một phần đáng kể sự chênh lệch thô nhưng không làm biến mất hiệu ứng hôn nhân. Khi điều chỉnh đồng thời cả tuổi, giới tính, học vấn, số giờ làm và lãi/lỗ vốn ở M3, OR của Married-civ-spouse so với Never-married đạt 9.755 ([8.692, 10.948], p-Wald < 0.001) và kiểm định tỷ số hợp lý cho đóng góp chung của biến marital_status đạt LR χ^2 = 3,050.9 (df = 6, p-LR < 0.001, p-Holm < 0.001). Ngoài ra, phép kiểm định tương tác khám phá giữa cờ đã kết hôn và giới tính (is_married × sex) bổ sung vào cấu hình M3 cho LR χ^2 = 164.3 (df = 1, $p < 0.001$), cho thấy độ chênh lệch thu nhập theo tình trạng hôn nhân còn khác biệt giữa nam và nữ (tương ứng với phát hiện ở H4).

Kết luận: bác bỏ H0 (LR χ^2 = 3,050.9, df = 6, p < 0.001, p-Holm < 0.001); kết quả ủng hộ giả thuyết khám phá H5. Tình trạng hôn nhân có liên hệ rất mạnh với xác suất thu nhập >50K. Mặc dù độ tuổi giải thích hơn một nửa độ lớn tỷ số chênh thô giữa nhóm Married-civ-spouse và Never-married (OR giảm từ 16.745 ở M1 xuống 7.848 ở M2), mối liên hệ này vẫn duy trì ở mức rất lớn sau khi đã kiểm soát đồng thời tuổi, giới tính, học vấn, số giờ làm và lãi/lỗ vốn (OR = 9.755, CI 95% [8.692, 10.948] ở M3). Cần lưu ý nhóm Married-AF-spouse chỉ có n = 23 quan sát nên ước lượng 43.5% ([25.6%, 63.2%]) kém ổn định, và trong điều tra CPS thu nhập hay vị trí hộ gia đình có thể phản ánh đặc điểm kinh tế chung của hộ gia đình.

3.3. So sánh độ mạnh liên hệ giữa các biến

Hình 3.6 và Bảng 3.9 so sánh độ mạnh liên hệ đơn biến của tám biến phân loại với income_bin bằng hệ số Cramér's V hiệu chỉnh sai lệch theo Bergsma [15] kèm khoảng tin cậy bootstrap 95% (B = 1,000).



Hình 3.6. Cramér's V hiệu chỉnh giữa các biến phân loại và income kèm CI bootstrap 95%

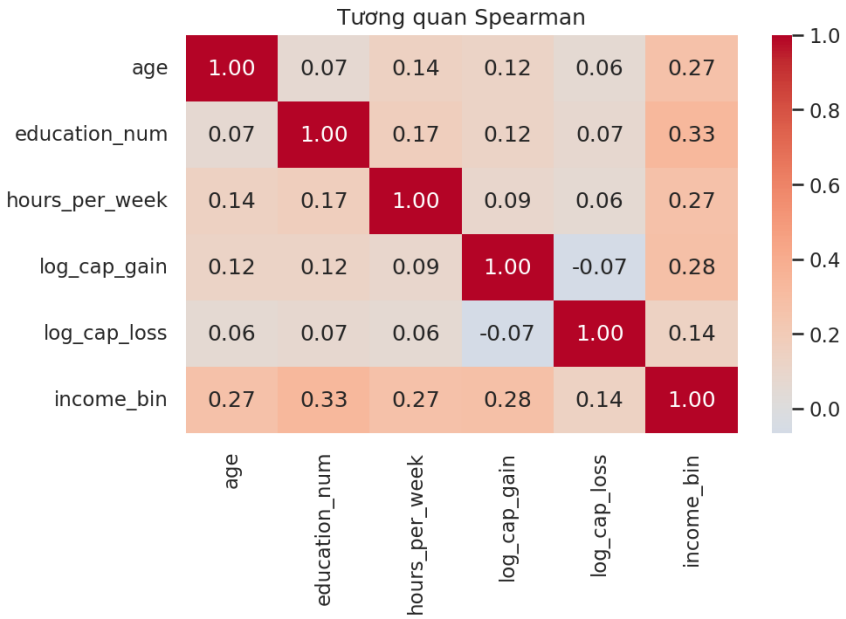
Bảng 3.9. Cramér's V chưa hiệu chỉnh, hiệu chỉnh Bergsma và CI bootstrap 95% giữa biến phân loại và income

Biến phân loại	V chưa hiệu chỉnh	V hiệu chỉnh (Bergsma)	CI bootstrap 95%	Thứ hạng
relationship	0.454	0.453	[0.445, 0.461]	1
marital_status	0.447	0.447	[0.439, 0.456]	2
education	0.369	0.368	[0.358, 0.379]	3
occupation	0.352	0.351	[0.342, 0.362]	4
sex	0.216	0.216	[0.206, 0.225]	5
workclass	0.179	0.179	[0.167, 0.191]	6
race	0.101	0.100	[0.092, 0.110]	7
native_group	0.039	0.038	[0.028, 0.048]	8

Do cỡ mẫu lớn (n = 32,537), giá trị Cramér's V hiệu chỉnh Bergsma chỉ lệch tối đa 0.001 so với V chưa hiệu chỉnh. Bốn biến đứng đầu đều thuộc mức liên hệ vừa (≥ 0.30 theo quy ước ở Bảng 3.1A): dẫn đầu là relationship (V_bc = 0.453, CI 95% [0.445, 0.461]) và marital_status (V_bc = 0.447, [0.439, 0.456]), tiếp theo là education (V_bc = 0.368, [0.358, 0.379]) và occupation (V_bc = 0.351, [0.342, 0.362]). Cần lưu ý khoảng tin cậy bootstrap 95% của relationship ([0.445, 0.461]) và marital_status ([0.439, 0.456]) chồng lấn nhau đáng kể, cũng như khoảng tin cậy của education ([0.358, 0.379]) và occupation ([0.342, 0.362]) giao nhau nhẹ ở vùng [0.358, 0.362], nên không thể khẳng định thứ hạng tuyệt đối tách biệt bên trong

từng cặp biến này. Nhóm có mức liên hệ nhỏ gồm sex (0.216, [0.206, 0.225]), workclass (0.179, [0.167, 0.191]) và race (0.100, [0.092, 0.110]), trong khi native_group đứng cuối bảng (0.038, [0.028, 0.048]), gần như không liên hệ với thu nhập.

Hình 3.7 cho thấy bức tranh tương ứng của các biến số, đo bằng Spearman.



Hình 3.7. Ma trận tương quan Spearman của các biến số

Với income_bin, education_num có hệ số cao nhất là 0.33, tiếp theo là log_cap_gain (0.28), age và hours_per_week (cùng 0.27) và log_cap_loss thấp nhất (0.14). Giữa các biến số với nhau tương quan đều yếu: age với education_num là 0.07, age với hours_per_week là 0.14, education_num với hours_per_week là 0.17, và log_cap_gain với log_cap_loss là -0.07. Hệ số âm nhẹ này khớp với việc không dòng nào có cả lãi và lỗ vốn. Vì các biến số ít chồng lấn nhau, mỗi biến mang một phần thông tin riêng, và không có biến số nào vượt trội, cao nhất cũng chỉ 0.33.

Bảng 3.10. Cramér's V giữa ba biến có thể chồng lấn

Cặp biến	Cramér's V	Mức
relationship và sex	0.649	Mạnh nhất
relationship và marital_status	0.488	Mạnh
marital_status và sex	0.462	Mạnh

Cần cảnh báo về ba biến relationship, marital_status và sex. Bảng 3.10 cho thấy các cặp giữa chúng có Cramér's V từ 0.462 đến 0.649, cao hơn mối liên hệ của từng biến với thu nhập (0.216 đến 0.454). Vì vậy không nên cộng độ mạnh của ba biến, hay hiểu sex hoặc marital_status là các yếu tố liên hệ độc lập với thu nhập. Một phần của sex chẳng hạn đã nằm sẵn trong relationship, vì các nhóm như Husband và Wife ngầm chứa giới tính.

Phân tích độ nhạy theo trọng số lấy mẫu fnlwgt. Để kiểm tra xem việc không sử dụng trọng số lấy mẫu fnlwgt trong các bảng mô tả có làm sai lệch kết luận hay không, notebook tính lại

tỷ lệ >50K có gia quyền theo fnlwgt cho toàn mẫu và theo các biến phân tích chính (age_group, education_num, sex, is_married). Trên toàn bộ 32,537 quan sát, tỷ lệ >50K chưa gia quyền là 24.09% và có gia quyền là 23.87% (chênh -0.22 điểm phần trăm). Bảng 3.10A đối chiếu chi tiết theo từng nhóm.

Bảng 3.10A. Đối chiếu tỷ lệ >50K chưa gia quyền và có gia quyền theo trọng số fnlwgt (n = 32,537)

Biến / Nhóm phân tích	Chưa gia quyền (%)	Có gia quyền fnlwgt (%)	Chênh lệch (điểm %)
Toàn mẫu (n = 32,537)	24.09	23.87	-0.22
Nhóm tuổi: 17-24 / 25-34 / 35-44	1.1 / 16.8 / 33.2	1.2 / 16.9 / 33.4	+0.1 / 0.0 / +0.3
Nhóm tuổi: 45-54 / 55-64 / 65+	40.1 / 32.3 / 20.7	40.7 / 33.2 / 19.7	+0.6 / +0.8 / -1.0
Học vấn: mức 9 / mức 10 / mức 13 / mức 16	16.0 / 19.0 / 41.5 / 74.1	15.6 / 19.7 / 41.9 / 75.1	-0.4 / +0.6 / +0.4 / +1.0
Học vấn: biên độ lệch trên toàn bộ 16 mức (1–16)	0.0 đến 74.1	0.0 đến 75.1	Từ -1.3 (mức 3) đến +1.0 (mức 16)
Giới tính: Nữ (Female) / Nam (Male)	11.0 / 30.6	10.8 / 30.1	-0.1 / -0.5
Hôn nhân (is_married): Khác / Đã kết hôn	6.5 / 44.7	6.4 / 45.0	-0.1 / +0.3

Kết quả ở Bảng 3.10A cho thấy độ lệch giữa tỷ lệ có gia quyền và chưa gia quyền là rất nhỏ: không quá 1.0 điểm phần trăm ở mọi nhóm tuổi (lệch lớn nhất là -1.0 điểm phần trăm ở nhóm 65+ và +0.8 điểm phần trăm ở nhóm 55-64), từ -1.3 đến +1.0 điểm phần trăm trên toàn bộ 16 mức học vấn, không quá 0.5 điểm phần trăm theo giới tính và không quá 0.3 điểm phần trăm theo tình trạng hôn nhân. Do đó, mọi nhận định về xu hướng, thứ bậc và hình dạng mối liên hệ ở H1–H5 đều hoàn toàn vững khi xét theo trọng số fnlwgt.

3.4. Bảng tổng hợp kết quả kiểm định

Bảng 3.11. Tổng hợp kết quả kiểm định năm giả thuyết

Mã	Phương pháp kiểm định	Thống kê và kích thước hiệu ứng chính	p-gốc	p-Holm	Kết luận
H1 (xác nhận)	Spearman (CI bootstrap 95%), tỷ lệ theo nhóm (CI Wilson 95%)	ρ = 0.330, CI 95% [0.320, 0.340] (mức vừa). Tỷ lệ tăng từ 16.0% [15.3, 16.7] (mức 9) lên 41.5% [40.2, 42.8] (mức 13) và 74.1% [69.7, 78.1] (mức 16)	< 0.001	< 0.001	Bác bỏ H0; ủng hộ giả thuyết (kèm điều kiện: chững lại ở mức 11–12 và bão hòa ở mức 15–16)

Mã	Phương pháp kiểm định	Thống kê và kích thước hiệu ứng chính	p-gốc	p-Holm	Kết luận
H2 (xác nhận)	Chi-square, Cramér's V, hồi quy logistic bậc hai, LR test	χ^2 = 3,168.5, V = 0.312 (mức vừa). Hồi quy bậc hai: β(age_c2) = -0.00346 [-0.00363, -0.00329], LR χ^2 = 2,277.0, tuổi cực đại tại 50.4 (nhóm 45-54 đạt 40.1% [38.9, 41.4])	< 0.001	< 0.001	Bác bỏ H0; ủng hộ giả thuyết (đường cong hình chuông có đỉnh tại 50.4 tuổi trên dữ liệu cắt ngang)
H3 (xác nhận)	Mann-Whitney U, CLES, rank-biserial, Spearman, tỷ lệ theo nhóm	U = 130,106,292; CLES = 0.672 (vừa–lớn), rank-biserial = 0.344; Spearman ρ = 0.269 [0.259, 0.279] (nhỏ). Mean giờ làm 45.47 vs 38.84 (median cùng 40.0). Tỷ lệ 6.9% đến 41.3%	< 0.001	< 0.001	Bác bỏ H0; ủng hộ giả thuyết (kèm điều kiện: tăng rõ đến 41-50 giờ rồi phẳng ở nhóm >50 giờ)
H4 (khám phá)	Chi-square, Cohen's h, tách nhóm, logistic đa biến lồng nhau (M0–M3), AME	Thô: nữ 11.0% vs nam 30.6% (V = 0.216, Cohen's h = 0.496). Tách hôn nhân: 45.5% vs 44.6%; tách giờ làm: 21.6% vs 44.1% (41-50 giờ). Logistic M0→M3: OR nữ/nam từ 0.279 [0.261, 0.299] lên 0.838 [0.764, 0.919] (M2) và 0.823 [0.746, 0.909] (M3); AME từ -19.63 [-20.57, -18.71] xuống -1.92 [-2.97, -0.84] (M2) và -2.03 [-3.20, -0.98] điểm % (M3)	< 0.001	< 0.001	Bác bỏ H0 ở M2; ủng hộ một phần (AME giảm ~90% sau điều chỉnh đa biến nhưng không giảm khi chỉ tách theo giờ làm và vẫn còn chênh ~2 điểm %)
H5 (khám phá)	Tỷ lệ theo nhóm, tách theo tuổi, logistic đa biến (M1–M3), LR test	V_bc = 0.447 [0.439, 0.456]. Married-civ-spouse 44.7% [43.9, 45.5] vs Never-married 4.6% [4.2, 5.0]. Logistic OR (Married-civ vs Never-married): M1 = 16.745 [15.211, 18.435], M2 (+tuổi) = 7.848 [7.085, 8.693], M3 (đầy đủ) = 9.755 [8.692, 10.948]; LR χ^2(M3, df=6) = 3,050.9	< 0.001	< 0.001	Bác bỏ H0; ủng hộ giả thuyết (tuổi giải thích hơn nửa OR thô nhưng hôn nhân vẫn có liên hệ độc lập rất mạnh sau điều chỉnh đa biến)

Sau khi áp dụng thủ tục hiệu chỉnh đa kiểm định Holm (m = 5, α = 0.05) cho họ năm giả thuyết từ H1 đến H5, cả năm giá trị p-Holm đều đạt < 0.001 và đều bác bỏ H0. Như đã phân định ở

mục 1.1.2 và 3.1.1, H1–H3 là các kiểm định xác nhận còn H4–H5 là các phân tích khám phá được làm sâu bằng mô hình đa biến.

CHƯƠNG 4. ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ

4.1. Các phát hiện nổi bật

Học vấn đi cùng thu nhập cao rõ nhất từ bậc đại học trở lên. Tỷ lệ >50K tăng từ 16.0% (CI 95% [15.3%, 16.7%]) ở nhóm 9 năm học lên 41.5% ([40.2%, 42.8%]) ở nhóm 13 và 74.1% ([69.7%, 78.1%]) ở nhóm 16 năm học, với hệ số tương quan hạng Spearman $\rho = 0.330$, CI bootstrap 95% [0.320, 0.340] (Hình 3.1).

Vị trí trong gia đình và tình trạng hôn nhân là nhóm biến liên hệ mạnh nhất, ngay cả sau khi điều chỉnh đa biến. relationship đạt Cramér's V hiệu chỉnh 0.453 ([0.445, 0.461]) và marital_status đạt 0.447 ([0.439, 0.456]), với hai khoảng tin cậy chồng lấn nhau (Hình 3.6). Nhóm Married-civ-spouse có tỷ lệ >50K là 44.7% so với 4.6% ở nhóm Never-married (Hình 3.5); khi điều chỉnh đồng thời tuổi, giới tính, học vấn, giờ làm và lãi/lỗ vốn trong hồi quy logistic (M3), tỷ số chênh OR vẫn đạt 9.755 ([8.692, 10.948], LR χ^2 = 3,050.9, $p < 0.001$). Đồng thời, ba biến relationship, marital_status, sex có Cramér's V với nhau từ 0.462 đến 0.649 (Bảng 3.10).

Tuổi có quan hệ đường cong hình chuông được xác nhận bằng kiểm định bậc hai. Tỷ lệ >50K tăng từ 1.1% ở nhóm 17-24 lên đỉnh 40.1% ([38.9%, 41.4%]) ở nhóm 45-54 rồi giảm còn 20.7% ở nhóm 65+ (Hình 3.2). Hồi quy logistic bậc hai cho hệ số $\beta(age_c2) = -0.00346$ ($p < 0.001$, LR χ^2 = 2,277.0 so với mô hình tuyến tính) với đỉnh xác suất dự đoán tại 50.4 tuổi.

Số giờ làm việc liên hệ thuận với thu nhập đến ngưỡng 41-50 giờ rồi đi ngang. Tỷ lệ >50K tăng qua bốn nhóm giờ làm từ 6.9% lên 20.7%, 39.6% và 41.3%, với kích thước hiệu ứng Mann-Whitney CLES = 0.672 (rank-biserial = 0.344) và Spearman $\rho = 0.269$ ([0.259, 0.279]) (Hình 3.3).

Chênh lệch giữa nam và nữ thu hẹp khoảng 90% khi điều chỉnh đa biến nhưng không giảm khi chỉ tách theo giờ làm. Số liệu thô là 11.0% ở nữ so với 30.6% ở nam (chênh 19.6 điểm phần trăm, Cohen's h = 0.496), gần như biến mất trong nhóm đã kết hôn (45.5% so với 44.6%) nhưng vẫn rộng khi chỉ tách theo giờ làm (21.6% so với 44.1% ở nhóm 41-50 giờ, Hình 3.4). Trong mô hình logistic lồng nhau (M0–M3), hiệu ứng biên trung bình (AME, nữ trừ nam) thu hẹp từ -19.63 điểm phần trăm ([-20.57, -18.71]) xuống -4.58 ở M1, -1.92 ([-2.97, -0.84]) ở M2 và -2.03 điểm phần trăm ([-3.20, -0.98], OR = 0.823) ở M3 (Bảng 3.6A).

Thiếu dữ liệu nghề nghiệp không hoàn toàn ngẫu nhiên và kết quả vững trước các kiểm tra độ nhạy. workclass và occupation thiếu 5.64% và 5.66%, với tỷ lệ >50K khi thiếu chỉ là 10.4% so với 24.9% khi khai đủ và phụ thuộc có ý nghĩa vào thu nhập, giới tính, học vấn ($p < 0.001$, bác bỏ MCAR, Bảng 2.2). Kết quả phân tích cũng vững khi loại 159 dòng bị chặn trên tại capital_gain = 99,999 ($\rho = 0.257$ so với 0.278) và khi gia quyền theo trọng số fnlwgt (tỷ lệ toàn mẫu 23.87% so với 24.09%, độ lệch ở mọi nhóm con không quá 1.3 điểm phần trăm, Bảng 3.10A).

4.2. Đề xuất giải pháp ứng dụng

Các đề xuất dưới đây bám vào phát hiện ở mục 4.1. Vì mọi kết quả là liên hệ thống kê chứ không phải quan hệ nhân quả, mỗi đề xuất nên được hiểu là hướng ưu tiên để đánh giá thêm, không phải cam kết về hiệu quả. Không đề xuất nào dùng giới tính, quốc tịch hay tình trạng hôn nhân làm tiêu chí quyết định lương hoặc tuyển dụng.

Ý nghĩa thực tế của ngưỡng 50K. Ngưỡng này tính theo đô la năm 1994 nên không thể áp dụng nguyên trạng cho thị trường lao động hiện nay. Theo chỉ số giá tiêu dùng CPI-U của Cục Thống kê Lao động Mỹ (BLS), trung bình năm 1994 là 148.2 và tháng 9/2026 là 336.940, tức hệ số quy đổi khoảng 2.2735. Vì vậy 50,000 USD năm 1994 tương đương khoảng 113,677 USD theo mặt bằng giá tháng 9/2026, hay khoảng 113.7K USD [19], [20], [21]. Đây chỉ là phép quy đổi sức mua theo CPI, không phải mức lương hợp lý, mức sống hay thu nhập trung vị của người lao động hiện nay. Tại thời điểm hoàn thiện báo cáo (06/11/2026), tháng 9/2026 là tháng CPI mới nhất đã công bố, và CPI tháng 10/2026 được lên lịch công bố ngày 10/11/2026, nên cần kiểm tra lại nếu ngày hoàn thiện thay đổi.

Bảng 4.1. Đề xuất và phát hiện làm căn cứ

Đề xuất	Dựa trên phát hiện	Lưu ý
Mở rộng cơ hội tiếp cận và hoàn thành các bậc học từ mức 13 năm học trở lên, kèm hỗ trợ tài chính	Học vấn: 24.8% ở mức 12 lên 41.5% ở mức 13 (Hình 3.1)	Cần đánh giá riêng hiệu quả chương trình, vì học vấn còn đi cùng nhiều yếu tố khác
Đào tạo nghề và nâng kỹ năng cho nhóm 9 và 10 năm học	Hai mức này đông nhất (10,494 và 7,282 dòng) và có tỷ lệ 16.0% và 19.0% (Bảng 3.2)	Cần dữ liệu theo nghề để chọn đúng ngành đào tạo
Hỗ trợ việc làm đầu đời, thực tập và hướng nghiệp cho nhóm 17-24 và 25-34	Tỷ lệ 1.1% và 16.8%, thấp nhất trong các nhóm tuổi (Bảng 3.3)	Dữ liệu cắt ngang năm 1994, một phần là khác biệt giữa các thế hệ
Có chương trình việc làm linh hoạt và hỗ trợ thu nhập cho nhóm 65+	Tỷ lệ giảm còn 20.7% sau đỉnh 40.1% (Hình 3.2)	Mẫu 65+ chỉ có 1,335 dòng
Thiết kế biểu mẫu thu thập nghề nghiệp để phân biệt “chưa từng đi làm” với “không khai báo”	Thiếu workclass, occupation đi cùng tỷ lệ 10.4% (Bảng 2.2), 7 dòng Never-worked (Bảng 2.1)	Chỉ cải thiện chất lượng dữ liệu, chưa tác động trực tiếp lên thu nhập
Theo dõi chênh lệch nam nữ theo giờ làm bằng dữ liệu chi tiết hơn về nghề, vị trí, thâm niên trước khi kết luận	Chênh lệch còn khi chỉ tách theo giờ làm nhưng AME thu hẹp từ -19.63 xuống -2.03 điểm % sau khi điều chỉnh đa biến ở M3 (Bảng 3.6, Bảng 3.6A)	Bài không kết luận có hay không có phân biệt đối xử

4.3. Giới hạn của dữ liệu và phân tích

- **Thời điểm và phạm vi.** Dữ liệu năm 1994 và chỉ ở Mỹ, nên kết quả khó áp dụng trực tiếp cho giai đoạn hoặc quốc gia khác.
- **Ngưỡng nhị phân.** Ngưỡng 50K chia thu nhập thành hai nhãn, làm mất thông tin về mức thu nhập cụ thể. Hai nhãn cũng mất cân bằng, <=50K chiếm 75.92% và >50K chiếm 24.08%.
- **Giá trị bị chặn trên.** capital_gain bị chặn trên ở 99,999 với 159 dòng đều thuộc nhóm >50K. Mặc dù kiểm tra độ nhạy loại bỏ 159 dòng này cho thấy hệ số Spearman chỉ giảm nhẹ từ 0.278 xuống 0.257, dữ liệu vẫn không cho phép phân biệt mức lãi vốn thực tế bên trong nhóm bị chặn trên.
- **Nhóm ít quan sát.** Tỷ lệ ở các nhóm ít quan sát có khoảng tin cậy Wilson 95% rộng, đặc biệt là Married-AF-spouse chỉ có n = 23 dòng (43.5%, CI 95% [25.6%, 63.2%], n < 30) và mức 1 năm học có n = 50 dòng (0.0%, CI 95% [0.0%, 7.1%]).
- **Biến chồng lấn.** relationship, marital_status và sex chồng lấn nhau (V từ 0.462 đến 0.649), nên không thể đọc độ mạnh liên hệ của từng biến một cách độc lập.
- **Giới hạn của đặc tả mô hình đa biến.** Ở H4 và H5, báo cáo đã khắc phục việc tách từng biến đơn lẻ bằng các mô hình hồi quy logistic đa biến lồng nhau (M0–M3 và M1–M3) cùng kiểm định tương tác sex × is_married. Tuy nhiên, mô hình logistic vẫn dựa trên giả định cộng tính trên thang log-odds đối với các biến kiểm soát khác và chỉ điều chỉnh được các biến có mặt trong bộ dữ liệu.
- **Quyết định có chủ ý.** Việc bỏ 24 dòng trùng là một lựa chọn vì không có cột định danh để chứng minh đó là bản ghi lặp, và nhãn Unknown giả định rằng "không khai báo" là một nhóm có ý nghĩa riêng.
- **Thiết kế chọn mẫu và trọng số fnlwgt.** Phân tích độ nhạy mô tả bằng trọng số fnlwgt (Bảng 3.10A) cho thấy tỷ lệ >50K có gia quyền rất sát với tỷ lệ mẫu chưa gia quyền (chênh tối đa 1.3 điểm phần trăm). Tuy vậy, các mô hình hồi quy vẫn ước lượng không gia quyền vì bản trích xuất công khai trên UCI không cung cấp biến phân tầng (strata) và đơn vị lấy mẫu sơ cấp (PSU) của điều tra CPS để ước lượng phương sai theo thiết kế mẫu đầy đủ.
- **Dữ liệu cắt ngang.** Kết quả mô tả sự khác biệt giữa các nhóm tại một thời điểm, không theo dõi cùng một người theo thời gian.
- **Giới hạn lấy mẫu.** Bộ Adult chỉ gồm các bản ghi thỏa các điều kiện lọc của UCI về tuổi, thu nhập gộp điều chỉnh, trọng số và số giờ làm lớn hơn 0 [2]. File 32,561 dòng có thể chỉ là phần huấn luyện chứ không phải toàn bộ 48,842 quan sát, và sai lệch chọn mẫu có thể ảnh hưởng đến thành phần mẫu, đặc biệt là sự chênh lệch quy mô giữa nữ và nam trong nhóm đã kết hôn.

- **Giới hạn suy diễn thống kê.** Báo cáo đã áp dụng hiệu chỉnh đa kiểm định Holm ($\alpha = 0.05$) và báo cáo khoảng tin cậy 95% cùng kích thước hiệu ứng chuẩn hóa cho mọi giả thuyết. Tuy nhiên, việc hiệu chỉnh Holm không biến hai giả thuyết khám phá (H4, H5) thành kiểm định xác nhận đặt trước, và với mẫu lớn ($n = 32,537$), p-value rất nhỏ ngay cả khi hiệu ứng nhỏ nên việc diễn giải phải luôn bám sát khoảng tin cậy và cỡ hiệu ứng.
- **Biến gây nhiễu chưa quan sát được.** Các mô hình chỉ điều chỉnh những biến có trong dữ liệu, nên không loại trừ được các yếu tố quyết định thu nhập không được ghi nhận, và kết quả không cho phép suy diễn nhân quả.

Đạo đức dữ liệu. sex và race là các biến nhạy cảm về mặt xã hội. Bài chỉ dùng chúng để mô tả và kiểm tra các mối liên hệ thống kê. Kết quả không được dùng làm tiêu chí quyết định tuyển dụng, phân bổ lương hay đánh giá năng lực cá nhân, và sự khác biệt thống kê giữa các nhóm không được diễn giải thành kết luận về năng lực vốn có của một nhóm. Kết quả từ dữ liệu quan sát năm 1994 cũng không đủ căn cứ để đưa ra quyết định đối với một cá nhân hiện nay.

4.4. Hướng mở rộng trong tương lai

- Kết hợp tệp dữ liệu gốc của điều tra Current Population Survey (CPS) có đầy đủ thông tin phân tầng (strata), cụm lấy mẫu sơ cấp (PSU) và trọng số fnlwgt để ước lượng sai số chuẩn theo thiết kế chọn mẫu phức hợp.
- So sánh kết quả với dữ liệu điều tra hiện đại để xem các mối liên hệ có thay đổi không.
- Phân tích thu nhập theo nhóm nghề chi tiết hơn, đặc biệt với occupation.
- Mở rộng các mô hình đa biến ở H4 và H5 bằng kỹ thuật phân rã Oaxaca–Blinder hoặc mô hình phi tham số trên dữ liệu thu nhập liên tục (không bị cắt nhị phân tại ngưỡng 50K), có bổ sung biến thâm niên thực tế và khu vực địa lý.

Trong tương lai, dữ liệu đã làm sạch này cũng có thể làm đầu vào cho một mô hình dự đoán thu nhập.

KẾT LUẬN

Báo cáo phân tích bộ dữ liệu Adult Census Income gồm 32,561 quan sát và 15 thuộc tính nhằm xác định các yếu tố liên hệ với việc có thu nhập trên 50K USD/năm. Ở giai đoạn đánh giá và làm sạch, 4,262 ô thiếu mã hóa bằng "?" ở ba cột workclass, occupation, native_country được kiểm định cơ chế thiếu (bác bỏ giả định MCAR với $p < 0.001$) và gán nhãn Unknown; 24 dòng trùng lặp bị loại, giữ lại 32,537 quan sát sạch. Phép biến đổi log1p giúp giảm độ lệch của capital_gain từ 11.95 xuống 3.09 (nhưng ít thay đổi capital_loss), đồng thời các biến cờ nhị phân (has_cap_gain, has_cap_loss) và biến tuổi tâm hóa bậc hai (age_c, age_c2) được thiết lập để phục vụ mô hình hóa đa biến. Kiểm tra độ nhạy khi loại 159 dòng bị chặn trên tại capital_gain = 99,999 cho thấy tương quan hạng Spearman chỉ thay đổi nhẹ từ 0.278 xuống 0.257.

Sau khi hiệu chỉnh đa kiểm định Holm ở mức ý nghĩa $\alpha = 0.05$, toàn bộ năm giả thuyết (H1–H3 xác nhận, H4–H5 khám phá) đều bác bỏ H0 với p-Holm < 0.001. Kết quả ủng hộ H1, H2, H3 và H5 (trong đó H1 và H3 kèm điều kiện về đoạn chững), và ủng hộ một phần H4. Cụ thể: (1) tỷ lệ >50K tăng theo học vấn từ 16.0% (9 năm học) lên 74.1% (16 năm học) với Spearman $\rho = 0.330$ (CI 95% [0.320, 0.340]); (2) tuổi có quan hệ hình chuông đạt cực đại tại 50.4 tuổi trong hồi quy logistic bậc hai (LR $\chi^2 = 2{,}277.0$, $p < 0.001$, đỉnh mô tả 40.1% ở nhóm 45-54 tuổi); (3) số giờ làm việc đi cùng tỷ lệ thu nhập cao hơn (CLES = 0.672, Spearman $\rho = 0.269$) nhưng chững lại sau ngưỡng 41-50 giờ (39.6% so với 41.3% ở nhóm >50 giờ); (4) tình trạng hôn nhân có liên hệ độc lập rất mạnh với thu nhập, khi nhóm Married-civ-spouse vẫn duy trì OR = 9.755 (CI 95% [8.692, 10.948], LR $\chi^2 = 3{,}050.9$) so với Never-married sau khi đã điều chỉnh tuổi, giới tính, học vấn, giờ làm và lãi/lỗ vốn; (5) chênh lệch xác suất dự đoán giữa nữ và nam thu hẹp khoảng 90% qua các mô hình logistic lồng nhau (AME từ -19.63 điểm phần trăm ở M0 xuống -1.92 ở M2 và -2.03 điểm phần trăm, CI 95% [-3.20, -0.98], OR = 0.823 ở M3), nhưng không thu hẹp khi chỉ tách đơn biến theo giờ làm việc.

Phân tích độ nhạy theo trọng số lấy mẫu fnlwgt xác nhận tỷ lệ >50K có gia quyền (23.87% toàn mẫu) lệch không quá 1.3 điểm phần trăm ở mọi nhóm con so với tỷ lệ chưa gia quyền (24.09%). Giới hạn quan trọng nhất là dữ liệu cắt ngang năm 1994 tại Mỹ, biến mục tiêu bị nhị phân hóa tại ngưỡng 50K, sự chồng lấn cấu trúc giữa relationship, marital_status và sex (Cramér's V từ 0.462 đến 0.649), và khả năng tồn tại biến gây nhiễu chưa quan sát được. Vì vậy, mọi kết quả trong báo cáo cần được hiểu là mối liên hệ thống kê làm cơ sở định hướng nghiên cứu sâu hơn chứ không phải kết luận nhân quả.

TÀI LIỆU THAM KHẢO

[1] “Adult Census Income,” Kaggle, UCI Machine Learning. [Online]. Available: https://www.kaggle.com/datasets/uciml/adult-census-income (accessed Nov. 2, 2026).

[2] B. Becker and R. Kohavi, “Adult,” UCI Machine Learning Repository, 1996. [Online]. Available: https://archive.ics.uci.edu/dataset/2/adult (accessed Nov. 2, 2026).

[3] The pandas development team, “pandas documentation.” [Online]. Available: https://pandas.pydata.org/docs (accessed Nov. 2, 2026).

[4] M. L. Waskom, “seaborn: statistical data visualization,” J. Open Source Softw., vol. 6, no. 60, p. 3021, 2021.

[5] P. Virtanen et al., “SciPy 1.0: Fundamental algorithms for scientific computing in Python,” Nat. Methods, vol. 17, pp. 261-272, 2020.

[6] C. Spearman, “The proof and measurement of association between two things,” Am. J. Psychol., vol. 15, no. 1, pp. 72-101, 1904.

[7] H. Cramér, Mathematical Methods of Statistics. Princeton, NJ, USA: Princeton Univ. Press, 1946.

[8] H. B. Mann and D. R. Whitney, “On a test of whether one of two random variables is stochastically larger than the other,” Ann. Math. Statist., vol. 18, no. 1, pp. 50-60, 1947.

[9] J. Mincer, Schooling, Experience, and Earnings. New York, NY, USA: National Bureau of Economic Research, 1974.

[10] G. S. Becker, Human Capital: A Theoretical and Empirical Analysis, with Special Reference to Education, 3rd ed. Chicago, IL, USA: Univ. of Chicago Press, 1993.

[11] F. D. Blau and L. M. Kahn, “The gender wage gap: Extent, trends, and explanations,” J. Econ. Lit., vol. 55, no. 3, pp. 789-865, 2017, doi: 10.1257/jel.20160995.

[12] R. Kohavi, “Scaling up the accuracy of naive-Bayes classifiers: A decision-tree hybrid,” in Proc. 2nd Int. Conf. Knowl. Discovery Data Mining (KDD-96), 1996, pp. 202-207.

[13] S. Holm, “A simple sequentially rejective multiple test procedure,” Scand. J. Statist., vol. 6, no. 2, pp. 65-70, 1979.

[14] E. B. Wilson, “Probable inference, the law of succession, and statistical inference,” J. Amer. Statist. Assoc., vol. 22, no. 158, pp. 209-212, 1927.

[15] W. Bergsma, “A bias-correction for Cramér's V and Tschuprow's T,” J. Korean Statist. Soc., vol. 42, no. 3, pp. 323-328, 2013, doi: 10.1016/j.jkss.2012.10.002.

[16] S. Seabold and J. Perktold, “Statsmodels: Econometric and statistical modeling with Python,” in Proc. 9th Python Sci. Conf., 2010, pp. 57-61.

[17] J. Cohen, Statistical Power Analysis for the Behavioral Sciences, 2nd ed. Hillsdale, NJ, USA: Lawrence Erlbaum Associates, 1988.

[18] H. Chen, P. Cohen, and S. Chen, “How big is a big odds ratio? Interpreting the magnitudes of odds ratios in epidemiological studies,” Commun. Statist. Simul. Comput., vol. 39, no. 4, pp. 860-864, 2010, doi: 10.1080/03610911003650383.

[19] U.S. Bureau of Labor Statistics, “Consumer Price Index news release.” [Online]. Available: https://www.bls.gov/news.release/CPI.htm (accessed Nov. 6, 2026).

[20] U.S. Bureau of Labor Statistics, “CPI inflation calculator.” [Online]. Available: https://www.bls.gov/data/inflation_calculator.htm (accessed Nov. 6, 2026).

[21] U.S. Census Bureau, Statistical Abstract of the United States: 1995, 115th ed., table of prices. [Online]. Available: https://www2.census.gov/library/publications/1995/compendia/statab/115ed/tables/prices.pdf (accessed Nov. 6, 2026).

PHỤ LỤC

Phụ lục A. Mã nguồn

Mã nguồn: https://github.com/dladat/group19-dataset9-adult-census-income

Phụ lục B. Mô tả đầy đủ các thuộc tính

Bảng B.1. Kiểu và các giá trị của 15 thuộc tính

Thuộc tính	Kiểu	Giá trị
age	Số	Số nguyên từ 17 đến 90
workclass	Chữ	Private, Self-emp-not-inc, Local-gov, ?, State-gov, Self-emp-inc, Federal-gov, Without-pay, Never-worked
fnlwgt	Số	Số nguyên từ 12,285 đến 1,484,705
education	Chữ	HS-grad, Some-college, Bachelors, Masters, Assoc-voc, 11th, Assoc-acdm, 10th, 7th-8th, Prof-school, 9th, 12th, Doctorate, 5th-6th, 1st-4th, Preschool
education_num	Số	Số nguyên từ 1 đến 16
marital_status	Chữ	Married-civ-spouse, Never-married, Divorced, Separated, Widowed, Married-spouse-absent, Married-AF-spouse
occupation	Chữ	Prof-specialty, Craft-repair, Exec-managerial, Adm-clerical, Sales, Other-service, Machine-op-inspct, ?, Transport-moving, Handlers-cleaners, Farming-fishing, Tech-support, Protective-serv, Priv-house-serv, Armed-Forces
relationship	Chữ	Husband, Not-in-family, Own-child, Unmarried, Wife, Other-relative
race	Chữ	White, Black, Asian-Pac-Islander, Amer-Indian-Eskimo, Other
sex	Chữ	Male, Female
capital_gain	Số	Số nguyên từ 0 đến 99,999
capital_loss	Số	Số nguyên từ 0 đến 4,356
hours_per_week	Số	Số nguyên từ 1 đến 99
native_country	Chữ	United-States, Mexico, ?, Philippines, Germany, Canada, Puerto-Rico, El-Salvador, India, Cuba, England, Jamaica, South, China, Italy, Dominican-Republic, Vietnam, Guatemala, Japan, Poland, Columbia, Taiwan, Haiti, Iran, Portugal, Nicaragua, Peru, Greece, France, Ecuador, Ireland, Hong, Trinadad&Tobago, Cambodia, Laos, Thailand, Yugoslavia, Outlying-US(Guam-USVI-etc), Honduras, Hungary, Scotland, Holand-Netherlands *Các tên quốc gia như Columbia, Trinadad&Tobago, Holand-Netherlands, Hong, South được giữ nguyên theo chuỗi ký tự gốc trong file adult.csv.*
income	Chữ	<=50K, >50K

Danh sách giá trị tra từ adult.csv*, sắp xếp từ giá trị phổ biến nhất. Dấu "?" là mã của giá trị thiếu.*

Phụ lục C. Danh sách hình và tên tệp ảnh

Bảng C.1. Hình trong báo cáo và tệp ảnh tương ứng

Hình	Tệp ảnh	Nội dung
2.1	01_missing.png	Tỷ lệ thiếu sau khi đổi "?" thành NaN
2.2	02_boxplot_numeric.png	Boxplot sáu cột số
2.3	03_capital_gain_log.png	Phân phối capital_gain > 0 trước và sau log1p
3.1	04_h1_education.png	H1, tỷ lệ >50K (education_num) theo số năm học kèm CI Wilson 95%
3.2	05_h2_age.png	H2, tỷ lệ >50K theo nhóm tuổi kèm CI Wilson 95%
3.3	06_h3_hours.png	H3, tỷ lệ >50K theo số giờ làm mỗi tuần kèm CI Wilson 95%
3.4	07_h4_sex.png	H4, tỷ lệ >50K theo giới tính, tách theo hôn nhân và giờ làm kèm CI Wilson 95%
3.5	08_h5_marital.png	H5, tỷ lệ >50K theo tình trạng hôn nhân kèm CI Wilson 95%
3.6	09_cramers_v.png	Cramér's V hiệu chỉnh giữa các biến phân loại và income kèm CI bootstrap 95%
3.7	10_heatmap.png	Ma trận tương quan Spearman của các biến số