ĐẠI HỌC KINH TẾ QUỐC DÂN

VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO & POHE



BÁO CÁO KIỂM TRA GIỮA KÌ

Môn học: Khoa học dữ liệu trong kinh tế và kinh doanh

Chủ đề: Adult Census Income

GVHD: TS. Trần Đức Minh

Số nhóm: 19

Sinh viên :

11244071 - Đan Lê Anh Đạt

11244352 - Nguyễn Tuấn Minh

11247674 - Nguyễn Đại Lợi

11243146 - Nguyễn Bảo Thanh

11243260 - Nguyễn Đức Việt

Hà Nội 2026

MỤC LỤC

TÓM TẮT iii
DANH MỤC HÌNH 1
DANH MỤC BẢNG 2
CHƯƠNG 1. THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU 3
1.1. Giới thiệu bài toán và mục tiêu 3
1.1.1. Bối cảnh và câu hỏi nghiên cứu 3
1.1.2. Các giả thuyết 3
1.1.3. Phạm vi 3
1.2. Nguồn dữ liệu 4
1.3. Kiểm tra hiện trạng dữ liệu 5
1.3.1. Cấu trúc và kiểu dữ liệu 5
1.3.2. Giá trị thiếu 5
1.3.3. Phân phối của biến mục tiêu 6
1.3.4. Tính nhất quán giữa *education* và *education_num* 6
1.4. Tổng hợp vấn đề phát hiện 6
CHƯƠNG 2. TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU 8
2.1. Giá trị thiếu 8
2.1.1. Mức độ và cơ chế thiếu 8
2.1.2. Giải trình cách xử lý 9
2.1.3. Dùng median hay mean để điền giá trị thiếu 9
2.2. Dòng trùng lặp 10
2.3. Ngoại lệ 10
2.3.1. Phát hiện bằng IQR 10
2.3.2. *capital_gain* và *capital_loss* 11
2.3.3. *hours_per_week* và *age* 12
2.3.4. *fnlwgt* và *education_num* 12
2.4. Biến đổi và mã hóa 13
2.4.1. Vì sao chọn *log1p* thay vì chuẩn hóa thang đo 13
2.5. Tổng kết sau làm sạch 14
CHƯƠNG 3. PHÂN TÍCH VÀ TRỰC QUAN HÓA 16
3.1. Tổng quan 16
3.2. Kiểm định năm giả thuyết 16
3.2.1. H1: học vấn và thu nhập 16
3.2.2. H2: tuổi và thu nhập 17
3.2.3. H3: số giờ làm và thu nhập 18
3.2.4. H4: chênh lệch giữa nam và nữ 19

3.2.5. H5: tình trạng hôn nhân và thu nhập 21
3.3. So sánh độ mạnh liên hệ giữa các biến 23
3.4. Bảng tổng hợp kết quả kiểm định 25
CHƯƠNG 4. ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ 26
4.1. Các phát hiện nổi bật 26
4.2. Đề xuất giải pháp ứng dụng 26
4.3. Giới hạn của dữ liệu và phân tích 27
4.4. Hướng mở rộng trong tương lai 27
KẾT LUẬN 29
TÀI LIỆU THAM KHẢO 30
PHỤ LỤC 31
Phụ lục A. Mã nguồn 31
Phụ lục B. Mô tả đầy đủ các thuộc tính 31
Phụ lục C. Danh sách hình và tên tệp ảnh 32

TÓM TẮT

Báo cáo phân tích bộ dữ liệu Adult Census Income, trích từ điều tra dân số Mỹ năm 1994 [1], [2], gồm 32,561 quan sát và 15 thuộc tính. Câu hỏi chính là những yếu tố nào liên hệ với việc có thu nhập trên 50K.

Ở giai đoạn làm sạch, giá trị thiếu được mã hóa bằng "?" ở ba cột workclass, occupation, native_country và được gán nhãn Unknown. 24 dòng trùng bị loại, còn 32,537 dòng. Hai cột capital_gain và capital_loss lệch mạnh nên được biến đổi bằng log1p, và cách này chỉ có hiệu quả với capital_gain. Năm giả thuyết được kiểm định bằng Spearman, chi-square và Mann-Whitney.

Ba phát hiện nổi bật nhất. Thứ nhất, tỷ lệ thu nhập trên 50K tăng từ 16.0% ở nhóm 9 năm học lên 74.1% ở nhóm 16 năm học. Thứ hai, marital_status có Cramér's V là 0.447, chỉ sau relationship (0.454), và nhóm Married-civ-spouse đạt 44.7% so với 4.6% ở nhóm Never-married. Thứ ba, khoảng cách thô giữa nữ (11.0%) và nam (30.6%) gần như biến mất trong nhóm đã kết hôn (45.5% và 44.6%) nhưng vẫn còn khi tách theo giờ làm.

Giới hạn quan trọng nhất là dữ liệu chỉ phản ánh nước Mỹ năm 1994, và ngưỡng 50K nhị phân hóa làm mất thông tin về mức thu nhập. Kết quả chỉ mô tả mối liên hệ thống kê, không cho phép kết luận nhân quả.

DANH MỤC HÌNH

Hình 2.1. Tỷ lệ giá trị thiếu sau khi đổi "?" thành NaN 8
Hình 2.2. Boxplot của sáu cột số 11
Hình 2.3. Phân phối capital_gain > 0 trước và sau log1p 14
Hình 3.1. Tỷ lệ >50K theo số năm học (education_num) 17
Hình 3.2. Tỷ lệ >50K theo nhóm tuổi 18
Hình 3.3. Tỷ lệ >50K theo số giờ làm mỗi tuần 19
Hình 3.4. Tỷ lệ >50K theo giới tính, tách theo hôn nhân (trái) và giờ làm (phải) 20
Hình 3.5. Tỷ lệ >50K theo tình trạng hôn nhân 21
Hình 3.6. Cramér's V giữa các biến phân loại và income 23
Hình 3.7. Ma trận tương quan Spearman của các biến số 24

DANH MỤC BẢNG

Bảng 1.1. Năm giả thuyết và phương pháp kiểm định dự kiến 3
Bảng 1.2. Mô tả 15 thuộc tính của bộ dữ liệu 4
Bảng 1.3. Thống kê mô tả sáu cột số (dữ liệu gốc, n = 32,561) 5
Bảng 1.4. Giá trị thiếu mã hóa bằng "?" (n = 32,561) 5
Bảng 1.5. Phân phối của income (n = 32,561) 6
Bảng 1.6. Các vấn đề dữ liệu, mức độ và nơi xử lý 6
Bảng 2.1. Đối chiếu dòng thiếu của workclass và occupation (n = 32,561) 8
Bảng 2.2. Tỷ lệ >50K khi thiếu và khi đủ, tính riêng từng cột (n = 32,561) 9
Bảng 2.3. Ảnh hưởng của việc loại dòng trùng 10
Bảng 2.4. Ngoại lệ theo phương pháp IQR (n = 32,537) 10
Bảng 2.5. Quyết định xử lý ngoại lệ theo từng cột 12
Bảng 2.6. Các biến đổi và mã hóa 13
Bảng 2.7. Độ lệch trước và sau log1p 13
Bảng 2.8. Dữ liệu trước và sau làm sạch 14
Bảng 3.1. Mục tiêu và loại biểu đồ của từng hình 16
Bảng 3.2. Tỷ lệ >50K và số dòng theo số năm học 17
Bảng 3.3. Tỷ lệ >50K và số dòng theo nhóm tuổi 18
Bảng 3.4. Tỷ lệ >50K và số dòng theo nhóm giờ làm 19
Bảng 3.5. Tỷ lệ >50K theo hôn nhân và giới tính 20
Trong mẫu khảo sát, có tới 61.1 % nam giới (13.313 trên tổng số 21.775) nằm ở nhóm Đã kết hôn (nhóm có tỷ lệ thu nhập cao xấp xỉ 45 %), trong khi chỉ có 15.4 % nữ giới (1.657 trên tổng số 10.762) thuộc nhóm này (84.6 % nữ nằm ở nhóm Khác vốn có tỷ lệ rất thấp). Chính sự chênh lệch cấu trúc mẫu này (biến nhiễu tình trạng hôn nhân) đã kéo tỷ lệ trung bình thô của toàn bộ nam giới lên cao. 20
Bảng 3.6. Tỷ lệ >50K theo giờ làm và giới tính 20
Bảng 3.7. Tỷ lệ >50K, số dòng và tuổi trung vị theo tình trạng hôn nhân 21
Bảng 3.8. Tỷ lệ >50K theo nhóm tuổi và cờ is_married 22
Bảng 3.9. Cramér's V giữa biến phân loại và income 23
Bảng 3.10. Cramér's V giữa ba biến có thể chồng lấn 24
Bảng 3.11. Tổng hợp kết quả kiểm định năm giả thuyết 25
Bảng 4.1. Đề xuất và phát hiện làm căn cứ 26
Bảng B.1. Kiểu và các giá trị của 15 thuộc tính 31
Bảng C.1. Hình trong báo cáo và tệp ảnh tương ứng 32

CHƯƠNG 1. THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU

1.1. Giới thiệu bài toán và mục tiêu

1.1.1. Bối cảnh và câu hỏi nghiên cứu

Thu nhập của một người thường đi cùng nhiều đặc điểm nhân khẩu và việc làm như học vấn, độ tuổi, số giờ làm hay tình trạng hôn nhân. Bộ dữ liệu Adult Census Income ghi lại các đặc điểm này cho hơn 32 nghìn người trưởng thành ở Mỹ, kèm một nhãn cho biết thu nhập của họ có vượt 50K hay không [1]. Theo mô tả của bộ dữ liệu, ngưỡng 50K tính bằng đô la Mỹ mỗi năm.

Câu hỏi nghiên cứu của bài là: **những yếu tố nào liên hệ với việc có thu nhập trên 50K, và mối liên hệ đó mạnh đến đâu?** Bài có bốn mục tiêu cụ thể:

- Đánh giá chất lượng dữ liệu và ghi lại các vấn đề phát hiện được.
- Làm sạch dữ liệu, mỗi quyết định đều có bằng chứng và lý do.
- Kiểm định năm giả thuyết và so sánh độ mạnh liên hệ của các biến với thu nhập.
- Rút ra phát hiện chính, đề xuất ứng dụng và chỉ rõ giới hạn của kết quả.

1.1.2. Các giả thuyết

Năm giả thuyết dưới đây được đặt ra trước khi xem kết quả kiểm định. Bốn giả thuyết đầu xuất phát từ những đặc điểm có thể liên hệ với thu nhập. H4 và H5 được thiết kế để kiểm tra xem một mối liên hệ thô có còn nguyên vẹn sau khi tách theo biến thứ ba hay không.

Bảng 1.1. Năm giả thuyết và phương pháp kiểm định dự kiến

Mã	Phát biểu	Biến chính	Phương pháp
H1	Học vấn càng cao thì tỷ lệ thu nhập trên 50K càng cao.	education_num	Spearman, tỷ lệ theo số năm học
H2	Tỷ lệ thu nhập cao tăng theo tuổi rồi giảm ở nhóm lớn tuổi.	age_group	Chi-square, Cramér's V
H3	Người làm nhiều giờ hơn có tỷ lệ thu nhập cao hơn.	hours_per_week	Mann-Whitney, Spearman, tỷ lệ theo nhóm giờ làm
H4	Chênh lệch tỷ lệ thu nhập cao giữa nam và nữ giảm đáng kể khi kiểm soát theo tình trạng hôn nhân hoặc số giờ làm việc.	sex, marital_status, hours_group	Chi-square, Cramér's V, tách theo biến thứ ba
H5	Tình trạng hôn nhân liên hệ mạnh với thu nhập, và tuổi không giải thích hết mối liên hệ đó.	marital_status, age_group	Tỷ lệ theo nhóm, tách theo nhóm tuổi

1.1.3. Phạm vi

Bài làm trọn trong bốn giai đoạn mà đề yêu cầu: đánh giá dữ liệu, làm sạch, phân tích và trực quan hóa, đánh giá tác động và khuyến nghị. Phân tích dừng ở mô tả và kiểm định mối liên hệ

thống kê. Các cụm như "đi cùng" hay "liên hệ với" được dùng xuyên suốt vì dữ liệu quan sát không cho phép kết luận nhân quả. Mọi số liệu lấy từ notebook đi kèm, và các hình được lưu trong thư mục figures.

1.2. Nguồn dữ liệu

Dữ liệu được lấy từ trang Kaggle của UCI tại địa chỉ https://www.kaggle.com/datasets/uciml/adult-census-income [1]. Nguồn gốc là kho UCI Machine Learning Repository, trích từ cơ sở dữ liệu điều tra dân số Mỹ năm 1994 [2]. Notebook tải dữ liệu bằng kagglehub và đọc file adult.csv có sẵn trong máy nếu việc tải bị lỗi.

Bộ dữ liệu chỉ có một file là adult.csv, gồm 32,561 dòng và 15 cột, trong đó 6 cột là số nguyên và 9 cột là chữ (Bảng 1.2). Notebook dùng assert để chặn lại ngay nếu nạp nhầm file có kích thước khác. Mỗi dòng mô tả một người theo tài liệu của dataset, và file không có cột định danh. Tên cột gốc có dấu chấm, chẳng hạn education.num, nên được đổi thành dấu gạch dưới để truy cập thuộc tính bằng mã thuận tiện hơn.

Vì chỉ có một file, không tồn tại khóa chính hay khóa ngoại để gộp bảng. Bước kiểm tra nhất quán giữa các file mà đề nêu vì vậy không áp dụng, và được thay bằng kiểm tra nhất quán nội tại giữa education và education_num ở mục 1.3.4.

Bảng 1.2. Mô tả 15 thuộc tính của bộ dữ liệu

Thuộc tính	Kiểu	Ý nghĩa theo tài liệu UCI	Số giá trị khác nhau
age	Số	Tuổi của người được điều tra	73
workclass	Chữ	Loại hình người sử dụng lao động, ví dụ Private, Self-emp-not-inc, Never-worked	9
fnlwgt	Số	Trọng số lấy mẫu của điều tra (final weight)	21,648
education	Chữ	Trình độ học vấn cao nhất	16
education_num	Số	Trình độ học vấn dưới dạng số	16
marital_status	Chữ	Tình trạng hôn nhân	7
occupation	Chữ	Nhóm nghề nghiệp	15
relationship	Chữ	Vai trò trong hộ gia đình, ví dụ Husband, Wife, Own-child	6
race	Chữ	Chủng tộc	5
sex	Chữ	Giới tính	2
capital_gain	Số	Lãi từ vốn	119
capital_loss	Số	Lỗ từ vốn	92
hours_per_week	Số	Số giờ làm việc mỗi tuần	94
native_country	Chữ	Quốc gia xuất thân	42
income	Chữ	Nhãn thu nhập: <=50K hoặc >50K	2

Số giá trị khác nhau lấy từ output của df_raw.nunique(). *Ba cột* workclass, occupation, native_country *đã tính "?" là một giá trị.*

1.3. Kiểm tra hiện trạng dữ liệu

1.3.1. Cấu trúc và kiểu dữ liệu

Lệnh df.info() cho thấy 32,561 dòng, 15 cột, không ô nào trống theo cách đếm mặc định của pandas. Sáu cột số là age, fnlwgt, education_num, capital_gain, capital_loss, hours_per_week. Chín cột còn lại là chữ. Bảng 1.3 cho thống kê mô tả của sáu cột số trên dữ liệu gốc.

Bảng 1.3. Thống kê mô tả sáu cột số (dữ liệu gốc, n = 32,561)

Cột	Mean	Std	Min	25%	50%	75%	Max
age	38.58	13.64	17	28	37	48	90
fnlwgt	189,778.37	105,549.98	12,285	117,827	178,356	237,051	1,484,705
education_num	10.08	2.57	1	9	10	12	16
capital_gain	1,077.65	7,385.29	0	0	0	0	99,999
capital_loss	87.30	402.96	0	0	0	0	4,356
hours_per_week	40.44	12.35	1	40	40	45	99

Bảng thống kê trả lời câu hỏi: cột số nào có hình dạng bất thường cần xem kỹ hơn. Ba cột nổi lên. capital_gain có trung bình 1,077.65 trong khi trung vị bằng 0 và giá trị lớn nhất là 99,999. capital_loss có tứ phân vị thứ ba vẫn bằng 0 nhưng giá trị lớn nhất là 4,356. hours_per_week có tứ phân vị thứ nhất và trung vị cùng bằng 40, tứ phân vị thứ ba là 45, nên khoảng giữa rất hẹp so với khoảng từ 1 đến 99 giờ. Cả ba dấu hiệu này báo trước các vấn đề về ngoại lệ và độ lệch sẽ được xử lý ở mục 2.3 và 2.4. Bảng này chỉ gợi ý, chưa đủ để kết luận, và nó được tính trước khi loại dòng trùng.

1.3.2. Giá trị thiếu

Notebook đếm số ô NaN thật và nhận được 0. Con số này dễ khiến người đọc nghĩ dữ liệu đầy đủ, nhưng bộ dữ liệu mã hóa giá trị thiếu bằng chuỗi "?" nên isna() mặc định không nhận ra. Khi đếm riêng chuỗi này trên chín cột chữ, ba cột xuất hiện giá trị thiếu (Bảng 1.4). Sáu cột số có kiểu int64 và không chứa chuỗi nên không thể có "?".

Bảng 1.4. Giá trị thiếu mã hóa bằng "?" (n = 32,561)

Cột	Số dòng thiếu	Tỷ lệ (%)
workclass	1,836	5.64
occupation	1,843	5.66
native_country	583	1.79

workclass và occupation thiếu gần bằng nhau, 5.64% và 5.66%, trong khi native_country thấp hơn nhiều với 1.79%. Điều đáng chú ý là hai cột đầu chênh nhau đúng 7 dòng, gợi ý hai cột thiếu ở cùng các dòng, trừ một số rất ít. Điều này được kiểm chứng ở mục 2.1. Ý nghĩa thực tế là nếu bỏ qua bước đếm "?" thì cả ba cột sẽ bị coi là sạch và các nhóm thiếu sẽ bị gộp ngầm

vào phân tích. Tính chung, 4,262 ô thiếu nằm t rên 2,399 dòng (Bảng 2.8). Bảng này chỉ cho biết có bao nhiêu dòng thiếu, chưa nói được vì sao thiếu.

1.3.3. Phân phối của biến mục tiêu

Bảng 1.5. Phân phối của income (n = 32,561)

Nhãn	Số dòng	Tỷ lệ (%)
<=50K	24,720	75.92
>50K	7,841	24.08

Câu hỏi ở đây là hai nhãn có cân bằng hay không. Nhãn <=50K chiếm 24,720 dòng, tức 75.92%, còn >50K chỉ có 7,841 dòng, tức 24.08% (Bảng 1.5). Nói cách khác, khoảng ba trên bốn người trong mẫu nằm ở mức thu nhập thấp hơn ngưỡng. Hệ quả cho các chương sau là mọi tỷ lệ theo nhóm chỉ có ý nghĩa khi đặt cạnh mức nền chung. Vì vậy, Chương 3 luôn báo cáo tỷ lệ kèm số dòng của nhóm, và lấy mức nền 24.09% của mẫu sau làm sạch làm mốc tham chiếu.

1.3.4. Tính nhất quán giữa *education* và *education_num*

Do không có nhiều file để đối chiếu khóa, bài kiểm tra tính nhất quán nội tại giữa hai cột cùng mô tả học vấn. Notebook nhóm theo education rồi đếm số mã education_num khác nhau, sau đó làm ngược lại. Cả hai chiều đều cho kết quả tối đa là 1, trên toàn bộ 32,561 dòng. Hai cột vì vậy ánh xạ một một với nhau: mỗi trình độ chữ ứng với đúng một mã số và mỗi mã số ứng với đúng một trình độ chữ. Phát hiện này có nghĩa là hai cột mang cùng một thông tin, và việc giữ cả hai trong một phép phân tích sẽ lặp lại thông tin đó. Quyết định dùng education_num được giải trình ở mục 2.4. Giới hạn của phép kiểm tra là nó chỉ chứng minh hai cột khớp nhau, chứ không chứng minh giá trị ghi nhận đúng với trình độ thực tế của từng người.

1.4. Tổng hợp vấn đề phát hiện

Bảng 1.6 gom các vấn đề đã nhận diện và chỉ ra chương xử lý. Hai vấn đề về dòng trùng và ngoại lệ chỉ được xác nhận bằng phép tính ở Chương 2, còn ở giai đoạn này chúng mới được gợi ý qua Bảng 1.3. Mức độ được đánh giá theo ảnh hưởng của vấn đề lên phân tích phía sau.

Bảng 1.6. Các vấn đề dữ liệu, mức độ và nơi xử lý

Vấn đề	Bằng chứng	Mức độ	Xử lý tại
Giá trị thiếu mã hóa bằng "?"	Ba cột thiếu 5.64%, 5.66%, 1.79%, trong khi isna() báo 0 (Bảng 1.4)	Cao	Mục 2.1
Hai cột workclass và occupation thiếu cùng dòng	Chênh nhau chỉ 7 dòng (Bảng 1.4)	Trung bình	Mục 2.1
Biến mục tiêu mất cân bằng	>50K chiếm 24.08% (Bảng 1.5)	Trung bình	Chương 3, báo cáo tỷ lệ kèm n
Dòng trùng lặp	Chưa kiểm tra ở giai đoạn này	Thấp	Mục 2.2

Vấn đề	Bằng chứng	Mức độ	Xử lý tại
Ngoại lệ và lệch của capital_gain, capital_loss, hours_per_week	Mean khác xa median, Q1 = Q3 = 0 (Bảng 1.3)	Cao	Mục 2.3 và 2.4
education và education_num trùng thông tin	Ánh xạ một một hai chiều (mục 1.3.4)	Thấp	Mục 2.4
native_country có nhiều nhóm rất nhỏ	Mỹ chiếm khoảng 90% mẫu, các nước còn lại mỗi nước rất ít dòng	Thấp	Mục 2.4
fnlwgt là trọng số lấy mẫu, không phải đặc điểm của người	Mô tả của UCI (Bảng 1.2)	Thấp	Mục 2.3, không dùng trong phân tích
Tên cột chứa dấu chấm	Ví dụ education.num	Thấp	Đổi tên ngay khi nạp dữ liệu

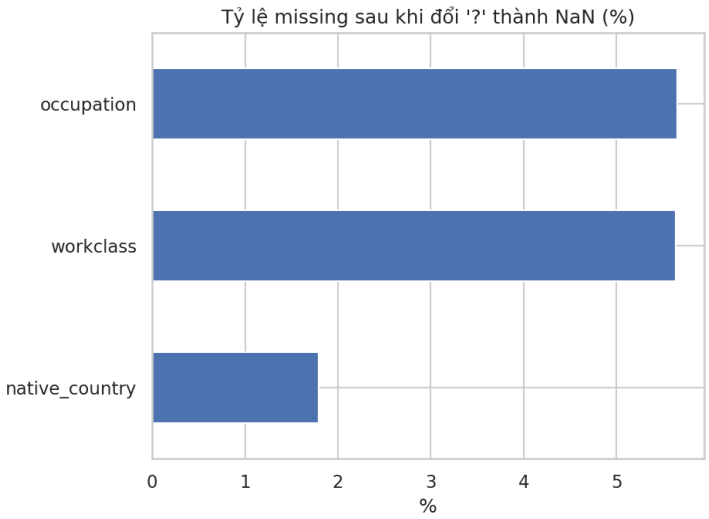
CHƯƠNG 2. TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU

Chương này xử lý lần lượt bốn việc: giá trị thiếu, dòng trùng, ngoại lệ, rồi biến đổi và mã hóa. Thứ tự này trùng với thứ tự trong notebook. Vì dòng trùng chỉ bị loại ở bước thứ hai, các bảng về giá trị thiếu tính trên 32,561 dòng, còn bảng IQR, độ lệch và toàn bộ Chương 3 tính trên 32,537 dòng. Mỗi quyết định được trình bày theo trình tự vấn đề, bằng chứng, giải pháp, lý do và phương án đã loại.

2.1. Giá trị thiếu

2.1.1. Mức độ và cơ chế thiếu

Câu hỏi cần trả lời là giá trị thiếu rải ngẫu nhiên hay đi theo một quy luật nào đó, vì câu trả lời quyết định cách điền. Sau khi đổi chuỗi "?" thành NaN bằng pandas [3], Hình 2.1 cho thấy ba cột bị ảnh hưởng.



Hình 2.1. Tỷ lệ giá trị thiếu sau khi đổi "?" thành NaN

occupation thiếu 5.66%, workclass thiếu 5.64% và native_country thiếu 1.79%. Hai thanh đầu dài gần bằng nhau, còn thanh thứ ba chỉ bằng khoảng một phần ba. Bảng 2.1 kiểm tra xem hai cột đầu có thiếu cùng các dòng hay không.

Bảng 2.1. Đối chiếu dòng thiếu của workclass và occupation (n = 32,561)

	occupation đủ	occupation thiếu
workclass đủ	30,718	7
workclass thiếu	0	1,836

Có 1,836 dòng thiếu đồng thời cả hai cột và không có dòng nào thiếu workclass mà đủ occupation. Bảy dòng còn lại chỉ thiếu occupation và cả bảy đều có workclass là Never-worked. Kết quả này phù hợp với việc một người chưa từng đi làm không có nghề để khai báo, nên bảy dòng này có vẻ là thiếu có lý do chứ không phải sót ghi.

Bảng 2.2. Tỷ lệ >50K khi thiếu và khi đủ, tính riêng từng cột (n = 32,561)

Cột	Số dòng thiếu	Tỷ lệ >50K khi thiếu (%)	Tỷ lệ >50K khi đủ (%)
workclass	1,836	10.4	24.9
occupation	1,843	10.4	24.9
native_country	583	25.0	24.1

Bảng 2.2 cho thấy hai cột đầu hành xử khác native_country. Khi workclass hoặc occupation thiếu, tỷ lệ >50K chỉ là 10.4%, thấp rõ rệt so với 24.9% ở nhóm khai đủ. Với native_country, hai con số gần như trùng nhau, 25.0% và 24.1%. Nếu gộp ba cột thành một cờ "có thiếu" thì sự khác biệt này bị che mất, vì vậy notebook xét từng cột riêng. Bằng chứng này chỉ là gián tiếp. Việc tỷ lệ thu nhập khác nhau cho biết thiếu dữ liệu đi cùng thu nhập thấp hơn, nhưng không nói được lý do người ta bỏ trống.

Về mặt bản chất cơ chế thiếu dữ liệu, 7 dòng Never-worked thiếu occupation thuộc dạng thiếu có cấu trúc (Structural missingness). Đối với 1.836 dòng thiếu đồng thời cả workclass và occupation có tỷ lệ thu nhập trên 50K thấp hơn hẳn (10.4 phần trăm so với 24.9 phần trăm), chứng tỏ cơ chế thiếu không phải hoàn toàn ngẫu nhiên (không phải dạng MCAR, mà thuộc nhóm MAR hoặc MNAR). Do đó, việc gán nhãn Unknown thay vì xóa dòng hay điền bằng Mode ở mục 2.1.2 là hoàn toàn có cơ sở khoa học để giữ lại thông tin.

2.1.2. Giải trình cách xử lý

Vấn đề. Ba cột chứa giá trị thiếu mã hóa bằng "?" cần được xử lý trước khi phân tích.

Bằng chứng. Bảng 2.1 và Bảng 2.2: thiếu ở workclass và occupation trùng gần như hoàn toàn và đi cùng tỷ lệ >50K khác hẳn, còn native_country thì không.

Giải pháp. Đổi "?" thành NaN, rồi điền nhãn Unknown cho cả ba cột. Sau bước này notebook xác nhận còn 0 giá trị thiếu.

Lý do. Cả ba cột đều là biến phân loại nên một nhãn riêng là cách điền tự nhiên. Với workclass và occupation, nhãn Unknown giữ lại thông tin "không khai báo", vốn đi cùng một tỷ lệ thu nhập khác hẳn. Cách này cũng giữ nguyên số dòng. native_country được làm cùng cách cho nhất quán dù mức khác biệt nhỏ.

Phương án đã loại. Điền giá trị phổ biến nhất (mode) sẽ gán một nghề phổ biến cho những người không khai báo, và xóa mất tín hiệu 10.4% ở trên. Xóa các dòng thiếu sẽ bỏ đi 2,399 dòng có ít nhất một ô thiếu (Bảng 2.8), trong đó nhóm thiếu workclass và occupation có tỷ lệ >50K thấp hơn phần còn lại, nên mẫu giữ lại sẽ lệch về phía thu nhập cao.

2.1.3. Dùng median hay mean để điền giá trị thiếu

Sáu cột số đều có đủ 32,561 giá trị (Bảng 1.3) nên không cần điền. Nếu buộc phải chọn, median phù hợp hơn mean với các cột lệch, và capital_gain là ví dụ rõ nhất. Trên dữ liệu gốc, trung bình của cột này là 1,077.65 trong khi trung vị bằng 0. Trung bình bị kéo lên bởi một nhóm nhỏ có lãi vốn lớn, trong đó có giá trị 99,999. Điền bằng mean sẽ gán cho người thiếu một

khoản lãi vốn mà phần lớn mẫu không có, còn median là 0 mô tả đúng người điển hình. Với các cột chữ, bài dùng nhãn Unknown như đã nêu ở mục 2.1.2.

2.2. Dòng trùng lặp

Vấn đề. Một số dòng có thể bị lặp và làm đếm hai lần cùng một người.

Bằng chứng. Notebook đánh dấu 24 dòng trùng khi giữ bản đầu, và 47 dòng thuộc các nhóm trùng. Các ví dụ đầu tiên là những cặp dòng giống hệt nhau ở tất cả các cột, chẳng hạn hai người 19 tuổi cùng fnlwgt 97,261, cùng HS-grad, Never-married, Farming-fishing. Không nhóm trùng nào có nhãn income mâu thuẫn nhau (0 nhóm).

Giải pháp. Loại 24 dòng trùng, giữ bản đầu tiên, đưa dữ liệu từ 32,561 xuống 32,537 dòng.

Lý do. Số dòng bị loại rất ít và nhãn nhất quán, nên việc loại không tạo mâu thuẫn. Bảng 2.3 cho thấy tỷ lệ >50K chỉ đổi từ 24.081% sang 24.093%, tức ảnh hưởng không đáng kể.

Bảng 2.3. Ảnh hưởng của việc loại dòng trùng

Chỉ tiêu	Trước	Sau
Số dòng	32,561	32,537
Tỷ lệ >50K (%)	24.081	24.093

Cần nói thẳng một hạn chế: dữ liệu không có cột định danh, nên bài không chứng minh được chắc chắn rằng 24 dòng này là bản ghi lặp. Hai người khác nhau vẫn có thể trùng toàn bộ các thuộc tính. Cột fnlwgt có tới 21,648 giá trị khác nhau (Bảng 1.2) nên trùng khớp cả cột này cùng các cột còn lại ít có khả năng chỉ do ngẫu nhiên, nhưng đó là suy luận chứ không phải bằng chứng. Quyết định loại vì vậy là một lựa chọn có chủ ý, được cân nhắc dựa trên quy mô nhỏ và tác động không đáng kể.

Phương án đã loại. Giữ nguyên các dòng trùng cũng cho kết quả gần như không đổi, nhưng sẽ đếm lặp nếu chúng thật sự là một bản ghi. Loại cả 47 dòng thuộc nhóm trùng thì mất luôn các bản gốc, và cũng không có lý do để làm vậy.

2.3. Ngoại lệ

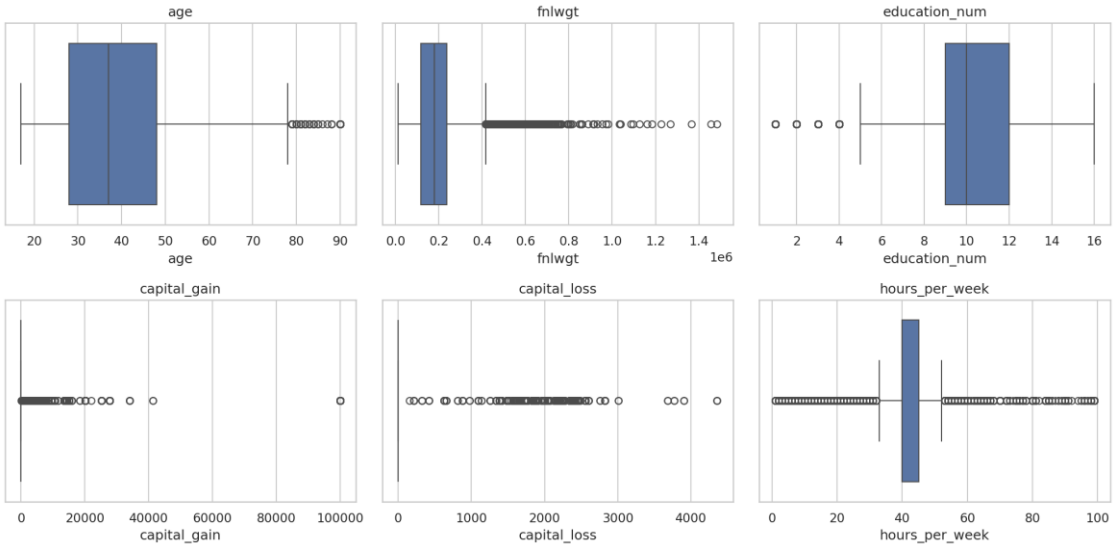
2.3.1. Phát hiện bằng IQR

Câu hỏi là cột số nào có nhiều giá trị ngoài khoảng thông thường, và phương pháp IQR có đáng tin ở từng cột hay không. IQR (khoảng tứ phân vị) là hiệu giữa tứ phân vị thứ ba và thứ nhất. Một giá trị bị gắn là ngoại lệ nếu nằm dưới Q1 trừ 1.5 lần IQR hoặc trên Q3 cộng 1.5 lần IQR. Bảng 2.4 là kết quả trên 32,537 dòng, và Hình 2.2 là boxplot vẽ bằng seaborn [4].

Bảng 2.4. Ngoại lệ theo phương pháp IQR (n = 32,537)

Cột	Q1	Q3	Cận dưới	Cận trên	Số ngoại lệ	Tỷ lệ (%)
age	28	48	-2	78	142	0.44
fnlwgt	117,827	236,993	-60,922	415,742	993	3.05
education_num	9	12	4.5	16.5	1,193	3.67

Cột	Q1	Q3	Cận dưới	Cận trên	Số ngoại lệ	Tỷ lệ (%)
capital_gain	0	0	0	0	2,712	8.34
capital_loss	0	0	0	0	1,519	4.67
hours_per_week	40	45	32.5	52.5	9,002	27.67



Hình 2.2. Boxplot của sáu cột số

Theo tỷ lệ, hours_per_week dẫn đầu với 9,002 ngoại lệ (27.67%), tiếp theo là capital_gain (8.34%), capital_loss (4.67%), education_num (3.67%), fnlwgt (3.05%) và age (0.44%). Hình 2.2 cho thấy hình dạng của từng cột. Hai cột capital_gain và capital_loss có hộp dẹt tại 0 và một dải chấm kéo dài sang phải, với điểm xa nhất ở 99,999 và 4,356. hours_per_week có hộp hẹp từ 40 đến 45 giờ, râu từ khoảng 33 đến 52 và chấm ở cả hai phía. age có chấm ở phía trên 78 tuổi, còn education_num có chấm ở các mức 1 đến 4. Điểm đáng chú ý là tỷ lệ ngoại lệ cao không đồng nghĩa với dữ liệu lỗi. Con số 27.67% của hours_per_week và các con số của hai cột capital_* đến từ hình dạng phân phối chứ không phải từ sai sót nhập liệu. Vì vậy mỗi cột cần được xem riêng trước khi quyết định, và các mục dưới đây làm việc đó.

2.3.2. *capital_gain* và *capital_loss*

Hơn 90% giá trị của cả hai cột là 0, nên Q1 và Q3 đều bằng 0, IQR bằng 0 và mọi giá trị khác 0 tự động bị gắn là ngoại lệ. Con số 2,712 và 1,519 ở Bảng 2.4 vì thế chỉ bằng số dòng khác 0 và không cho thêm thông tin nào. Notebook mô tả hai cột bằng tỷ lệ khác 0 và đuôi phân phối. capital_gain khác 0 ở 8.34% số dòng (n = 2,712), trung vị của nhóm khác 0 là 7,298 và giá trị lớn nhất là 99,999. capital_loss khác 0 ở 4.67% số dòng (n = 1,519), trung vị của nhóm khác 0 là 1,887 và giá trị lớn nhất là 4,356. Không dòng nào có đồng thời gain và loss lớn hơn 0.

Giá trị 99,999 đáng chú ý nhất. Nó xuất hiện 159 lần và cả 159 dòng đều có nhãn >50K. Dù là giá trị lớn nhất của cột, nó đứng thứ năm về tần suất, sau 0, 15,024 (347 lần), 7,688 (284 lần) và 7,298 (246 lần). Một mức cao nhất mà lặp lại nhiều như vậy giống một giá trị bị chặn trên hơn là một số đo thật, nghĩa là các khoản lãi vốn lớn hơn có thể đã bị gộp vào cùng một con số.

Quyết định. Giữ nguyên các dòng, không xóa và không cắt đuôi, và biến đổi bằng log1p ở mục 2.4. **Lý do.** Nhóm 99,999 đồng nhất với nhãn >50K, nên xóa đi là mất đúng tín hiệu mạnh nhất của cột. **Phương án đã loại.** Xóa theo IQR sẽ loại toàn bộ người có lãi vốn, và cắt đuôi (winsorize) vô nghĩa vì phần đuôi chính là phần có thông tin. Giới hạn của lựa chọn này là phân tích không thể phân biệt các mức lãi vốn thật nằm bên trong nhóm 99,999.

2.3.3. *hours_per_week* và *age*

Gần một nửa số dòng, chính xác là 46.7%, làm đúng 40 giờ mỗi tuần. Khoảng từ Q1 đến Q3 vì vậy chỉ rộng 5 giờ, cận trên 52.5 và cận dưới 32.5, và IQR gắn ngoại lệ cho 9,002 dòng dù phần lớn không phải lỗi. Ở đầu cực trị, có 341 dòng làm từ 80 giờ trở lên, trong đó 85 dòng đúng 99 giờ. Tỷ lệ >50K của nhóm từ 80 giờ trở lên là 35.2%, cao hơn mức nền 24.1%. **Quyết định.** Giữ nguyên và gộp thành nhóm giờ làm ở mục 2.4. **Lý do.** Các giá trị này khả dĩ về mặt thực tế và nhóm cực trị mang thông tin, vì nó có tỷ lệ thu nhập cao khác với phần còn lại.

Với age, tuổi nhỏ nhất là 17 và lớn nhất là 90. Có 142 ngoại lệ phía trên 78 tuổi, gồm 120 dòng từ 80 tuổi trở lên và 42 dòng đúng 90 tuổi. Tỷ lệ >50K của nhóm từ 80 tuổi trở lên là 13.3%, thấp hơn mức nền 24.1%. **Quyết định.** Giữ nguyên và đưa vào nhóm 65+ của age_group. **Lý do.** Đây là các độ tuổi hợp lệ của người trưởng thành, và nhóm này không hành xử như lỗi mà đơn giản là có thu nhập thấp hơn.

2.3.4. *fnlwgt* và *education_num*

fnlwgt là trọng số lấy mẫu của điều tra chứ không phải đặc điểm của người được hỏi. Nó có 993 ngoại lệ (3.05%), giá trị lớn nhất là 1,484,705. Notebook chỉ dùng IQR ở đây để báo cáo, và các bước sau không dùng cột này. Điều đó có nghĩa là các tỷ lệ trong Chương 3 là tỷ lệ trong mẫu, chưa được gia quyền về dân số, và đây là một giới hạn được nêu lại ở mục 4.3. Với education_num, 1,193 ngoại lệ chính là bốn mức 1 đến 4 nằm dưới cận 4.5. Bốn mức này có 50, 166, 332 và 645 dòng (Bảng 3.2), cộng lại đúng 1,193, và đều là trình độ hợp lệ nên được giữ nguyên.

Bảng 2.5. Quyết định xử lý ngoại lệ theo từng cột

Cột	Quyết định	Lý do
age	Giữ, chia nhóm	Độ tuổi hợp lệ, nhóm từ 80 tuổi có tỷ lệ >50K 13.3%
fnlwgt	Không dùng	Là trọng số lấy mẫu, không phải đặc điểm của người
education_num	Giữ	Các mức 1 đến 4 là trình độ hợp lệ
capital_gain	Giữ, biến đổi log1p	Q1 = Q3 = 0 nên IQR vô nghĩa, 159 dòng 99,999 đều là >50K
capital_loss	Giữ, biến đổi log1p	Q1 = Q3 = 0 nên IQR vô nghĩa, chỉ 4.67% khác 0
hours_per_week	Giữ, chia nhóm	46.7% dồn ở 40 giờ nên IQR gắn ngoại lệ quá nhiều, nhóm từ 80 giờ có tỷ lệ >50K 35.2%

2.4. Biến đổi và mã hóa

Bảng 2.6 liệt kê các biến đổi được thực hiện và lý do chọn. Các cột mới được thêm vào chứ không thay thế cột gốc, nên dữ liệu sau xử lý có 22 cột.

Bảng 2.6. Các biến đổi và mã hóa

Cột	Kỹ thuật	Lý do
income	Mã hóa nhị phân thành income_bin (1 nếu >50K)	Tính tỷ lệ >50K bằng trung bình và dùng được cho Spearman
education, education_num	Dùng education_num cho H1 và Spearman	Ánh xạ một một (mục 1.3.4), có thứ tự, 16 mức. Cột chữ education vẫn dùng cho Cramér's V
age	Chia 6 nhóm age_group: 17-24, 25-34, 35-44, 45-54, 55-64, 65+	Để thấy đường cong tăng rồi giảm của H2. Khoảng đầu bắt đầu từ 16 vì tuổi nhỏ nhất là 17
hours_per_week	Chia 4 nhóm hours_group: <=34, 35-40, 41-50, >50	Mốc 40 giờ được tách riêng vì phổ biến nhất (46.7%)
native_country	Gộp 3 nhóm native_group: US, Non-US, Unknown	Mỹ chiếm khoảng 90% mẫu, các nước khác mỗi nước rất ít dòng
marital_status	Cờ is_married: Married-civ-spouse là "Đã kết hôn", còn lại là "Khác"	Để tách theo hôn nhân ở H4 và H5
capital_gain, capital_loss	log1p thành log_cap_gain, log_cap_loss	Hai cột lệch mạnh và có rất nhiều giá trị 0

Sau khi gộp, native_group có 29,153 dòng US, 2,802 dòng Non-US và 582 dòng Unknown. Cần nhớ rằng nhóm "Khác" của is_married còn chứa cả Married-spouse-absent và Married-AF-spouse, vì cờ này chỉ lấy riêng Married-civ-spouse.

2.4.1. Vì sao chọn *log1p* thay vì chuẩn hóa thang đo

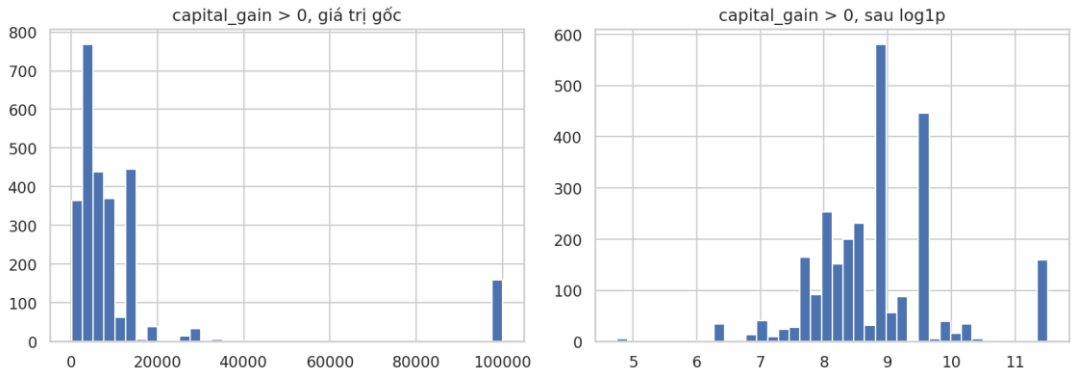
Vấn đề. capital_gain và capital_loss lệch rất mạnh. **Bằng chứng.** Độ lệch (skewness) của capital_gain là 11.95 và của capital_loss là 4.59 (Bảng 2.7). **Giải pháp.** Áp dụng log1p, tức logarit của 1 cộng giá trị. **Lý do.** Phải dùng log1p thay vì log thường vì cả hai cột có rất nhiều giá trị 0, và logarit của 0 không xác định. Bài này không huấn luyện mô hình, các phân tích dùng tỷ lệ theo nhóm và tương quan hạng, nên điều cần sửa ở hai cột là độ lệch chứ không phải chênh lệch thang đo giữa các cột. **Phương án đã loại.** StandardScaler và MinMaxScaler chỉ thay đổi thang đo mà giữ nguyên hình dạng phân phối, nên không làm giảm độ lệch. MinMaxScaler còn bị giá trị 99,999 quyết định toàn bộ khoảng chia. Với Spearman, phép tính dựa trên thứ hạng nên dùng cột gốc hay cột log cho cùng kết quả, vì vậy log1p chủ yếu phục vụ việc quan sát và mô tả phân phối.

Bảng 2.7. Độ lệch trước và sau log1p

Phạm vi	Trước	Sau log1p
capital_gain (toàn cột)	11.95	3.09

Phạm vi	Trước	Sau log1p
capital_loss (toàn cột)	4.59	4.31
capital_gain > 0	3.41	0.56

Hình 2.3 trả lời câu hỏi log1p có làm gọn phân phối của capital_gain hay không, và vẽ riêng nhóm lãi vốn dương vì 29,825 dòng bằng 0 sẽ che hết phần còn lại.



Hình 2.3. Phân phối capital_gain > 0 trước và sau log1p

Ở nhóm lãi vốn dương, độ lệch giảm từ 3.41 xuống 0.56, và hình bên phải trải đều hơn hẳn so với hình bên trái, vốn dồn vào vùng dưới 20,000 với một cột lẻ loi ở 99,999. Cột lẻ loi đó là 159 dòng và vẫn hiện ở khoảng 11.5 sau biến đổi. Với toàn cột, độ lệch giảm từ 11.95 xuống 3.09 nhưng vẫn còn cao, vì khối 29,825 giá trị 0 vẫn tồn tại. Điểm bất ngờ nằm ở capital_loss: độ lệch gần như không đổi, 4.59 xuống 4.31. Lý do là cột này chỉ có 4.67% giá trị khác 0, nên độ lệch chủ yếu đến từ khối số 0 chứ không từ phần đuôi, và log1p không xử lý được khối số 0. Bài học là log1p có hiệu quả với capital_gain và gần như vô tác dụng với capital_loss. Cột log_cap_loss vẫn được giữ vì Spearman không phụ thuộc vào phép biến đổi, nhưng không nên coi nó là đã được chuẩn hóa. Hình bên phải cũng còn nhiều cột nhọn, vì lãi vốn lặp lại ở một số mức cố định.

2.5. Tổng kết sau làm sạch

Bảng 2.8 so sánh dữ liệu trước và sau làm sạch, lấy từ output của notebook.

Bảng 2.8. Dữ liệu trước và sau làm sạch

Chỉ tiêu	Trước	Sau
Số dòng	32,561	32,537
Số cột	15	22
Số ô thiếu (mã hóa bằng "?")	4,262	0
Số dòng có ít nhất một ô thiếu	2,399	0
Số dòng bị đánh dấu trùng	24	0
Tỷ lệ >50K (%)	24.081	24.093

Chỉ 24 dòng bị loại, toàn bộ vì trùng. Không dòng nào bị xóa vì thiếu, mà 4,262 ô thiếu rải trên 2,399 dòng được giữ lại bằng nhãn Unknown. Bảy cột mới là income_bin, age_group,

hours_group, log_cap_gain, log_cap_loss, native_group và is_married. Tỷ lệ >50K gần như không đổi nên các bước làm sạch không làm lệch biến mục tiêu.

CHƯƠNG 3. PHÂN TÍCH VÀ TRỰC QUAN HÓA

3.1. Tổng quan

Mọi phân tích trong chương này tính trên 32,537 dòng sau làm sạch, và tỷ lệ thu nhập trên 50K của toàn mẫu là 24.09%. Con số này là mức nền để so sánh với tỷ lệ của từng nhóm. Các phép kiểm định dùng thư viện SciPy [5]. Vì mẫu lớn nên mọi giá trị p đều rất nhỏ, notebook in ra là < 1e-300, và vì vậy kết luận dựa chủ yếu vào độ lớn của hiệu ứng (hệ số Spearman, Cramér's V) và vào tỷ lệ theo nhóm kèm số dòng, không dựa vào giá trị p.

Bảng 3.1. Mục tiêu và loại biểu đồ của từng hình

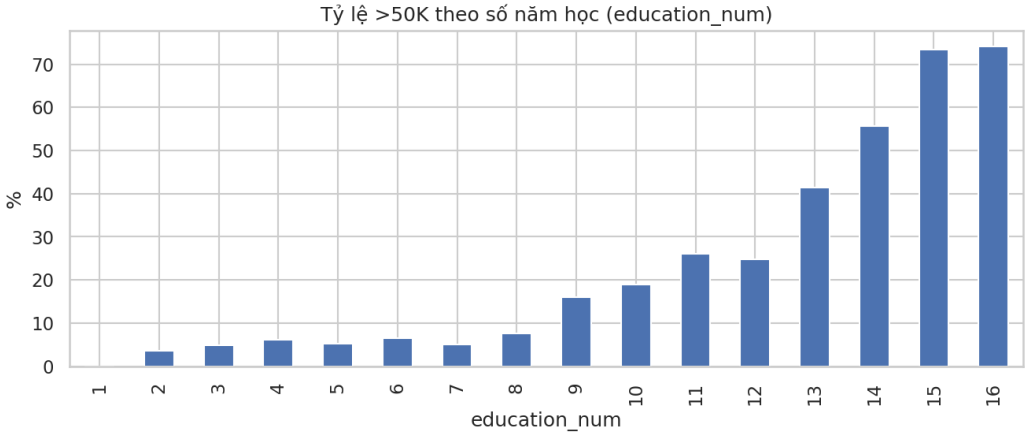
Hình	Loại biểu đồ	Câu hỏi phân tích
3.1	Cột, tỷ lệ theo số năm học	H1: tỷ lệ >50K có tăng theo học vấn không
3.2	Đường, tỷ lệ theo nhóm tuổi	H2: tỷ lệ có tăng rồi giảm theo tuổi không
3.3	Cột, tỷ lệ theo nhóm giờ làm	H3: làm nhiều giờ hơn có tỷ lệ cao hơn không
3.4	Cột nhóm, giới tính theo hôn nhân và giờ làm	H4: chênh lệch nam nữ còn lại gì sau khi tách
3.5	Cột ngang, tỷ lệ theo tình trạng hôn nhân	H5: hôn nhân liên hệ với thu nhập mạnh đến đâu
3.6	Cột ngang, Cramér's V	Biến phân loại nào liên hệ mạnh nhất với thu nhập
3.7	Heatmap Spearman	Các biến số liên hệ với nhau và với thu nhập ra sao

3.2. Kiểm định năm giả thuyết

3.2.1. H1: học vấn và thu nhập

Giả thuyết: học vấn càng cao thì tỷ lệ thu nhập trên 50K càng cao. **Phương pháp:** education_num là biến thứ bậc còn income_bin là nhị phân, nên bài dùng hệ số tương quan hạng Spearman [6], không đòi hỏi phân phối chuẩn. Bài đồng thời tính tỷ lệ >50K ở từng mức học vấn để xem hình dạng của mối liên hệ.

Câu hỏi của Hình 3.1 là tỷ lệ >50K thay đổi thế nào khi số năm học tăng.



Hình 3.1. Tỷ lệ >50K theo số năm học (education_num)

Bảng 3.2. Tỷ lệ >50K và số dòng theo số năm học

Năm học	Tỷ lệ (%)	n	Năm học	Tỷ lệ (%)	n
1	0.0	50	9	16.0	10,494
2	3.6	166	10	19.0	7,282
3	4.8	332	11	26.1	1,382
4	6.2	645	12	24.8	1,067
5	5.3	514	13	41.5	5,353
6	6.6	933	14	55.7	1,722
7	5.1	1,175	15	73.4	576
8	7.6	433	16	74.1	413

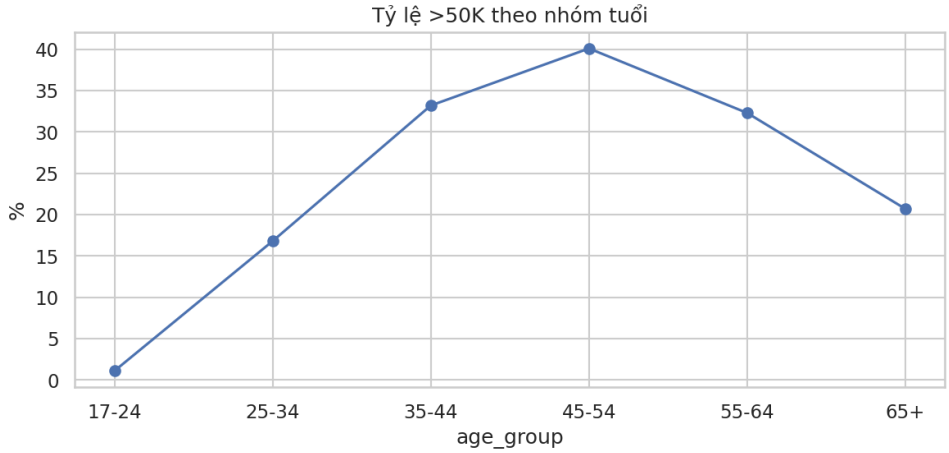
Hệ số Spearman giữa education_num và income_bin là 0.330 ($p < 1e\text{-}300$). Tỷ lệ >50K ở các mức từ 1 đến 8 năm học dao động thấp, từ 0.0% đến 7.6%. Từ mức 9 trở đi tỷ lệ leo dần: 16.0% ở mức 9, 19.0% ở mức 10, 41.5% ở mức 13, 55.7% ở mức 14, rồi 73.4% ở mức 15 và 74.1% ở mức 16. Bước nhảy lớn nhất nằm giữa mức 12 (24.8%) và mức 13 (41.5%). Có hai chỗ không tuân theo xu hướng tăng đều: mức 11 (26.1%) nhỉnh hơn mức 12 (24.8%), và hai mức cao nhất gần như bằng nhau (73.4% và 74.1%), tức mối liên hệ có dấu hiệu bão hòa. Ba mức đầu chỉ có 50, 166 và 332 dòng nên tỷ lệ ở đó kém ổn định.

Kết luận: chấp nhận, kèm điều kiện. Học vấn cao đi cùng tỷ lệ thu nhập cao, nhưng xu hướng không đơn điệu tuyệt đối ở mức 11 và 12, và các nhóm 1 đến 3 năm học quá nhỏ để diễn giải. Hệ số 0.330 ở mức trung bình thấp, nghĩa là học vấn chỉ liên hệ với một phần sự khác biệt về thu nhập. Đây là liên hệ thống kê, không cho biết học thêm có làm thu nhập tăng hay không.

3.2.2. H2: tuổi và thu nhập

Giả thuyết: tỷ lệ thu nhập cao tăng theo tuổi rồi giảm ở nhóm lớn tuổi. **Phương pháp:** giả thuyết nói về đường cong có đỉnh, nên Spearman (đo xu hướng một chiều) không phù hợp. Bài dùng kiểm định chi-square giữa age_group và income_bin, kèm Cramér's V [7] để đo độ mạnh, và vẽ đường để xem hình dạng.

Hình 3.2 hỏi tỷ lệ >50K đạt đỉnh ở nhóm tuổi nào và giảm bao nhiêu sau đỉnh.



Hình 3.2. Tỷ lệ >50K theo nhóm tuổi

Bảng 3.3. Tỷ lệ >50K và số dòng theo nhóm tuổi

Nhóm tuổi	Tỷ lệ (%)	n
17-24	1.1	5,562
25-34	16.8	8,473
35-44	33.2	8,146
45-54	40.1	5,849
55-64	32.3	3,172
65+	20.7	1,335

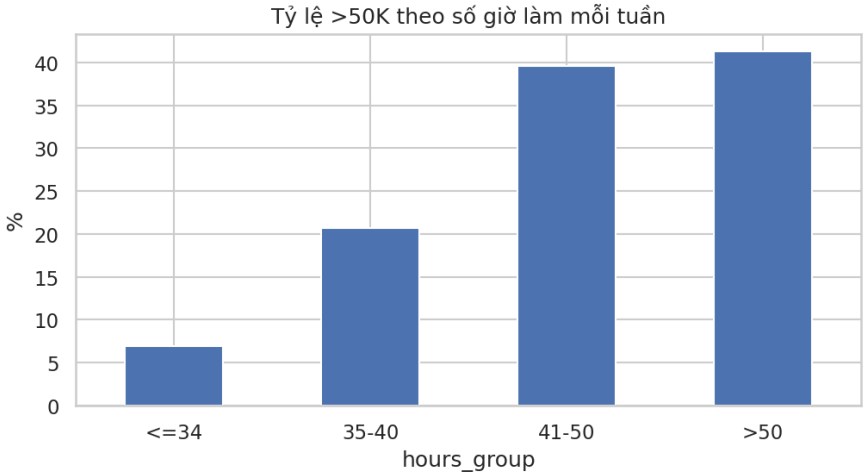
Kiểm định cho chi2 = 3,168.5 và Cramér's V = 0.312 ($p < 1e\text{-}300$). Tỷ lệ tăng từ 1.1% ở nhóm 17-24, qua 16.8% ở 25-34 và 33.2% ở 35-44, đạt đỉnh 40.1% ở nhóm 45-54, rồi giảm xuống 32.3% ở 55-64 và 20.7% ở 65+. Điểm đáng chú ý là nhóm 65+ vẫn cao hơn nhóm 25-34 (20.7% so với 16.8%), tức phía lớn tuổi của đường cong không rơi về mức của người trẻ. Nhóm 17-24 gần như không có người trên 50K dù có tới 5,562 dòng.

Kết luận: chấp nhận. Đường cong có hình chuông với đỉnh ở nhóm 45-54, và V = 0.312 là mức liên hệ trung bình. Hạn chế là dữ liệu cắt ngang năm 1994, nên đây là so sánh giữa các nhóm tuổi khác nhau chứ không theo dõi một người qua thời gian, và sự giảm ở nhóm lớn tuổi có thể phản ánh khác biệt giữa các thế hệ hoặc việc ai còn đi làm.

3.2.3. H3: số giờ làm và thu nhập

Giả thuyết: người làm nhiều giờ hơn có tỷ lệ thu nhập cao hơn. **Phương pháp:** hours_per_week dồn mạnh ở 40 giờ nên không thể giả định phân phối chuẩn, vì vậy bài dùng kiểm định Mann-Whitney [8] để so sánh giờ làm giữa hai nhóm thu nhập. Bài dùng thêm tỷ lệ >50K theo bốn nhóm giờ làm.

Câu hỏi của Hình 3.3 là tỷ lệ >50K có tăng đều theo số giờ làm hay chỉ tăng đến một mốc nào đó.



Hình 3.3. Tỷ lệ >50K theo số giờ làm mỗi tuần

Bảng 3.4. Tỷ lệ >50K và số dòng theo nhóm giờ làm

Nhóm giờ làm	Tỷ lệ (%)	n
<=34	6.9	5,578
35-40	20.7	17,383
41-50	39.6	5,934
>50	41.3	3,642

Tỷ lệ tăng từ 6.9% ở nhóm từ 34 giờ trở xuống, lên 20.7% ở nhóm 35-40, rồi 39.6% ở nhóm 41-50, nhưng chỉ nhích lên 41.3% ở nhóm trên 50 giờ. Kiểm định Mann-Whitney cho giá trị p rất nhỏ ($p < 1e\text{-}300$), đi cùng hệ số tương quan hạng Spearman giữa hours_per_week và income_bin là rho = 0.27 (Hình 3.7), phản ánh mức độ liên hệ thuận chiều ở ngưỡng trung bình yếu. Trung vị giờ làm của cả hai nhóm thu nhập đều bằng 40, trong khi trung bình khác nhau: 45.47 giờ ở nhóm >50K và 38.84 giờ ở nhóm <=50K. Vì trung vị bằng nhau, sự khác biệt nằm ở phần đuôi chứ không ở mức giờ làm điển hình.

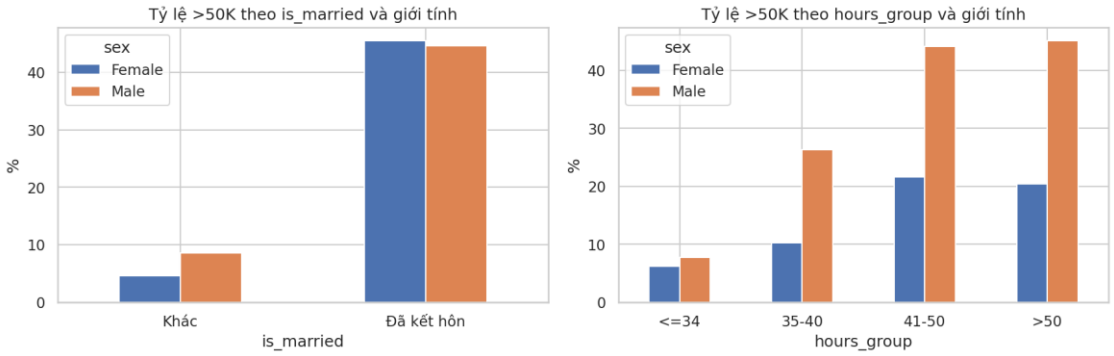
Kết luận: chấp nhận, kèm điều kiện. Mối liên hệ rõ đến nhóm 41-50 giờ rồi gần như phẳng ở nhóm trên 50 giờ, nên không thể nói "càng nhiều giờ càng cao" cho toàn dải. Các mốc của nhóm giờ làm do bài tự chọn, và số giờ làm còn đi cùng loại công việc và độ tuổi, nên không thể tách riêng tác dụng của giờ làm.

3.2.4. H4: chênh lệch giữa nam và nữ

Giả thuyết: Chênh lệch tỷ lệ thu nhập cao giữa nam và nữ giảm đáng kể khi kiểm soát theo tình trạng hôn nhân hoặc số giờ làm việc.

Phương pháp: bài đo chênh lệch thô bằng chi-square và Cramér's V, sau đó tách mẫu theo biến thứ ba và so tỷ lệ >50K của nam và nữ ngay trong từng nhóm, kèm số dòng. Bài tách riêng từng biến một, nên đây là so sánh trong nhóm chứ không phải kiểm soát đồng thời nhiều yếu tố.

Số liệu thô. Tỷ lệ >50K của nữ là 11.0% (n = 10,762) và của nam là 30.6% (n = 21,775), với Cramér's V = 0.216 (p < 1e-300). Chênh lệch thô rất lớn. Câu hỏi của Hình 3.4 là con số này còn lại bao nhiêu khi so nam và nữ trong cùng nhóm hôn nhân và cùng nhóm giờ làm.



Hình 3.4. Tỷ lệ >50K theo giới tính, tách theo hôn nhân (trái) và giờ làm (phải)

Bảng 3.5. Tỷ lệ >50K theo hôn nhân và giới tính

Nhóm hôn nhân	Giới tính	Tỷ lệ (%)	n
Đã kết hôn	Nữ	45.5	1,657
Đã kết hôn	Nam	44.6	13,313
Khác	Nữ	4.7	9,105
Khác	Nam	8.6	8,462

Trong mẫu khảo sát, có tới 61.1 % nam giới (13.313 trên tổng số 21.775) nằm ở nhóm Đã kết hôn (nhóm có tỷ lệ thu nhập cao xấp xỉ 45 %), trong khi chỉ có 15.4 % nữ giới (1.657 trên tổng số 10.762) thuộc nhóm này (84.6 % nữ nằm ở nhóm Khác vốn có tỷ lệ rất thấp). Chính sự chênh lệch cấu trúc mẫu này (biến nhiễu tình trạng hôn nhân) đã kéo tỷ lệ trung bình thô của toàn bộ nam giới lên cao.

Bảng 3.6. Tỷ lệ >50K theo giờ làm và giới tính

Nhóm giờ làm	Nữ (%)	Nam (%)
<=34	6.2	7.7
35-40	10.3	26.3
41-50	21.6	44.1
>50	20.4	45.1

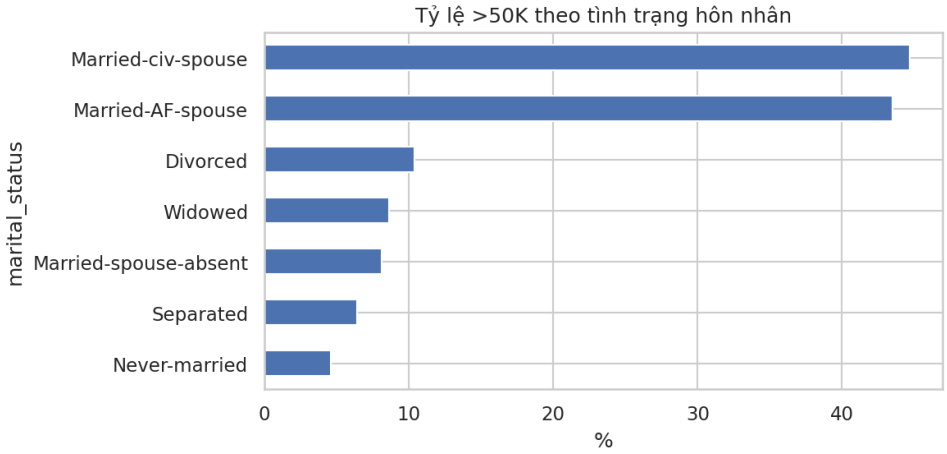
Hai cách tách cho hai bức tranh khác nhau. Trong nhóm đã kết hôn, chênh lệch gần như biến mất: nữ đạt 45.5% và nam đạt 44.6%, nữ thậm chí nhỉnh hơn một chút. Trong nhóm còn lại, nam vẫn cao hơn, 8.6% so với 4.7%, nhưng cả hai đều thấp. Khi tách theo giờ làm, chênh lệch vẫn còn và lớn dần: 6.2% so với 7.7% ở nhóm từ 34 giờ trở xuống, 10.3% so với 26.3% ở nhóm 35-40, 21.6% so với 44.1% ở nhóm 41-50 và 20.4% so với 45.1% ở nhóm trên 50 giờ. Điểm đáng chú ý là quy mô: nhóm nữ đã kết hôn chỉ có 1,657 người so với 13,313 nam, và điều này gợi ý một phần chênh lệch thô gắn với việc nữ chủ yếu nằm ở nhóm "Khác", nơi tỷ lệ thấp với cả hai giới.

Kết luận: chấp nhận, có điều kiện. Chênh lệch thô là lớn, nhưng gần như không còn trong nhóm đã kết hôn, trong khi vẫn còn khi tách theo giờ làm. Hai cách tách chưa được kết hợp đồng thời, nên bài không nói được chênh lệch còn lại bao nhiêu sau khi cùng lúc cân nhắc cả hôn nhân và giờ làm. Nhóm nữ đã kết hôn nhỏ nên kết quả ở đó kém chắc. Đây là liên hệ thống kê, và bài không kết luận có hay không có phân biệt đối xử. sex còn chồng lấn với marital_status và relationship (mục 3.3), nên các số liệu này cần đọc cùng nhau.

3.2.5. H5: tình trạng hôn nhân và thu nhập

Giả thuyết: tình trạng hôn nhân liên hệ mạnh với thu nhập, và tuổi không giải thích hết mối liên hệ đó. **Phương pháp:** bài so tỷ lệ >50K giữa bảy nhóm hôn nhân, đo độ mạnh bằng Cramér's V ở mục 3.3, rồi kiểm tra vai trò của tuổi bằng hai cách: xem tuổi trung vị của từng nhóm và so "đã kết hôn" với "khác" ngay trong từng nhóm tuổi.

Câu hỏi của Hình 3.5 là nhóm hôn nhân nào có tỷ lệ cao và khoảng cách giữa các nhóm lớn đến mức nào.



Hình 3.5. Tỷ lệ >50K theo tình trạng hôn nhân

Trong mẫu khảo sát, **61.1% nam giới** (13,313 / 21,775) nằm ở nhóm Đã kết hôn (nhóm có tỷ lệ thu nhập cao ~45%), trong khi chỉ có **15.4% nữ giới** (1,657 / 10,762) nằm ở nhóm này (84.6% nữ nằm ở nhóm Khác vốn có tỷ lệ rất thấp). Chính sự chênh lệch cấu trúc mẫu này (biến nhiễu is_married) đã kéo tỷ lệ trung bình thô của toàn bộ nam giới lên cao.

Bảng 3.7. Tỷ lệ >50K, số dòng và tuổi trung vị theo tình trạng hôn nhân

Tình trạng hôn nhân	Tỷ lệ (%)	n	Tuổi trung vị
Never-married	4.6	10,667	25
Separated	6.4	1,025	38
Married-spouse-absent	8.1	418	40
Widowed	8.6	993	60
Divorced	10.4	4,441	42
Married-AF-spouse	43.5	23	30
Married-civ-spouse	44.7	14,970	42

Bảy nhóm tách thành hai cụm rõ rệt. Hai nhóm có vợ hoặc chồng đi cùng là Married-civ-spouse (44.7%) và Married-AF-spouse (43.5%) cao hơn hẳn năm nhóm còn lại, vốn nằm trong khoảng từ 4.6% đến 10.4%. Về tuổi, nhóm Never-married có tuổi trung vị chỉ 25, thấp nhất, nên tuổi trẻ chắc chắn giải thích được một phần tỷ lệ 4.6%. Nhưng tuổi không giải thích hết. Divorced và Married-civ-spouse có cùng tuổi trung vị 42 mà tỷ lệ là 10.4% và 44.7%, còn Widowed có tuổi trung vị cao nhất, 60, vẫn chỉ đạt 8.6%.

Bảng 3.8. Tỷ lệ >50K theo nhóm tuổi và cờ is_married

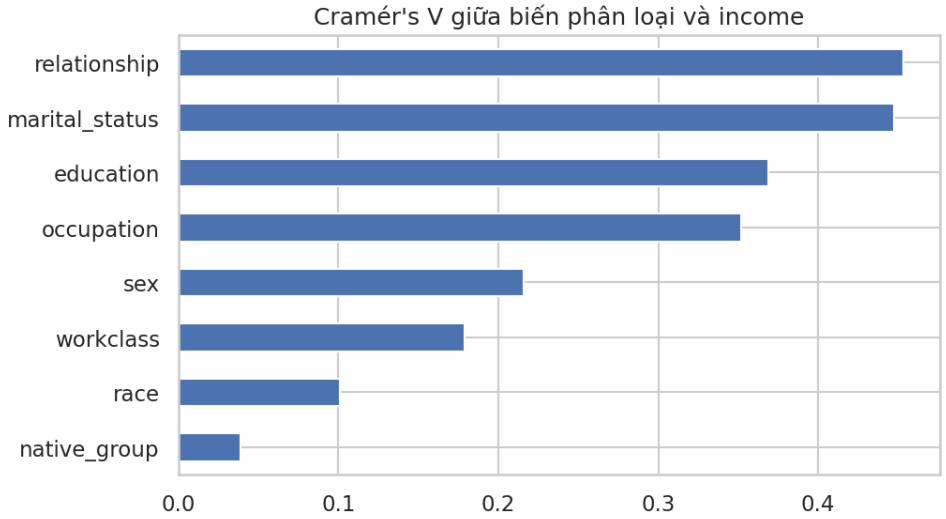
Nhóm tuổi	Khác (%)	Đã kết hôn (%)
17-24	0.5	7.0
25-34	5.0	33.6
35-44	10.7	50.3
45-54	14.4	56.0
55-64	11.3	44.5
65+	7.2	31.3

Bảng 3.8 kiểm tra trực tiếp vai trò của tuổi. Trong mọi nhóm tuổi, người đã kết hôn đều có tỷ lệ cao hơn rõ rệt, chẳng hạn 50.3% so với 10.7% ở nhóm 35-44 và 56.0% so với 14.4% ở nhóm 45-54. Khoảng cách này vẫn còn cả ở nhóm 17-24, tuy ở mức thấp hơn nhiều (7.0% so với 0.5%).

Kết luận: chấp nhận. Hôn nhân liên hệ mạnh với thu nhập, và tuổi chỉ giải thích một phần chứ không hết, vì chênh lệch vẫn còn trong từng nhóm tuổi. Cần thận trọng ở ba điểm. Married-AF-spouse chỉ có 23 dòng nên 43.5% kém ổn định. Cờ is_married chỉ lấy Married-civ-spouse. Và bài chưa tách thêm theo học vấn hay giờ làm, nên không loại trừ được các yếu tố khác cũng đi cùng hôn nhân.

3.3. So sánh độ mạnh liên hệ giữa các biến

Hình 3.6 hỏi biến phân loại nào liên hệ mạnh nhất với thu nhập khi đo bằng cùng một thước đo là Cramér's V.



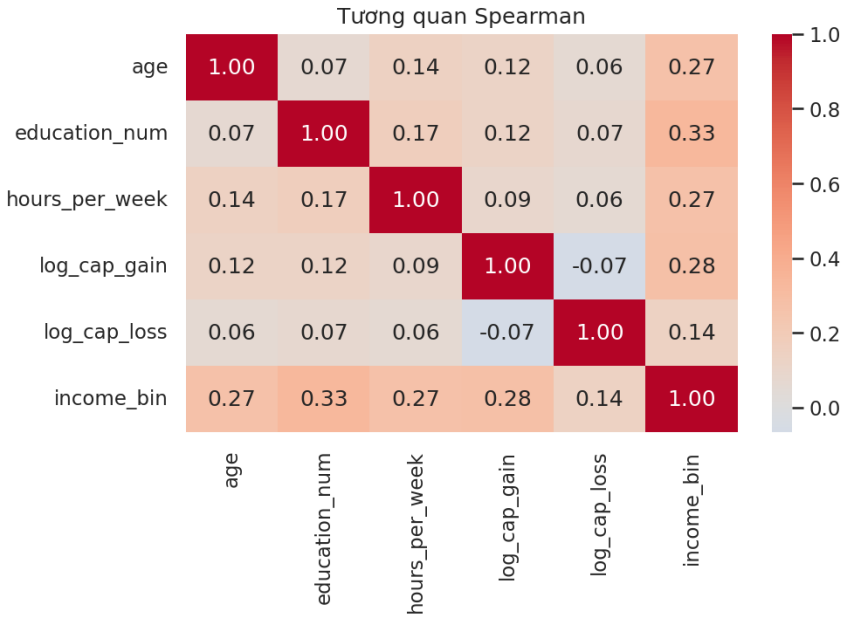
Hình 3.6. Cramér's V giữa các biến phân loại và income

Bảng 3.9. Cramér's V giữa biến phân loại và income

Biến	Cramér's V	Thứ hạng
relationship	0.454	1
marital_status	0.447	2
education	0.369	3
occupation	0.352	4
sex	0.216	5
workclass	0.179	6
race	0.101	7
native_group	0.039	8

Hai biến đầu, relationship (0.454) và marital_status (0.447), nổi hẳn lên so với education (0.369) và occupation (0.352). Cuối bảng là race (0.101) và native_group (0.039), gần như không liên hệ với thu nhập. Nhóm giữa gồm sex (0.216) và workclass (0.179). Điểm đáng chú ý là hai biến đứng đầu cùng mô tả vị trí của một người trong gia đình, chứ không phải trình độ hay nghề nghiệp.

Hình 3.7 cho thấy bức tranh tương ứng của các biến số, đo bằng Spearman.



Hình 3.7. Ma trận tương quan Spearman của các biến số

Với income_bin, education_num có hệ số cao nhất là 0.33, tiếp theo là log_cap_gain (0.28), age và hours_per_week (cùng 0.27) và log_cap_loss thấp nhất (0.14). Giữa các biến số với nhau tương quan đều yếu: age với education_num là 0.07, age với hours_per_week là 0.14, education_num với hours_per_week là 0.17, và log_cap_gain với log_cap_loss là -0.07. Hệ số âm nhẹ này khớp với việc không dòng nào có cả lãi và lỗ vốn. Vì các biến số ít chồng lấn nhau, mỗi biến mang một phần thông tin riêng, và không có biến số nào vượt trội, cao nhất cũng chỉ 0.33.

Bảng 3.10. Cramér's V giữa ba biến có thể chồng lấn

Cặp biến	Cramér's V	Mức
relationship và sex	0.649	Mạnh nhất
relationship và marital_status	0.488	Mạnh
marital_status và sex	0.462	Mạnh

Cần cảnh báo về ba biến relationship, marital_status và sex. Bảng 3.10 cho thấy các cặp giữa chúng có Cramér's V từ 0.462 đến 0.649, cao hơn mối liên hệ của từng biến với thu nhập (0.216 đến 0.454). Vì vậy không nên cộng độ mạnh của ba biến, hay hiểu sex hoặc marital_status là các yếu tố liên hệ độc lập với thu nhập. Một phần của sex chẳng hạn đã nằm sẵn trong relationship, vì các nhóm như Husband và Wife ngầm chứa giới tính.

3.4. Bảng tổng hợp kết quả kiểm định

Bảng 3.11. Tổng hợp kết quả kiểm định năm giả thuyết

Mã	Phương pháp	Thống kê chính	Kết luận
H1	Spearman, tỷ lệ theo nhóm	ρ = 0.330. Tỷ lệ 16.0% (9 năm học) đến 74.1% (16 năm học)	Chấp nhận, kèm điều kiện: không đơn điệu ở mức 11, 12, nhóm 1 đến 3 năm học nhỏ
H2	Chi-square, Cramér's V	chi2 = 3,168.5, V = 0.312. Đỉnh 40.1% ở nhóm 45-54, 20.7% ở nhóm 65+	Chấp nhận
H3	Mann-Whitney, Spearman, tỷ lệ theo nhóm	rho = 0.27 (p < 1e-300). Mean giờ làm 45.47 và 38.84, median cùng 40. Tỷ lệ 6.9% đến 41.3%	Chấp nhận, có điều kiện: gần phẳng ở nhóm trên 50 giờ
H4	Chi-square, Cramér's V, tách theo biến thứ ba	V = 0.216. Thô 11.0% và 30.6%. Đã kết hôn 45.5% và 44.6%	Chấp nhận, có điều kiện: gần mất khi đã kết hôn, còn khi tách theo giờ làm
H5	Cramér's V, tỷ lệ theo nhóm, tách theo tuổi	V = 0.447. 44.7% và 4.6%. Nhóm 35-44: 50.3% và 10.7%	Chấp nhận: tuổi giải thích một phần, không hết

CHƯƠNG 4. ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ

4.1. Các phát hiện nổi bật

Học vấn đi cùng thu nhập cao rõ nhất ở các mức đại học trở lên. Tỷ lệ >50K tăng từ 16.0% ở nhóm 9 năm học lên 41.5% ở nhóm 13 và 74.1% ở nhóm 16 năm học, với hệ số Spearman 0.330 (Hình 3.1).

Vị trí trong gia đình và hôn nhân là nhóm biến liên hệ mạnh nhất, nhưng chúng chồng lấn nhau. relationship đạt Cramér's V 0.454 và marital_status đạt 0.447 (Hình 3.6). Nhóm Married-civ-spouse có tỷ lệ 44.7%, so với 4.6% ở nhóm Never-married (Hình 3.5). Ba biến relationship, marital_status, sex có Cramér's V từ 0.462 đến 0.649 với nhau (Bảng 3.10).

Tuổi có dạng đường cong có đỉnh. Tỷ lệ tăng từ 1.1% ở nhóm 17-24 lên đỉnh 40.1% ở nhóm 45-54 rồi giảm còn 20.7% ở nhóm 65+ (Hình 3.2).

Giờ làm liên hệ với thu nhập đến một mốc rồi gần như phẳng. Tỷ lệ là 6.9%, 20.7%, 39.6% và 41.3% qua bốn nhóm giờ làm, nên mức tăng gần như dừng sau nhóm 41-50 giờ (Hình 3.3).

Chênh lệch giữa nam và nữ phụ thuộc vào cách tách. Số liệu thô là 11.0% so với 30.6%, gần như biến mất trong nhóm đã kết hôn (45.5% so với 44.6%), nhưng vẫn còn khi tách theo giờ làm, chẳng hạn 10.3% so với 26.3% ở nhóm 35-40 giờ (Hình 3.4).

Thiếu dữ liệu nghề nghiệp đi cùng thu nhập thấp hơn. workclass và occupation thiếu 5.64% và 5.66%, và nhóm thiếu có tỷ lệ >50K là 10.4% so với 24.9% ở nhóm khai đủ (Bảng 2.2). Ngược lại native_group gần như không liên hệ với thu nhập (V = 0.039).

4.2. Đề xuất giải pháp ứng dụng

Các đề xuất dưới đây bám vào phát hiện ở mục 4.1. Vì mọi kết quả là liên hệ thống kê chứ không phải quan hệ nhân quả, mỗi đề xuất nên được hiểu là hướng ưu tiên để đánh giá thêm, không phải cam kết về hiệu quả. Không đề xuất nào dùng giới tính, quốc tịch hay tình trạng hôn nhân làm tiêu chí quyết định lương hoặc tuyển dụng.

Bảng 4.1. Đề xuất và phát hiện làm căn cứ

Đề xuất	Dựa trên phát hiện	Lưu ý
Mở rộng cơ hội tiếp cận và hoàn thành các bậc học từ mức 13 năm học trở lên, kèm hỗ trợ tài chính	Học vấn: 24.8% ở mức 12 lên 41.5% ở mức 13 (Hình 3.1)	Cần đánh giá riêng hiệu quả chương trình, vì học vấn còn đi cùng nhiều yếu tố khác
Đào tạo nghề và nâng kỹ năng cho nhóm 9 và 10 năm học	Hai mức này đông nhất (10,494 và 7,282 dòng) và có tỷ lệ 16.0% và 19.0% (Bảng 3.2)	Cần dữ liệu theo nghề để chọn đúng ngành đào tạo
Hỗ trợ việc làm đầu đời, thực tập và hướng nghiệp cho nhóm 17-24 và 25-34	Tỷ lệ 1.1% và 16.8%, thấp nhất trong các nhóm tuổi (Bảng 3.3)	Dữ liệu cắt ngang năm 1994, một phần là khác biệt giữa các thế hệ

Đề xuất	Dựa trên phát hiện	Lưu ý
Có chương trình việc làm linh hoạt và hỗ trợ thu nhập cho nhóm 65+	Tỷ lệ giảm còn 20.7% sau đỉnh 40.1% (Hình 3.2)	Mẫu 65+ chỉ có 1,335 dòng
Thiết kế biểu mẫu thu thập nghề nghiệp để phân biệt "chưa từng đi làm" với "không khai báo"	Thiếu workclass, occupation đi cùng tỷ lệ 10.4% (Bảng 2.2), 7 dòng Never-worked (Bảng 2.1)	Chỉ cải thiện chất lượng dữ liệu, chưa tác động trực tiếp lên thu nhập
Theo dõi chênh lệch nam nữ theo giờ làm bằng dữ liệu chi tiết hơn về nghề, vị trí, thâm niên trước khi kết luận	Chênh lệch còn khi tách theo giờ làm nhưng gần mất ở nhóm đã kết hôn (Bảng 3.5, 3.6)	Bài không kết luận có hay không có phân biệt đối xử

4.3. Giới hạn của dữ liệu và phân tích

- **Thời điểm và phạm vi.** Dữ liệu năm 1994 và chỉ ở Mỹ, nên kết quả khó áp dụng trực tiếp cho giai đoạn hoặc quốc gia khác.
- **Ngưỡng nhị phân.** Ngưỡng 50K chia thu nhập thành hai nhãn, làm mất thông tin về mức thu nhập cụ thể. Hai nhãn cũng mất cân bằng, <=50K chiếm 75.92% và >50K chiếm 24.08%.
- **Giá trị bị chặn trên.** capital_gain và capital_loss bị chặn ở 99,999 và có thể ở các mức khác, với 159 dòng bằng 99,999 đều là >50K, nên không phân biệt được mức lãi vốn thật trong nhóm này.
- **Nhóm nhỏ.** Tỷ lệ ở các nhóm nhỏ kém ổn định, như Married-AF-spouse chỉ có 23 dòng và các mức 1 đến 3 năm học có 50, 166 và 332 dòng.
- **Biến chồng lấn.** relationship, marital_status và sex chồng lấn nhau (V từ 0.462 đến 0.649), nên không thể đọc độ mạnh liên hệ của từng biến một cách độc lập.
- **Tách từng biến một.** Ở H4 và H5, bài tách theo từng biến riêng lẻ chứ chưa tách đồng thời nhiều biến, nên chưa loại trừ hết các yếu tố đi kèm.
- **Quyết định có chủ ý.** Việc bỏ 24 dòng trùng là một lựa chọn vì không có cột định danh để chứng minh đó là bản ghi lặp, và nhãn Unknown giả định rằng "không khai báo" là một nhóm có ý nghĩa riêng.
- **Chưa gia quyền.** Cột fnlwgt chưa được dùng, nên các tỷ lệ là tỷ lệ trong mẫu, chưa phản ánh dân số.
- **Dữ liệu cắt ngang.** Kết quả mô tả sự khác biệt giữa các nhóm tại một thời điểm, không theo dõi cùng một người theo thời gian.

4.4. Hướng mở rộng trong tương lai

- Dùng fnlwgt để gia quyền các tỷ lệ, cho kết quả có ý nghĩa với toàn dân số.
- So sánh kết quả với dữ liệu điều tra hiện đại để xem các mối liên hệ có thay đổi không.

- Phân tích thu nhập theo nhóm nghề chi tiết hơn, đặc biệt với occupation.
- Tách đồng thời hôn nhân, giờ làm, tuổi và học vấn khi so sánh nam và nữ.

Trong tương lai, dữ liệu đã làm sạch này cũng có thể làm đầu vào cho một mô hình dự đoán thu nhập.

KẾT LUẬN

Bài phân tích bộ dữ liệu Adult Census Income gồm 32,561 quan sát và 15 thuộc tính, với câu hỏi những yếu tố nào liên hệ với việc có thu nhập trên 50K. Ở giai đoạn đánh giá, giá trị thiếu mã hóa bằng "?" ở ba cột khiến isna() báo 0, và hai nhãn thu nhập mất cân bằng với 24.08% là >50K. Ở giai đoạn làm sạch, các giá trị thiếu được gán nhãn Unknown, 24 dòng trùng bị loại, và log1p giảm độ lệch của capital_gain từ 11.95 xuống 3.09 nhưng gần như không cải thiện capital_loss.

Năm giả thuyết đều được chấp nhận, ba trong số đó với điều kiện. Học vấn đi cùng tỷ lệ thu nhập cao hơn, từ 16.0% ở 9 năm học lên 74.1% ở 16 năm học. Tuổi cho đường cong có đỉnh 40.1% ở nhóm 45-54. Giờ làm liên hệ với thu nhập đến nhóm 41-50 giờ rồi gần như phẳng. Hôn nhân liên hệ mạnh, với 44.7% ở Married-civ-spouse so với 4.6% ở Never-married, và tuổi chỉ giải thích một phần. Chênh lệch thô giữa nam và nữ gần như không còn trong nhóm đã kết hôn nhưng còn khi tách theo giờ làm.

Giới hạn lớn nhất là dữ liệu chỉ phản ánh nước Mỹ năm 1994, nhãn thu nhập nhị phân, và ba biến relationship, marital_status, sex chồng lấn nhau. Kết quả vì vậy chỉ mô tả mối liên hệ thống kê. Các hướng tiếp theo gồm gia quyền bằng fnlwgt, đối chiếu với dữ liệu hiện đại và tách đồng thời nhiều biến.

TÀI LIỆU THAM KHẢO

[1] "Adult Census Income," Kaggle, UCI Machine Learning. [Online]. Available: https://www.kaggle.com/datasets/uciml/adult-census-income (accessed Nov. 2, 2026).

[2] B. Becker and R. Kohavi, "Adult," UCI Machine Learning Repository, 1996. [Online]. Available: https://archive.ics.uci.edu/dataset/2/adult (accessed Nov. 2, 2026).

[3] The pandas development team, "pandas documentation." [Online]. Available: https://pandas.pydata.org/docs

[4] M. L. Waskom, "seaborn: statistical data visualization," J. Open Source Softw., vol. 6, no. 60, p. 3021, 2021.

[5] P. Virtanen et al., "SciPy 1.0: Fundamental algorithms for scientific computing in Python," Nat. Methods, vol. 17, pp. 261-272, 2020.

[6] C. Spearman, "The proof and measurement of association between two things," Am. J. Psychol., vol. 15, no. 1, pp. 72-101, 1904.

[7] H. Cramér, Mathematical Methods of Statistics. Princeton, NJ, USA: Princeton Univ. Press, 1946.

[8] H. B. Mann and D. R. Whitney, "On a test of whether one of two random variables is stochastically larger than the other," Ann. Math. Statist., vol. 18, no. 1, pp. 50-60, 1947.

PHỤ LỤC

Phụ lục A. Mã nguồn

Mã nguồn: https://github.com/dladat/group19-dataset9-adult-census-income

Phụ lục B. Mô tả đầy đủ các thuộc tính

Bảng B.1. Kiểu và các giá trị của 15 thuộc tính

Thuộc tính	Kiểu	Giá trị
age	Số	Số nguyên từ 17 đến 90
workclass	Chữ	Private, Self-emp-not-inc, Local-gov, ?, State-gov, Self-emp-inc, Federal-gov, Without-pay, Never-worked
fnlwgt	Số	Số nguyên từ 12,285 đến 1,484,705
education	Chữ	HS-grad, Some-college, Bachelors, Masters, Assoc-voc, 11th, Assoc-acdm, 10th, 7th-8th, Prof-school, 9th, 12th, Doctorate, 5th-6th, 1st-4th, Preschool
education_num	Số	Số nguyên từ 1 đến 16
marital_status	Chữ	Married-civ-spouse, Never-married, Divorced, Separated, Widowed, Married-spouse-absent, Married-AF-spouse
occupation	Chữ	Prof-specialty, Craft-repair, Exec-managerial, Adm-clerical, Sales, Other-service, Machine-op-inspct, ?, Transport-moving, Handlers-cleaners, Farming-fishing, Tech-support, Protective-serv, Priv-house-serv, Armed-Forces
relationship	Chữ	Husband, Not-in-family, Own-child, Unmarried, Wife, Other-relative
race	Chữ	White, Black, Asian-Pac-Islander, Amer-Indian-Eskimo, Other
sex	Chữ	Male, Female
capital_gain	Số	Số nguyên từ 0 đến 99,999
capital_loss	Số	Số nguyên từ 0 đến 4,356
hours_per_week	Số	Số nguyên từ 1 đến 99
native_country	Chữ	United-States, Mexico, ?, Philippines, Germany, Canada, Puerto-Rico, El-Salvador, India, Cuba, England, Jamaica, South, China, Italy, Dominican-Republic, Vietnam, Guatemala, Japan, Poland, Columbia, Taiwan, Haiti, Iran, Portugal, Nicaragua, Peru, Greece, France, Ecuador, Ireland, Hong, Trinadad&Tobago, Cambodia, Laos, Thailand, Yugoslavia, Outlying-US(Guam-USVI-etc), Honduras, Hungary, Scotland, Holand-Netherlands
income	Chữ	<=50K, >50K

Danh sách giá trị tra từ adult.csv*, sắp xếp từ giá trị phổ biến nhất. Dấu "?" là mã của giá trị thiếu.*

Phụ lục C. Danh sách hình và tên tệp ảnh

Bảng C.1. Hình trong báo cáo và tệp ảnh tương ứng

Hình	Tệp ảnh	Nội dung
2.1	01_missing.png	Tỷ lệ missing sau khi đổi "?" thành NaN
2.2	02_boxplot_numeric.png	Boxplot sáu cột số
2.3	03_capital_gain_log.png	capital_gain > 0 trước và sau log1p
3.1	04_h1_education.png	H1, tỷ lệ >50K theo số năm học
3.2	05_h2_age.png	H2, tỷ lệ >50K theo nhóm tuổi
3.3	06_h3_hours.png	H3, tỷ lệ >50K theo giờ làm
3.4	07_h4_sex.png	H4, giới tính theo hôn nhân và giờ làm
3.5	08_h5_marital.png	H5, tỷ lệ >50K theo hôn nhân
3.6	09_cramers_v.png	Cramér's V
3.7	10_heatmap.png	Heatmap Spearman